



COPPE/UFRJ

ANÁLISE DE COMPONENTES INDEPENDENTES PARA UMA FILTRAGEM
ONLINE BASEADA EM CALORIMETRIA DE ALTA ENERGIA E COM FINA
SEGMENTAÇÃO

Eduardo Furtado de Simas Filho.

Tese de Doutorado apresentada ao Programa de Pós-graduação em Engenharia Elétrica, COPPE, da Universidade Federal do Rio de Janeiro, como parte dos requisitos necessários à obtenção do título de Doutor em Engenharia Elétrica.

Orientadores: José Manoel de Seixas
Luiz Pereira Calôba

Rio de Janeiro
Junho de 2010

ANÁLISE DE COMPONENTES INDEPENDENTES PARA UMA FILTRAGEM
ONLINE BASEADA EM CALORIMETRIA DE ALTA ENERGIA E COM FINA
SEGMENTAÇÃO

Eduardo Furtado de Simas Filho.

TESE SUBMETIDA AO CORPO DOCENTE DO INSTITUTO ALBERTO LUIZ
COIMBRA DE PÓS-GRADUAÇÃO E PESQUISA DE ENGENHARIA (COPPE)
DA UNIVERSIDADE FEDERAL DO RIO DE JANEIRO COMO PARTE DOS
REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE DOUTOR
EM CIÊNCIAS EM ENGENHARIA ELÉTRICA.

Examinada por:

Prof. José Manoel de Seixas, D.Sc.

Prof. Luiz Pereira Calôba, Dr.Ing.

Prof. Luiz Wagner Pereira Biscainho, D.Sc.

Prof. Marley M. B. Rebuzzi Vellasco, Ph.D.

Prof. Leandro Salazar de Paula, D.Sc.

Prof. André Ponce de Leon F. de Carvalho, Ph.D

RIO DE JANEIRO, RJ – BRASIL

JUNHO DE 2010

Simas Filho., Eduardo Furtado de

Análise de Componentes Independentes para uma Filtragem Online Baseada em Calorimetria de Alta Energia e com Fina Segmentação/Eduardo Furtado de Simas Filho.. – Rio de Janeiro: UFRJ/COPPE, 2010.

XVI, 108 p.: il.; 29, 7cm.

Orientadores: José Manoel de Seixas

Luiz Pereira Calôba

Tese (doutorado) – UFRJ/COPPE/Programa de Engenharia Elétrica, 2010.

Referências Bibliográficas: p. 71 – 85.

1. Análise de Componentes Independentes.
 2. Filtragem Online.
 3. Calorimetria de Alta Energia.
- I. Seixas, José Manoel de *et al.*. II. Universidade Federal do Rio de Janeiro, COPPE, Programa de Engenharia Elétrica. III. Título.

Aos meus amores Cléa e Letícia.

Agradecimentos

Agradeço ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) pelo suporte financeiro concedido em parte do tempo no qual este trabalho foi desenvolvido.

Sou profundamente grato ao apoio, motivação e conhecimentos que me foram passados por meus orientadores, os professores José Manoel de Seixas e Luiz Pereira Calôba, sem os quais este trabalho não existiria.

Agradeço aos colegas, professores e funcionários do Laboratório de Processamento de Sinais (LPS/COPPE/UFRJ) pela inestimável ajuda na condução do trabalho, em especial aos amigos Natanael Nunes de Moura, Rodrigo Coura Torres e Danilo Enoque Ferreira.

Também gostaria de agradecer ao apoio do Instituto Federal de Educação, Ciência e Tecnologia da Bahia, em especial aos professores e funcionários do Campus Simões Filho.

Finalmente preciso agradecer à minha família e meus amigos por suportarem minha ausência durante este período e por me incentivarem sempre a continuar. Em especial a minha esposa Cléa e minha filha Letícia pelo amor e apoio em todos os momentos.

Resumo da Tese apresentada à COPPE/UFRJ como parte dos requisitos necessários para a obtenção do grau de Doutor em Ciências (D.Sc.)

ANÁLISE DE COMPONENTES INDEPENDENTES PARA UMA FILTRAGEM ONLINE BASEADA EM CALORIMETRIA DE ALTA ENERGIA E COM FINA SEGMENTAÇÃO

Eduardo Furtado de Simas Filho.

Junho/2010

Orientadores: José Manoel de Seixas

Luiz Pereira Calôba

Programa: Engenharia Elétrica

O ATLAS é o maior detector de partículas do experimento LHC. Nas colisões do LHC, uma enorme quantidade de informação é produzida, porém, apenas uma pequena parcela é importante para a caracterização dos fenômenos físicos de interesse, tornando necessário um eficiente sistema de filtragem *online* de eventos. Informações da energia depositada no sistema de calorímetros (medidores de energia) são utilizadas para a identificação das partículas. Os elétrons são partículas extremamente importantes para o experimento, e, no ambiente do LHC, aparecem mascarados por um intenso ruído de fundo composto de jatos hadrônicos, pois esses últimos podem apresentar perfil de deposição de energia semelhante ao de elétrons. Neste trabalho, é proposta a utilização de métodos de extração de características, como a análise de componentes independentes, para otimizar o desempenho do segundo nível de filtragem *online* do detector ATLAS. A extração de características foi efetuada visando explorar toda a segmentação e granularidade disponíveis nos calorímetros. A partir da utilização da abordagem proposta neste trabalho foi possível alcançar alta eficiência de discriminação, gerando dados mais limpos para a análise *offline*.

Abstract of Thesis presented to COPPE/UFRJ as a partial fulfillment of the requirements for the degree of Doctor of Science (D.Sc.)

INDEPENDENT COMPONENT ANALYSIS FOR ONLINE FILTERING
BASED ON HIGH-ENERGY AND HIGHLY SEGMENTED CALORIMETRY

Eduardo Furtado de Simas Filho.

June/2010

Advisors: José Manoel de Seixas

Luiz Pereira Calôba

Department: Electrical Engineering

Here goes the abstract ...

Sumário

Lista de Figuras	xi
Lista de Tabelas	xiii
Símbolos e Abreviaturas	xiv
1 Introdução	1
1.1 Contexto	1
1.2 Motivação	2
1.3 Objetivos	6
1.4 Metodologia	6
1.5 Conteúdo do trabalho	7
2 Física de Partículas e o detector ATLAS	8
2.1 Panorama geral da física de partículas elementares	8
2.2 O acelerador LHC	13
2.3 Características gerais do detector ATLAS	14
2.3.1 O sistema de calorimetria do ATLAS	19
2.3.2 Principais objetos de interesse no ATLAS	25
3 O Sistema de Filtragem do detector ATLAS	27
3.1 Introdução aos sistemas de filtragem em HEP	27
3.2 O sistema de filtragem do ATLAS	29
3.2.1 Primeiro nível de filtragem	31
3.2.2 Filtragem de alto nível	33

4	Filtragem de Elétrons partir de Informações de Calorimetria	37
4.1	Filtragem de elétrons no L2 - Algoritmo T2Calo	38
4.2	Descrição dos dados utilizados	40
4.2.1	Sinais simulados - Corte E10 <i>loose</i>	41
4.2.2	Sinais simulados - Corte E15i	41
4.2.3	Raios Cósmicos	41
4.2.4	Sinais Reais de Colisões do LHC	42
4.3	Neural Ringer - Alternativa para Filtragem de Elétrons no L2 do ATLAS	42
5	Revisão da Literatura	45
5.1	Aplicações em Física de Altas Energias e Áreas Correlatas	46
5.1.1	Aplicações de classificadores neurais	46
5.1.2	Aplicações de técnicas estatísticas de extração de características	47
5.2	Técnicas de Extração de Características Utilizadas neste Trabalho . .	49
5.2.1	Mapas auto-organizáveis	49
5.2.2	Análise de Componentes Principais	51
5.2.3	Análise de Componentes Independentes	53
5.2.4	ICA não-linear	56
6	Metodologia Proposta	66
6.1	Sistemas de Classificação Propostos para a Seleção de Elétrons no Segundo-Nível de Filtragem do ATLAS	66
6.1.1	Classificadores Neurais Supervisionados	67
6.1.2	Combinação de Múltiplos Classificadores	69
7	Resultados	70
7.1	Resultados - Dados simulados / corte L1 do tipo E10 <i>loose</i>	70
7.2	Resultados - Dados simulados / corte L1 do tipo E15i	70
7.3	Resultados - Sinais de raios cósmicos	70
7.4	Resultados - Sinais Reais de Colisões do LHC	70
	Referências Bibliográficas	71

A Aspectos Teóricos das Técnicas de Extração de Características	86
A.1 Mapas auto-organizáveis	86
A.1.1 Quantização vetorial por aprendizado	86
A.1.2 Classificação a partir do mapa de características	88
A.2 Análise de Componentes Principais	88
A.2.1 Redução de dimensão	88
A.3 Análise de Componentes Independentes	89
A.3.1 Princípios de estimação das componentes independentes	89
A.3.2 Pré-processamento dos sinais para ICA	93
A.3.3 Principais algoritmos para ICA	93
A.3.4 Extensões ao modelo básico de ICA	97
A.4 ICA não-linear	99
A.4.1 Algoritmo Taleb-Jutten para o modelo PNL	100
 B Conceitos fundamentais em classificação de sinais	 102
B.1 Teste de Hipóteses	102
B.2 Critério de Bayes	103
B.3 Filtros Casados	104
B.4 Discriminante linear de Fisher	106
B.5 Classificadores Neurais	106

Lista de Figuras

1.1	Diagrama das etapas envolvidas no processo de discriminação elétron/jato.	5
2.1	Diagrama do Modelo Padrão, mostrando as partículas elementares incluindo o, ainda não confirmado, bóson de Higgs.	10
2.2	Mapa de localização dos detectores do LHC.	14
2.3	Diagrama esquemático do ATLAS.	15
2.4	Eixo de coordenadas do ATLAS.	16
2.5	Cortes (a) transversal e (b) axial do ATLAS.	18
2.6	Disposição em camadas dos calorímetros do ATLAS.	22
2.7	Granularidade e profundidade das camadas do calorímetro eletro- magnético, extraído de [1].	24
3.1	Diagrama em blocos do sistema de filtragem e aquisição de dados do ATLAS.	30
3.2	Diagrama em blocos do primeiro nível de filtragem.	33
3.3	Diagrama em blocos do segundo nível de filtragem.	36
4.1	Janela deslizante analisada pelo L1 no calorímetro eletromagnético. .	38
4.2	Diagrama do processo de construção dos anéis.	42
4.3	Sinais medidos na camada EM2 para (a) elétron e (b) jato.	43
4.4	Sinais em anéis para (a) elétron típico, (b) jato típico e (c) jato com perfil semelhante ao de elétrons.	44
5.1	Diagrama de um mapa auto-organizável	50
5.2	Diagrama do <i>cocktail party problem</i>	55
5.3	Sinais (a) fonte, (b) observados e (c) recuperados através da ICA. . .	56

5.4	Diagrama do modelo de mistura PNL.	59
5.5	Diagrama do modelo PNL-L.	60
5.6	Diagrama do modelo da Mono não-linearidade.	61
5.7	NLICA a partir de SOM.	61
5.8	Diagrama do modelo da ICA local.	64
6.1	Processo de extração de características globais.	67
6.2	Processo de extração de características segmentadas.	67
6.3	Decisão utilizando classificador global.	68
6.4	Decisão utilizando classificadores segmentados.	68
A.1	Diagrama da classificação a partir do mapa de características	88
A.2	Compressão e recuperação do sinal \mathbf{x} utilizando a transformação por PCA.	89
A.3	Diagrama do algoritmo de Taleb-Jutten para o modelo PNL.	100
B.1	Esquemático do problema de classificação binário.	102
B.2	Diagrama em blocos de um filtro casado.	105
B.3	Exemplo de uma rede neural utilizada para separação dos sinais de entrada em 3 classes.	107

Lista de Tabelas

2.1	Intensidade relativa (em comparação com a interação forte) dos diversos tipos de interação.	10
2.2	Exemplos de valores da massa (em energia equivalente) de algumas partículas.	12
2.3	Região de cobertura em η , granularidade e número de canais de leitura das camadas dos calorímetros.	23
2.4	Principais objetos de interesse no ATLAS, extraída de [2].	26
3.1	Principais características do sistema de <i>trigger</i> do ATLAS, onde Te e Ts são, respectivamente, as taxas de eventos na entrada e na saída e $Cr = Te/Ts$ é o coeficiente de redução de eventos.	31
3.2	Frequência esperada para os principais canais de <i>trigger</i> no primeiro nível de filtragem do ATLAS ($L=10^{34}\text{cm}^{-2}\text{s}^{-1}$).	34
4.1	Número de anéis formados para cada camada do calorímetro do ATLAS.	43

Símbolos e Abreviaturas

Símbolos

c	Velocidade da Luz no Vácuo
E	Energia
eV	Elétron-Volt
$\mathcal{E}(\cdot)$	Operador esperança
$E f_i$	Eficiência de discriminação da classe i
E_T	Energia transversa
E_T^{miss}	Energia transversa faltante
$H(\cdot)$	Entropia
$I(\cdot)$	Informação mútua
$J(\cdot)$	Negentropia
$kurt(\cdot)$	Curtose
m	Massa
p_T	Momento transverso
$p_x(x)$	Função de densidade de probabilidade
η	Pseudo-rapidez
θ	Ângulo polar no sistema de coordenadas do ATLAS
$\lambda(\cdot)$	Razão de semelhança
ϕ	Ângulo azimutal no sistema de coordenadas do ATLAS
e^-/j	Elétron/Jato
\mathbf{s}	Vetor das fontes independentes
\mathbf{x}	Vetor dos sinais observados (medidos)
\mathbf{y}	Vetor dos componentes independentes estimados
\mathbf{z}	Vetor dos sinais branqueados

Abreviaturas

No caso de algumas abreviaturas internacionalmente conhecidas, optou-se por manter as mesmas em inglês.

ALICE	Detector do LHC
ATLAS	<i>A Toroidal LHC ApparatuS</i>
BOOSTER	Experimento do laboratório Fermilab
CERN	Centro Europeu Para Pesquisa Nuclear
CHOOZ	Experimento de Física de Alta Energia
CMB	<i>Cosmic Microwave Background</i>
CMS	Detector do LHC
CP	<i>Charge parity</i>
CPLD	<i>Complex Programmable Logic Device</i>
DESY	<i>Deutsches Elektronen-Synchrotron</i>
EF	Filtro de Eventos (<i>Event Filter</i>)
EM	Eletromagnético
FastICA	Algoritmo de extração das componentes independentes
FPGA	<i>Field-Programmable Gate Array</i>
Fermilab	<i>Fermi National Accelerator Laboratory</i>
GTM	<i>Generative topographic mapping</i>
H1	Detector do acelerador HERA
HLT	<i>High Level Trigger</i>
HEP	<i>High-Energy Physics</i>
HERA	Experimento do laboratório DESY
HEGRA	Experimento de astrofísica de alta energia
IC	Componentes independentes
ICA	<i>Independent components analysis</i>
JADE	<i>Joint Approximate Diagonalization of Eigen-matrices</i>
LEAR	Experimento do CERN (desativado)
LEP	Experimento do CERN (desativado)

LHC	<i>Large Hadron Collider</i>
LVL1	Primeiro nível de filtragem do ATLAS
LVL2	Segundo nível de filtragem do ATLAS
LVQ	Quantização vetorial por aprendizado
MLP	Perceptron de múltiplas camadas
NLICA	<i>Non-linear independent component analysis</i>
NLPCA	<i>Non-linear principal component analysis</i>
PC	Computador pessoal
PCA	<i>Principal components analysis</i>
OGLE	Telescópio instalado no Chile
QV	Quantização vetorial
RNA	Rede Neural Artificial
ROC	<i>Receiver operating characteristic</i>
RoI	Região de interesse (<i>Region of Interest</i>)
RPROP	<i>Resilient back-propagation</i>
SICA	<i>Segmented independent component analysis</i>
SPCA	<i>Segmented principal component analysis</i>
SM	Modelo Padrão de interação entre as partículas elementares (<i>Standard Model</i>)
SOM	Mapa auto-organizável
SP	Figura de mérito de desempenho de classificação
SUSY	Supersimetria
T2Calo	Algoritmo de discriminação do HLT do ATLAS
TOTEM	Experimento do LHC

Capítulo 1

Introdução

O processamento estatístico de sinais encontra aplicações nas diversas áreas do conhecimento, desde medicina e saúde pública até as bolsas de valores. Seu uso simplifica bastante as tarefas de análise de dados e classificação, pois permite mapear os sinais em um espaço onde as características discriminantes estão mais evidentes.

Este trabalho descreve a aplicação das técnicas de processamento estatístico para a extração de características relevantes de sinais de um detector de partículas elementares de alta energia. As características e padrões extraídos são utilizados para guiar o processo de discriminação das partículas em um experimento de colisão de partículas de alta taxa de eventos e com enorme volume de dados produzidos.

1.1 Contexto

Com os constantes avanços tecnológicos dos sistemas eletrônicos de aquisição de informações, é crescente a necessidade de técnicas eficientes para o processamento *online* de sinais. As grandezas físicas são registradas por elementos sensores, que podem ser únicos (como na medição da velocidade de um motor), ou combinados aos milhares para obter o resultado final (como na captura de vídeo e imagem digitais).

Em aplicações onde a fina granularidade da informação é necessária para descrever adequadamente o processo físico em questão, e sinais com alta dimensão são assim gerados por sistemas de medição compostos por um número elevado de sensores, o custo computacional geralmente é alto. Em alguns casos, a informação disponível pode estar segmentada, pois foi produzida a partir de conjuntos de sen-

sores com características distintas.

Se há a necessidade de uma resposta rápida, pode ser utilizada a combinação de técnicas de compactação de sinais e processamento distribuído. O cenário pode ficar ainda mais complicado se o volume de dados é alto e o problema a ser resolvido apresenta elevado grau de complexidade.

O ambiente de aplicação deste trabalho é o sistema *online* de filtragem do ATLAS (*A Toroidal LHC Apparatus*) [1], maior detector de propósito geral do acelerador de partículas LHC (*Large Hadron Collider*) [3]. O LHC entrou em operação no final de 2008, logo depois, passou por reparos no sistema de resfriamento de um dos seus supercondutores, voltando a operar no final de 2009.

No LHC, os sinais de interesse são raros, estão imersos em um intenso ruído de fundo e a perda de um desses eventos compromete severamente o desempenho dos detectores. Neste caso, é necessária uma estratégia de filtragem capaz de remover, ou pelo menos atenuar a intensidade do ruído sem perder os eventos de interesse.

Combinado a isso, a taxa de ocorrência de eventos é extremamente elevada, fazendo com que o intervalo entre eventos consecutivos seja extremamente pequeno. Considerando ainda que os detectores são altamente segmentados e apresentam fina granularidade de células detectoras, a quantidade de informação produzida é enorme. Neste contexto, a seleção de eventos precisa ser realizada de modo *online* e sob severas restrições no tempo de processamento..

Técnicas que utilizam informações da estatística dos sinais, como Análise de Componentes Principais (PCA - *Principal Component Analysis*) [4], Análise de Componentes Independentes ICA (*Independent Component Analysis*) [5] e Redes Neurais Artificiais (RNA) [6], são frequentemente utilizadas na solução de problemas onde há a necessidade de processamento veloz, flexível e eficiente.

1.2 Motivação

Desde o final do século 19, quando foi descoberto o elétron, o estudo da física de partículas elementares, ou simplesmente física de partículas, teve um crescimento acentuado. Na década de 1950, com o uso dos aceleradores, foram descobertas centenas de novas partículas. A física de partículas de alta energia pretende encontrar

os componentes fundamentais da matéria e descrever suas formas de interação.

O acelerador de partículas LHC [3] é um experimento em desenvolvimento no CERN (Organização Europeia para Pesquisa Nuclear) que entrou em operação no segundo semestre de 2008. Ao operar na máxima capacidade, produzirá uma taxa de eventos que chegará a 40MHz. Entretanto, as assinaturas de interesse, se existirem, ocorrerão com uma frequência de alguns Hertz, o que faz do sistema de filtragem um componente fundamental para os detectores.

O detector ATLAS [1] é um experimento de propósito geral e está posicionado em um dos pontos de colisão do LHC. Entre os principais objetivos do ATLAS, pode-se destacar a busca pela partícula conhecida como *bóson de Higgs*, que segundo estudos teóricos seria responsável por interagir com as partículas fornecendo-lhes massa [7]. A partícula de Higgs ainda não foi verificada experimentalmente.

Parcela importante das informações necessárias para a caracterização dos eventos é obtida do sistema de calorímetros, que é subdividido em 7 camadas, sendo que 4 foram projetadas para as partículas eletromagnéticas e 3 para as hadrônicas. Os calorímetros são, na verdade, medidores de energia compostos por um grande número de sensores (também chamados de células). As células dos calorímetros quantificam a energia perdida pelas partículas incidentes ao interagirem com o material do detector. Para a caracterização do tipo de partícula usa-se informação do perfil de deposição de energia nas camadas do calorímetro.

Operando em máxima capacidade o LHC irá colidir feixes de prótons a cada 25 ns. Numa colisão uma quantidade enorme de energia será transformada em um grande número de partículas. A maior parte da informação a ser gerada já foi visualizada em experimentos anteriores, não sendo relevante para os detectores do LHC. A chamada nova física, ou física de interesse, representa uma pequena parcela das informações produzidas. Os eventos da física de interesse devem ser armazenados para futura análise detalhada. Percebe-se, então, a importância do sistema *online* de filtragem e classificação, que deve ser capaz de identificar os eventos de interesse dentro do intenso ruído de fundo. Uma eficiente filtragem *online* permite o processo de busca e análise *offline*.

Os objetivos principais do sistema de filtragem são maximizar a probabilidade de detecção (e conseqüente armazenamento) dos eventos de interesse, e minimizar

a probabilidade de armazenar eventos não desejados (ruído de fundo). Em um ambiente como este, a grande dimensão dos dados, o intenso ruído de fundo e o curto tempo de resposta exigido são sérios entraves para o processamento e classificação *online*.

No ATLAS, o sistema *online* de filtragem (*trigger*) de eventos é composto por três níveis, esperando-se armazenar, em mídia permanente, uma taxa máxima de 200 Hz [8]. Considerando que a frequência dos eventos é 40 MHz, deve haver uma redução de 2×10^5 vezes. O primeiro nível (LVL1 - *Level-One*), por restrições de tempo de resposta e quantidade de informação a ser processada, foi implementado em *hardware* dedicado, e reduzirá a taxa de eventos para 10kHz com latência menor que $2,5\mu s$. O segundo nível (LVL2 - *Level-Two*) e o filtro de eventos (EF - *Event Filter*) correspondem à filtragem de alto nível (HLT - *high level trigger*) e em conjunto precisam reduzir de 10kHz para 200Hz a frequência dos eventos. Devido à latência um pouco maior, da ordem de $10ms$ para o segundo nível e alguns segundos para o filtro de eventos, essas etapas serão realizadas em *software* através de um sistema de processamento distribuído que utiliza centenas de processadores semelhantes aos de computadores pessoais (PC). Algoritmos desenvolvidos pela colaboração do ATLAS estão prontos para operar nos diversos canais e níveis de filtragem existentes. Neste trabalho estão sendo propostas alternativas para o algoritmo padrão de identificação de elétrons. Os algoritmos desenvolvidos apresentam maior eficiência de discriminação e tempo de processamento dentro das restrições do LVL2.

Devido à grande intensidade de energia de algumas partículas, com o tempo de uso, algumas regiões do calorímetro podem ser submetidas a níveis de radiação muito além do que as células detectoras podem suportar, provocando mau funcionamento e até danificação total dessas regiões. Uma característica importante para os algoritmos de filtragem de eventos é a robustez à perda de informação por células danificadas.

Quando o LHC estiver operando em alta luminosidade, será comum o efeito de empilhamento (do inglês *pile-up*), ocasionado por uma sobreposição de eventos na mesma região do detector. Ou seja, um evento que ainda se desenvolve tem seu padrão de deposição de energia distorcido por um novo que chega e se sobrepõe, gerando um ruído de fundo que pode atingir grande intensidade. Os algoritmos de

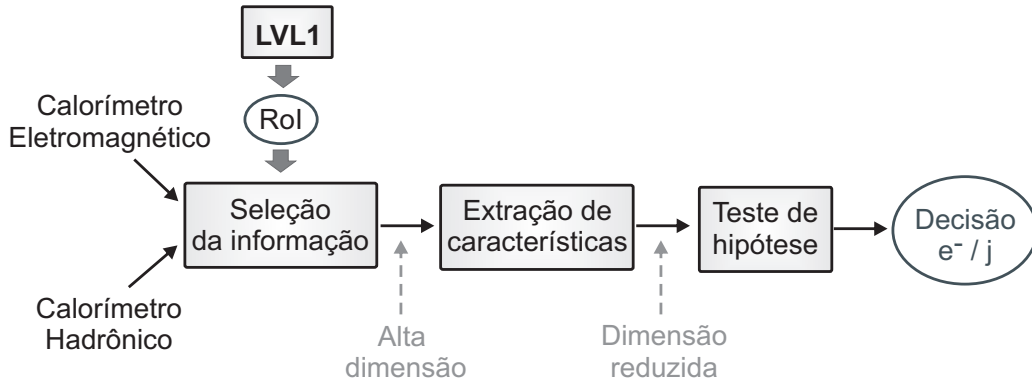


Figura 1.1: Diagrama das etapas envolvidas no processo de discriminação elétron/jato.

filtragem devem apresentar bom desempenho mesmo quando o empilhamento for frequente.

No contexto dos diversos canais de interesse para a física no ATLAS, este trabalho se encontra focado na discriminação elétron/jato (e^-/j). Os elétrons com alto momento transversal são componentes de muitas das assinaturas de Higgs. Porém, em termos de calorimetria, alguns jatos podem apresentar perfil de deposição de energia semelhante ao dos elétrons. Portanto, os jatos representam ruído de fundo no processo de identificação de elétrons. Apenas uma reduzida parcela dos candidatos a elétrons aceitos pelo primeiro nível serão realmente elétrons; portanto, cabe à filtragem de alto nível reduzir ainda mais o ruído de fundo sem perder assinaturas de interesse.

A cada evento, regiões diferentes do calorímetro são sensibilizadas, essas áreas são denominadas regiões de interesse (RoI - *Region of Interest*). O primeiro nível fornece para o segundo nível a localização primária das RoI.

Na Figura 1.1 são mostradas as etapas envolvidas no processo de filtragem no HLT. Inicialmente, os sinais dos calorímetros, que são compostos pelas leituras das células sensoras (de todas as sete camadas) que pertencem à RoI marcada pelo LVL1, são selecionados. Uma RoI típica é descrita por cerca de 700 células sensoras.

Em seguida as técnicas de extração de características tentam obter informações relevantes do conjunto de sinais e que serão utilizadas para o teste de hipótese e conseqüente decisão elétron/jato.

1.3 Objetivos

Considerando os desafios existentes no ambiente de filtragem *online* do ATLAS, onde os sinais são adquiridos com fina segmentação, estão imersos em intenso ruído de fundo e as assinaturas de interesse são raras, técnicas avançadas de extração de características podem ser utilizadas para melhorar a eficiência de classificação.

O principal objetivo deste trabalho é propor novos algoritmos para extração de características na filtragem de alto nível do ATLAS no canal elétron/jato. O trabalho será concentrado no desenvolvimento de algoritmos para os sinais de calorimetria.

Serão utilizadas técnicas avançadas de processamento estatístico de sinais, onde os principais desafios são a diminuição do tempo de processamento e a maximização da eficiência dos classificadores.

Os sistemas discriminadores propostos serão comparados em termos da eficiência global de discriminação e, também, considerando os diversos parâmetros de interesse para a física.

1.4 Metodologia

O projeto e teste dos discriminadores de partículas foram realizados a partir de um conjunto de eventos simulados. Estas simulações consideram todas as características físicas do detector e do acelerador. Os eventos simulados possuem rótulos de classe gerados pelos simuladores, ou seja, sabe-se a priori qual a classe da partícula que produziu cada um dos perfis de deposição de energia.

Foram utilizados também conjuntos de dados experimentais obtidos na fase inicial de operação do LHC. Além dos jatos, sabe-se também que os raios cósmicos representam ruído de fundo para o experimento, então, os algoritmos propostos foram testados para uma base de dados composta de eventos de raios cósmicos. Uma outra análise utilizou eventos adquiridos durante o primeiro ciclo de operação (*run*) do LHC no final de 2009.

1.5 Conteúdo do trabalho

No Capítulo 2 será apresentado o ambiente científico no qual o trabalho está sendo desenvolvido, contextualizando o detector de partículas ATLAS, o acelerador LHC e o CERN. Uma descrição detalhada do sistema de *trigger* também será apresentada.

No Capítulo 3 serão mostrados os fundamentos teóricos das técnicas de extração de características e teste de hipótese que serão utilizadas para a otimização do sistema de filtragem do ATLAS.

Os resultados obtidos serão apresentadas no Capítulo 4. As conclusões e os futuros trabalhos são os tópicos abordados no Capítulo 5.

Nos Apêndices A e B são fornecidas as bases matemáticas para uma melhor compreensão das técnicas estatística de processamento de sinais descritas no Capítulo 3.

Capítulo 2

Física de Partículas e o detector ATLAS

Os experimentos de Física de Partículas Elementares têm como principais objetivos a confirmação de modelos desenvolvidos teoricamente e a identificação de novos fenômenos. O experimento LHC [3] é o maior acelerador de partículas já desenvolvido e quando operando em máxima capacidade, serão gerados aproximadamente 10^9 interações por segundo. Os detectores são responsáveis por selecionar, dentro de um conjunto enorme, os eventos de real interesse, que são bastante raros. O projeto e a montagem do detector ATLAS (*A Thoroidal LHC Apparatus*) [1] foram conduzidos por uma colaboração de 36 países, conhecida como *ATLAS Collaboration*, contando com pesquisadores de mais de 150 universidades e centros de pesquisa [9]. Sendo um dos detectores de propósito geral do experimento LHC, o ATLAS tem formato cilíndrico e foi projetado para cobrir um ângulo sólido próximo a 4π ao redor da região de colisão.

2.1 Panorama geral da física de partículas elementares

A noção de que a matéria é composta por um conjunto de constituintes elementares existe há mais de 2000 anos, desde o tempo dos filósofos gregos [10]. No decorrer do século 20, a compreensão dos componentes elementares da matéria forneceu à comunidade científica mundial informações importantes a respeito das leis fundamentais

da natureza. O estudo da física de partículas elementares teve início no final do século 19, quando foi descoberto o elétron, experimentando um crescimento acentuado na década de 1950, quando foram descobertas centenas de novas partículas. A partir de sua criação em 1954, o CERN (Centro Europeu para Pesquisa Nuclear) contribuiu significativamente nesse processo.

Inicialmente, pensava-se que a matéria era constituída de partículas subatômicas, chamadas elétrons, prótons e nêutrons. Mais tarde, descobriu-se que os prótons e nêutrons são compostos de quarks. Hoje sabe-se que toda a matéria no universo é composta de léptons e quarks. Existem ainda outras partículas elementares que são responsáveis por promover a interação entre léptons e quarks. Juntamente com as descobertas experimentais, estudos teóricos possibilitaram o desenvolvimento do Modelo Padrão (SM-*Standard Model*) [7] que descreve e prevê, de forma unificada, o comportamento das partículas e das forças de interação.

As características e propriedades dos processos nucleares dependem da energia envolvida. A unidade de energia mais utilizada, neste contexto, é o elétron-volt (eV) e seus múltiplos (MeV, GeV ou TeV). O elétron-volt é definido como a energia necessária para aumentar o potencial elétrico de um elétron em 1 volt (em unidades do Sistema Internacional - SI temos: $1\text{eV}=1,6\times 10^{-19}\text{J}$) [11]. Os fenômenos produzidos quando a energia das partículas é menor que 20MeV são chamados de física a baixas energias. A faixa entre 20MeV e 400MeV corresponde à física a energias intermediárias, e finalmente, fenômenos com energia superior a 400MeV são estudados na física a altas energias [12].

Os experimentos realizados a partir do início da década de 1970 foram fundamentais para o desenvolvimento e teste do Modelo Padrão, mas também despertaram dúvidas a respeito de questões que não são completamente respondidas. O SM (ver Figura 2.1), divide as partículas elementares em quarks e léptons. Existem seis tipos de léptons (elétron, múon, tau e três neutrino) e seis tipos de quarks (*up*, *down*, *charm*, *strange*, *top* e *bottom*).

Atualmente são conhecidas quatro formas de interação (ou acoplamento) entre as partículas elementares, são elas eletromagnética, gravitacional, fraca e forte. A força gravitacional é predominante entre corpos massivos separados por longas distâncias. Entre partículas, onde a massa é da ordem de 10^{-27}Kg , a interação




Figura 2.1: Diagrama do Modelo Padrão, mostrando as partículas elementares incluindo o, ainda não confirmado, bóson de Higgs.

gravitacional tem intensidade muito baixa. Para distâncias maiores que 10^{-13}cm , a força eletromagnética domina, enquanto que para distancias menores, as interações forte e fraca se destacam. A intensidade relativa (em comparação com a interação forte) dos quatro tipos de interação é mostrada na Tabela 2.1 [13].

Existem algumas teorias que descrevem como as interações elementares ocorrem. A eletrodinâmica quântica (QED - *Quantum Eletrodynamics*) considera que os processos elétricos e magnéticos acontecem a partir da interação fundamental entre dois elétrons, com a troca de um fóton. O fóton é a partícula mediadora da interação eletromagnética.

De modo semelhantes são definidos os outros tipos de interação. Para a interação

Interação	Intensidade Relativa
Forte	1
Eletromagnética	10^{-2}
Fraca	10^{-5}
Gravitacional	10^{-39}

Tabela 2.1: Intensidade relativa (em comparação com a interação forte) dos diversos tipos de interação.

forte, as partículas mediadoras são os glúons. Os bósons W e Z mediam a interação fraca e o gráviton a interação gravitacional. A teoria da cromodinâmica quântica (QCD - *Quantum Chromodynamics*) [14], por exemplo, descreve como os quarks e glúons interagem para formar os hádrons (prótons e neutrons são exemplos de hádrons). Uma diferença entre a QED e a QCD é que na última, os quarks e glúons não são observados como partículas livres (mas apenas na forma de hádrons), em oposição aos elétrons e fótons da QED. Mesmo em colisões de alta energia, quando quarks são produzidos, eles se afastam rapidamente uns dos outros, e antes que possam ser observados, se convertem em “jatos” de hádrons (ou jets hadrônicos) [11].

Considerando uma teoria atualmente aceita pela física teórica (conhecida como *Gauge Invariance*) e as partículas e formas de interação já verificadas experimentalmente, todas as partículas elementares teriam massa nula. Esta previsão é contrária aos resultados experimentais e somente pode ser corrigida assumindo-se que existe um outro tipo de interação. Esta interação foi prevista pelo cientista inglês Peter Higgs em 1964, tendo como partícula mediadora o bóson de Higgs, que é responsável por fornecer massa às partículas [11]. A existência do bóson de Higgs é a mais importante previsão do modelo padrão ainda não verificada experimentalmente e sua busca é de máxima importância para a física de partículas.

Nas últimas décadas, os experimentos com aceleradores de partículas se tornaram gigantescos empreendimentos envolvendo milhares de físicos e engenheiros com contribuição financeira e intelectual de dezenas de países. Os aceleradores usam força eletromagnética para aumentar a energia de partículas estáveis e carregadas eletricamente. As partículas são injetadas na máquina por dispositivos que produzem uma fonte de partículas de alta intensidade e baixa energia. Quanto às características construtivas, os aceleradores podem ser divididos em alvo-fixo ou colisionadores de feixes. Nos aceleradores de alvo-fixo, as partículas são aceleradas até a máxima energia, quando o feixe é retirado da máquina e direcionado a um alvo estacionário. Nos colisionadores, feixes de partículas são acelerados e quando a energia desejada é atingida, os feixes são colocados em rota de colisão em alguns pontos específicos do percurso. Quanto ao percurso dos feixes, os aceleradores podem ser lineares ou circulares [11].

Imediatamente após a colisão, uma grande quantidade de partículas elementares

é produzida. Algumas delas são estáveis, porém outras têm curtíssimo tempo de vida. Os elétrons e prótons, por exemplo, têm vida média superior a 10^{23} anos, enquanto os múons podem ter vida média da ordem de 10^{-6} segundos [12]. Para que todos os eventos sejam corretamente identificados, um complexo sistema de detecção precisa ser construído.

A massa (m) das partículas é usualmente expressa em função da energia equivalente ($m = E/c^2$, onde c é a velocidade da luz e E a energia). Os bósons W e Z, por exemplo, têm massa de 80 e 91 GeV/ c^2 (onde 1GeV/ c^2 = $1,78 \times 10^{-27}$ kg). Na Tabela 2.2, são mostradas as massas de algumas partículas importantes. Ainda não é possível determinar a massa esperada para o bóson de Higgs, porém, considerando o conhecimento adquirido com os experimentos operados antes do LHC, sua massa deve ser maior que 115 GeV/ c^2 [7].

O acelerador LHC (*Large Hadron Collider* - Grande Colisionador Hadrônico) [3, 15] em operação no CERN (Centro Europeu para Pesquisa Nuclear) [16], será capaz de atingir energia de até 14 TeV e permitir à visualização do bóson de Higgs, caso o Modelo Padrão esteja correto.

Partícula	Massa (GeV/ c^2)
Elétron	0,000511
Próton	0,938
Bóson W	80
Bóson Z	91
Bóson de Higgs ou outras novas partículas	>115

Tabela 2.2: Exemplos de valores da massa (em energia equivalente) de algumas partículas.

Além da busca pelo bóson de Higgs, existem outras questões que precisam ser respondidas em física de partículas. É um desejo antigo dos físicos, desde Einstein, a unificação das teorias sobre as forças entre as partículas, incluindo no Modelo Padrão a força gravitacional. O estudo da física de partículas também é fundamental para o entendimento da natureza e origem do universo. Pretende-se, por exemplo, descobrir informações sobre a composição da matéria escura [17], super-simetria [18] e violação de CP (do inglês *Charge Parity*) [19].

Entre os laboratórios que conduzem experimentos em física de partículas os principais são: CERN, DESY [20], KEK [21], Fermilab [22], SLAC [23] e Brookhaven [24], localizados respectivamente na Suíça, Alemanha, Japão e os três últimos nos Estados Unidos.

O CERN, fundado em 1954, é atualmente um dos maiores centros de pesquisas em física de partículas do mundo. Localizado em Genebra, Suíça, funciona com base num complexo sistema de colaboração internacional, que envolve centenas de instituições de pesquisa em centenas de países [16].

2.2 O acelerador LHC

No CERN, foi projetado e construído o experimento LHC (*Large Hadron Collider*), que iniciou sua operação no final de 2008 [3, 25]. O LHC pode atingir níveis de energia de, aproximadamente, 14 TeV. O percurso do acelerador, localizado na fronteira franco-suíça, é aproximadamente circular, com 27 Km de comprimento, numa profundidade do solo que varia de 50 a 150 metros (ver Figura 2.2). Feixes de prótons serão acelerados em sentidos opostos e direcionados para colisão nos centros dos detectores.

O LHC tem 6 detectores com propósitos diferentes: ATLAS [1], CMS [26], LHCb [27], LHCf [28], ALICE [29] e TOTEM [30]. O ATLAS e o LHCf estão localizados em Meyrin, Suíça, o CMS e o TOTEM em Cessy, França, o ALICE em St. Genis-Pouilly, França e o LHCb em Ferney-Voltaire, França (os experimentos TOTEM e LHCf não são mostrados na Figura 2.2 pois estão em locais próximos respectivamente ao CMS e ATLAS). O ATLAS (*A Toroidal LHC ApparatuS*) e o CMS (*Compact Muon Solenoid*) são detectores de propósito geral, enquanto os outros são dedicados a aplicações específicas, como o LHCb, que é dedicado a explorar informações sobre a física proveniente dos hádrons do tipo **b** produzida nas colisões do LHC.

Quando operando em máxima capacidade, o LHC irá produzir colisões de feixes de prótons a cada 25 ns e atingirá energia 7 vezes maior que o Tevatron, que é o acelerador de maior energia em operação atualmente, funcionando no Fermilab.

O número de colisões por centímetro quadrado produzidas por segundo é

chamado de luminosidade (L) [11]:

$$L = n \frac{N_1 N_2}{A} f \quad (2.1)$$

onde n é o número de feixes, N_1 e N_2 o número de partículas em cada feixe, A a área da seção transversal do feixe e f a frequência de colisão. Quanto maior a luminosidade do experimento, maior a quantidade de informação (partículas) gerada.

Quando operando numa luminosidade jamais alcançada ($10^{34} \text{cm}^{-2} \text{s}^{-1}$), o LHC deve atingir uma taxa de interações da ordem de 1 GHz. No LHC, fatores como a alta taxa de interações, as altas doses de radiação, a multiplicidade de partículas e largas faixas de energia a cobrir, em conjunto com a necessidade de medições precisas, definiram novos padrões para o projeto dos detectores.

A seguir, serão descritas, de modo geral, as principais características do detector ATLAS.

2.3 Características gerais do detector ATLAS

Os métodos de detecção em física têm como princípio básico promover interação entre as partículas em estudo e um material conhecido, produzindo informações




Figura 2.2: Mapa de localização dos detectores do LHC.

sobre a natureza e as características da própria partícula. Os instrumentos que possibilitam a medição experimental destas quantidades físicas são chamados de detectores. Em particular, os detectores de energia são chamados de calorímetros. À medida que a energia envolvida aumenta, o sistema de detecção precisa ser mais sofisticado [12].

O ATLAS foi fruto do trabalho de uma grande colaboração, que envolveu milhares de físicos, engenheiros, técnicos e estudantes por um período de vinte anos de projeto, desenvolvimento, fabricação e instalação.

O detector ATLAS tem 45 m de comprimento, 25 m de altura e pesa aproximadamente 7.000 toneladas, sendo dividido em subsistemas dispostos em camadas. Conforme ilustrado na Figura 2.3, os principais subsistemas são: detector de trajetórias (ou de traço), calorímetros eletromagnético e hadrônico e os detectores de múons.




Figura 2.3: Diagrama esquemático do ATLAS.

A função dos detectores de trajetória é medir o momento das partículas eletricamente carregadas, a partir da curvatura de sua trajetória, quando imersos no campo magnético do solenóide central [31]. Caminhando do eixo central para as extremidades, em sequência, estão os calorímetros, que medem a energia depositada pelas partículas [32]. Na interação com as células do calorímetro, são produzidos chuveiros de partículas secundárias [33]. Num último estágio está o detector de múons, sistema dedicado à detecção destas partículas, que são as únicas que não ficam contidas nos calorímetros [34].

O sistema xyz de coordenadas do ATLAS é único para todos os subsistemas. Conforme mostrado na Figura 2.4, a direção do feixe do LHC define o eixo z , e os eixos x e y formam um plano transversal ao feixe. A direção positiva do eixo x é definida apontando do ponto de interação para o centro do anel do LHC, e o eixo y positivo aponta para cima. O ângulo azimutal é obtido a partir de:

$$\phi = \arctg(x/y), \quad (2.2)$$

sendo que $\phi = 0$ corresponde ao eixo x positivo e ϕ aumenta no sentido horário. O ângulo polar θ é medido a partir do eixo do feixe (eixo z positivo). O momento transversal p_T , a energia transversal E_T e a energia transversal perdida E_T^{miss} são definidas no plano xy . A pseudo-rapidez η é calculada a partir do ângulo θ de espalhamento em relação ao eixo z (ângulo de saída das partículas após a colisão) [8]:




Figura 2.4: Eixo de coordenadas do ATLAS.


$$\eta = -\ln \operatorname{tg}(\theta/2). \quad (2.3)$$

A partir das definições das equações 2.2 e 2.3, define-se o eixo (η, ϕ) , onde o ângulo ϕ representa a rotação e η a direção de projeção das partículas após a colisão. Grandes valores da pseudo-rapidez indicam que a colisão das partículas não foi frontal, pois o ângulo de saída, após o choque, é pequeno, no limite quando $\theta \rightarrow 0$ então $\eta \rightarrow \infty$. Nesse tipo de colisão, como quase não houve choque, a produção de partículas elementares é pequena. O ATLAS foi projetado com baixa resolução para $\eta > 3$.


Após uma colisão, as partículas geradas interagem com o material do detector, perdendo energia e consequentemente velocidade. Na Figura 2.5(a) pode-se visualizar os subsistemas do ATLAS num corte transversal (paralelo ao plano xy). Percebe-se que a câmara de múons e o calorímetro hadrônico têm as maiores dimensões. Na figura 2.5(b) é mostrada a penetração e consequente visualização esperadas de algumas partículas nas camadas do detector. Não espera-se, por exemplo, deposição de energia de fótons ou elétrons além das camadas eletromagnéticas do calorímetro, pois estas partículas interagem intensamente com os materiais que compõem a seção eletromagnética, perdendo toda sua energia. As partículas hadrônicas podem interagir com menos intensidade com o calorímetro eletromagnético e precisam das camadas hadrônicas para serem paradas. Os múons, em geral, são partículas que perdem pouca energia nos calorímetros, necessitando de um sistema especial para serem detectados, o detector de múons.

O ATLAS foi projetado e construído considerando-se as condições experimentais produzidas pelas colisões do LHC e com o objetivo de obter informações importantes para responder às questões chave em física de partículas. Entre os principais critérios utilizados para o projeto do detector pode-se destacar [1]:

- Os elementos sensores e circuitos eletrônicos devem apresentar resposta rápida e resistência a altos níveis de radiação. A fina granularidade do detector é importante para reduzir a influência dos eventos sobrepostos.
- Excelente calorimetria eletromagnética para a identificação de elétrons e fótons, complementada por informações acuradas dos calorímetros hadrônicos,



(a)



(b)

Figura 2.5: Cortes (a) transversal e (b) axial do ATLAS.

para medições de jatos hadrônicos e energia transversa E_T (se o valor para E_T for diferente do esperado isso pode indicar a ocorrência de um fenômeno não observado pelo detector);

- Eficiente sistema de identificação de trajetória para medição do momento;
- Alta precisão na identificação de múons;
- Alta aceitação em pseudo-rapidez (η) com cobertura quase total no ângulo azimutal (ϕ);
- Alta eficiência do sistema de filtragem (*trigger*), armazenando a maioria dos eventos físicos de interesse e reduzindo ao máximo o ruído de fundo (informação não relevante) produzido nas colisões do LHC.

Conforme mencionado no Capítulo 1, o estudo conduzido neste trabalho utiliza informações do sistema de calorímetros do ATLAS e propõe algoritmos para a otimização da detecção (trigger) de elétrons. Nas próximas sub-seções, serão descritos o sistema de calorímetros do ATLAS e a importância da detecção de elétrons para o desempenho do experimento.

2.3.1 O sistema de calorimetria do ATLAS

Calorímetros [33] representam uma importante classe de detectores para medição de energia e posição da partícula. Durante o processo de absorção, as partículas interagem com o material dos calorímetros gerando partículas secundárias que, por sua vez, interagem também gerando outras partículas e assim por diante. Este processo é chamado de cascata ou chuva de partículas. Os calorímetros podem apresentar resposta muito rápida, da ordem de nanossegundos [33], e, por isso, é utilizado intensamente pelo sistema de filtragem online (*trigger*). As prováveis classes de partículas são identificadas a partir das características esperadas para o seu perfil de deposição de energia.

Calorímetros são detectores de absorção total. O processo de medição utilizado é destrutivo e as partículas não estão disponíveis após a passagem pelos calorímetros (com exceção aos múons, que conseguem penetrar em grande quantidade de matéria

e necessitam de um detector especial a câmara de múons). Quando partículas atravessam matéria, elas em geral interagem e perdem assim uma parte de sua energia. Neste processo o meio é excitado ou aquecido (daí o termo calorimetria). Na prática absorção “total” significa 99 a 99,9 % da energia (ou até um pouco menos). A depender do tipo de partícula e da energia envolvida, a partícula pode exceder os limites do calorímetro (vazar) e acabam por interferir em outros detectores (ex. câmara de múons) [33].

Os calorímetros podem ser classificados em homogêneos ou amostradores. No calorímetro homogêneo todo o volume do detector é sensível às partículas e contribuem para produção do sinal, no calorímetro amostrador o material passivo absorve (interage) as partículas e o material ativo produz o sinal [33].

Partículas como elétrons e pósitrons interagem com a matéria gerando um chuveiro de partículas menos energéticas e necessitam de pequena quantidade de material para serem totalmente absorvidas. Os múons, por outro lado, perdem sua energia muito lentamente necessitando de grande quantidade de matéria para a absorção total. As partículas hadrônicas interagem com a matéria através da força nuclear forte. O processo de interação é muito mais complexo que o EM e uma variedade muito grande de fenômenos pode ocorrer. Os hadrons podem, por exemplo, se comportar de modo semelhante a elétrons e múons, ou se envolverem em uma interação nuclear e se transformarem em 15 novos hádrons. Uma parte da energia das interações hadrônicas não é visível (detectável) pelos calorímetros pois os hadrons neutros não ionizam o calorímetro e a energia é perdida em interações nucleares (fundamentalmente não detectadas pelo calorímetro) [33].

Os calorímetros deveriam ser intrinsecamente lineares para a detecção de partículas EM. Por exemplo um par de elétrons de 10 GeV deveria gerar um sinal de mesma intensidade que um único elétron de 20 GeV. Na prática, desvios do comportamento linear (para partículas EM) podem ser observados na prática devido a fenômenos como [33]:

- Vazamento do chuveiro: com o aumento da energia algumas partículas podem extrapolar os limites do detector;
- Recombinação dos elétrons com íons do material ativo (se isso ocorrem a ionização não é detectada);

- Atenuação da luz: a luz emitida pelo material ativo (cintilante) pode ser atenuada antes de atingir as PMT.

Calorímetros homogêneos são intrinsecamente não-lineares para a detecção de hadrons e jatos. A fração EM de chuviros hadrônicos depende da energia e varia bastante de evento para evento, tornando a resposta hadrônica não-constante em função da energia (tanto para calorímetros homogêneos como para os amostradores). A fração não EM (que produz interações nucleares) é, em geral, menor. Em qualquer calorímetro a resolução em energia para hádrons é pior que para elétrons de mesma energia. Isso se deve ao fato de ocorrerem flutuações na energia visível (detectável) aos calorímetros [33].

Como as características dos chuviros eletromagnéticos e hadrônicos são diferentes, na prática, são utilizados tipos de calorímetro específicos para estas classes de partículas [11]. O calorímetro eletromagnético é usualmente instalado internamente ao hadrônico. As partículas eletromagnéticas (ex: elétrons e fótons) apresentam perfil de deposição de energia que, em geral, é concentrado em torno do ponto de colisão. Tipicamente, as partículas eletromagnéticas são absorvidas completamente nos calorímetros eletromagnéticos. Os chuviros hadrônicos apresentam formas variadas e iniciam sua interação com o calorímetro eletromagnético, mas, em geral, somente são completamente absorvidas nas camadas hadrônicas (mais externas).

O sistema de calorímetros do detector ATLAS [1] é sub-dividido em 7 camadas [32], sendo 4 eletromagnéticas (PS, E1, E2, E3) e 3 hadrônicas (H0, H1 e H2), conforme Figura 2.6. Cada camada apresenta diferente concentração de células detectoras por unidade de área (granularidade). O calorímetro eletromagnético (EM) é composto de finas folhas de chumbo separadas por dispositivos sensores de argônio líquido, cobrindo a região onde $|\eta| < 3,2$. As três camadas do calorímetro eletromagnético são divididas em barril (região central do detector, onde $|\eta| < 1,5$) e tampa (regiões mais externas onde $1,4 < |\eta| < 3,2$). Na região onde $|\eta| < 1,8$, imediatamente antes da primeira camada EM existe uma fina camada de argônio líquido chamada pré-amostrador (*presampler* ou PS). O pré-amostrador é importante para corrigir medições nas quais existe perda de energia no caminho até os calorímetros.

Um problema específico do ATLAS é o substancial volume de material in-

erte(morto) instalado entre o ponto de colisão e os calorímetros. O pré-amostrador tem função primária amenizar os problemas causados pela perda de energia neste material (em 119 GeV 5% da energia de elétrons é perdida neste material). Os sinais medidos no PS são ponderados por um fator adequado α e somados aos sinais medidos nas outras camadas para compor a energia total do evento [33]:

$$E_{tot} = E_{calo} + \alpha E_{ps}. \quad (2.4)$$

O calorímetro hadrônico envolve o eletromagnético. Na região onde $|\eta| < 1,7$, ele é composto de placas absorvedoras de aço separadas por telhas de material plástico cintilante. Quando as partículas atravessam as telhas elas emitem luz de intensidade proporcional à energia incidente [35]. O sinal luminoso é então convertido em elétrico através de placas foto-multiplicadoras. Esta parte do calorímetro hadrônico do ATLAS é conhecida como calorímetro de telhas (*Tile Calorimeter* ou simplesmente *TileCal*) e é dividida em barril ($|\eta| < 1,0$) e barril-estendido ($0,8 < |\eta| < 1,7$) [36]. Para a tampa do calorímetro hadrônico ($|\eta| > 1,5$) utiliza-se a tecnologia do argônio líquido.

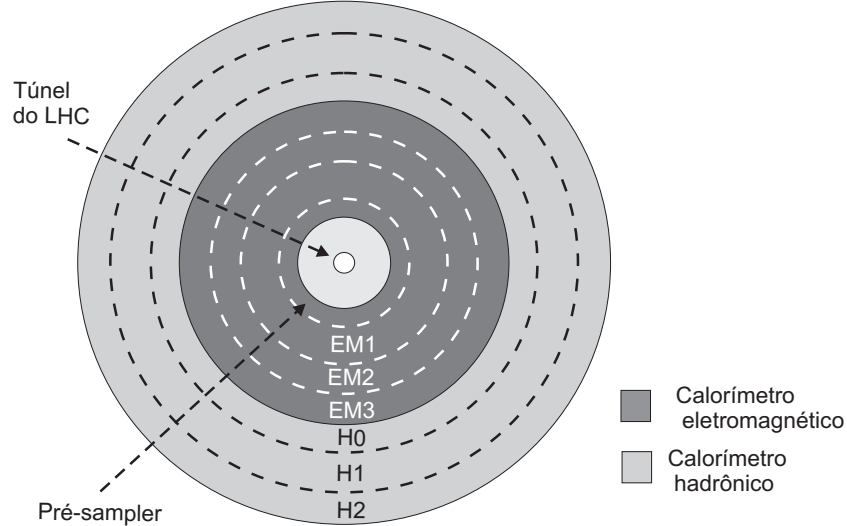


Figura 2.6: Disposição em camadas dos calorímetros do ATLAS.

A informação da energia depositada nas camadas do calorímetro, com fina segmentação, é muito importante para a caracterização física das partículas. Após um evento ser aceito pelo sistema de filtragem, todas as informações relativas a este evento são armazenadas em mídia permanente para posterior análise *off-line*. A granularidade, ou quantidade de células por unidade de área, varia entre as ca-

Pre-amostrador	Barril	Tampa
Cobertura	$ \eta < 1,52$	$1,5 < \eta < 1,8$
Granularidade ($\Delta\eta \times \Delta\phi$)	$0,025 \times 0,1$	$0,025 \times 0,1$
Canais de Leitura	7808	1536 (ambos os lados)
Eletromagnético	Barril	Tampa
Cobertura	$ \eta < 1,475$	$1,375 < \eta < 3,2$
Granularidade ($\Delta\eta \times \Delta\phi$)		
Camada 1	$0,025/8 \times 0,1$	$0,025/8 \times 0,1$ a $0,1 \times 0,1$
Camada 2	$0,025 \times 0,025$	$0,025 \times 0,025$ a $0,1 \times 0,1$
Camada 3	$0,050 \times 0,025$	$0,05 \times 0,025$
Canais de Leitura	101760	62208 (ambos os lados)
Had. Telhas Cintilantes	Barril	Barril estendido
Cobertura	$ \eta < 1,0$	$0,8 < \eta < 1,7$
Granularidade ($\Delta\eta \times \Delta\phi$)		
Camadas 1, e 2	$0,1 \times 0,1$	$0,1 \times 0,1$
Camada 3	$0,2 \times 0,1$	$0,2 \times 0,1$
Canais de Leitura	5760	4092 (ambos os lados)
Had. Argônio Líquido	Tampa	
Cobertura	$1,5 < \eta < 3,2$	
Granularidade ($\Delta\eta \times \Delta\phi$)		
Camadas 1, 2 e 3	$0,1 \times 0,1$ a $0,2 \times 0,2$	
Canais de Leitura	5632 (ambos os lados)	

Tabela 2.3: Região de cobertura em η , granularidade e número de canais de leitura das camadas dos calorímetros.

madas do calorímetro. A Tabela 2.3 traz informações sobre a região de cobertura em η , granularidade e quantidade de canais de leitura (células sensoras) de cada camada do calorímetro.

Conforme ilustrado na Figura 2.7, percebe-se que a primeira camada eletromagnética apresenta mais fina segmentação, possibilitando medição precisa do ponto de colisão. A segunda camada apresenta células detectoras quadradas e maior profundidade, absorvendo maior parcela da energia. A terceira camada, por sua vez,

captura os detalhes do final do chuveiro eletromagnético.




Figura 2.7: Granularidade e profundidade das camadas do calorímetro eletromagnético, extraído de [1].

Calorímetros são construídos utilizando estruturas modulares. Os cabos de transmissão de sinais e alimentação passam por espaços existentes entre os módulos (*cracks*). No ATLAS, na região de $|\eta| \sim 1,5$ (interconexão entre barril e barril-extendido) existe uma descontinuidade nos calorímetros (eletromagnético e hadrônico) para passagem de cabos de alimentação e dados do detector de trajetória e do barril do calorímetro eletromagnético [1]. Nesta faixa, há menor quantidade de células detectoras e, conseqüentemente, baixa resolução nas medições obtidas (o que pode representar um problema para o sistema de filtragem, como será descrito na Seção 3.2).

Diferente de outros tipos de detectores, a precisão dos calorímetros aumenta com a energia [33]:

$$\frac{\sigma_E}{E} \propto \frac{1}{\sqrt{E}} \quad (2.5)$$

onde E é a energia incidente por partícula. Outras fontes de flutuações de menor importância contribuem com fatores de outra ordem como ruído eletrônico: $\propto 1/E$ (domina em baixa energia, principalmente para LAr); e vazamento lateral do chuveiro: $\propto 1/(E)^{1/4}$. Uma característica interessante é que as flutuações podem não ser simétricas em torno do valor médio.

Para o calorímetro do ATLAS, foi calculada experimentalmente em [32] a resolução esperada. Os valores encontrados foram $0, 1/\sqrt{E}$ e $0, 4/\sqrt{E}$, respectivamente para os calorímetros eletromagnético (de argônio líquido) e hadrônico (de telhas cintilantes).

2.3.2 Principais objetos de interesse no ATLAS

Dentre os eventos gerados nas colisões do LHC, apenas uma pequena parte será útil para a caracterização dos processos da “nova física”. Com o LHC operando em alta luminosidade podem ocorrer até 10^9 interações por segundo, porém, os eventos de interesse são muito raros.

Provar a existência do bóson de Higgs é um dos principais objetivos do LHC. Com o conhecimento adquirido até agora, não é possível determinar sua massa m_H , embora seu limite inferior ($m_H > 114 \text{ GeV}/c^2$) tenha sido determinado pelos resultados obtidos em outros aceleradores, como o LEP (*Large Electron Positron Collider*, acelerador que operou no CERN de 1989 a 2000) [37]. O limite superior esperado por estudos teóricos é $\sim 1 \text{ TeV}/c^2$ [38].

Considerando os diversos decaimentos possíveis para a partícula de Higgs, espera-se que o canal mais limpo para seu estudo aconteça se sua massa estiver aproximadamente na faixa $150 < m_H < 700 \text{ GeV}/c^2$ [1]. Neste caso, o Higgs pode apresentar o decaimento em 2 bósons Z , com cada Z , por sua vez, decaindo¹ em dois léptons (elétrons ou múons):

$$H \rightarrow ZZ^{(*)} \rightarrow l^+l^-l^+l^- \quad (2.6)$$

Para este canal de busca do Higgs, é fundamental que os detectores tenham um sistema de filtragem capaz de identificar com alta eficiência elétrons e múons. Estas duas partículas, assim como os fótons, jatos e os taus, são importantes também

¹No decaimento de partículas elementares, parte da massa da partícula é convertida em energia e o restante em massa de outras partículas

para o melhor entendimento da supersimetria (SUSY - *supersimetry*) [7]. Os taus também podem levar aos modelos de Higgs estendidos [39]. Um resumo com os principais objetos de interesse no ATLAS e suas aplicações na física é mostrado na Tabela 2.4.

Objeto	Física de interesse
Elétron	Higgs, SUSY, dimensões-extra, novos bósons e <i>top quark</i>
Fóton	Higgs, SUSY e dimensões-extra
Múon	Higgs, SUSY, extra-dimensões, novos bósons e <i>top quark</i>
Jato	SUSY e ressonâncias
Jato + E_T^{miss}	SUSY e <i>leptoquarks</i>
Tau + E_T^{miss}	Modelo de Higgs estendido e SUSY

Tabela 2.4: Principais objetos de interesse no ATLAS, extraída de [2].

A identificação *online* destes objetos dentro de um universo enorme de informações é realizada pelo sistema de filtragem (*trigger*). Conforme mencionado, um dos objetos de interesse na filtragem do ATLAS é o elétron. Para a identificação de elétrons, a informação obtida no sistema de calorímetros é muito importante. Em termos da calorimetria, as assinaturas de elétrons podem ser confundidas com perfis de energia gerados por alguns jatos hadrônicos (especialmente concentrados nas camadas eletromagnéticas e com pouca energia nas hadrônicas). Considerando que a produção de jatos será muito frequente nas colisões do LHC, estes formarão um intenso ruído de fundo para a identificação de elétrons. Pelo que foi exposto, percebe-se que a discriminação elétron/jato (e^-/j) é importante para o desempenho do detector.

Capítulo 3

O Sistema de Filtragem do detector ATLAS

Neste capítulo serão apresentados uma breve introdução aos sistemas de filtragem (*trigger*) em experimentos de física de alta energia (HEP - *high-energy physics*) e em seguida serão descritas as características gerais do sistema de filtragem e aquisição de dados (TDAQ - *Trigger and Data Acquisition*) do detector ATLAS.

3.1 Introdução aos sistemas de filtragem em HEP

A maioria das reações físicas que são estudadas atualmente em experimentos de física de alta energia são raras, pois a maior parte da informação produzida representa processos já conhecidos (estudados anteriormente em outro experimentos) [40]. Por exemplo, o LHC produzirá uma taxa de eventos da ordem de 10^9 Hz para alta luminosidade ($L = 10^{34} \text{cm}^{-2}\text{s}^{-1}$). Dependendo de sua massa, a taxa de produção esperada para o bóson de Higgs varia entre 10^{-1} e 10^{-2} . Neste caso a frequência de interesse é de 10^{10} a 10^{11} vezes menor que a taxa de eventos produzidos, o que significa dizer que todo o restante da informação produzida representa ruído de fundo para a identificação da física de interesse.

Os sistemas de trigger, em geral, utilizam diferentes níveis hierárquicos de filtragem, onde os níveis mais baixo são responsáveis pela rejeição de eventos utilizando critérios mais simples e óbvios, enquanto que os níveis mais altos implementam análises mais complexas, pois dispõem de mais tempo para a tomada de decisão.

Como os níveis são hierárquicos (sequenciais), uma vez que o evento foi rejeitado em um dado nível ele não está mais disponível para análise nos níveis posteriores [40].

O primeiro nível de filtragem tem disponível um tempo muito curto para tomada de decisão (da ordem de μs), sendo, tipicamente, implementado através de hardware dedicado, utilizando, por exemplo, FPGAs (*field programmable gate arrays*). Se for necessário algum tipo de operação aritmética mais sofisticada no nível 1, pode-se utilizar também processadores digitais de sinais (DSPs *digital signal processors*) [41].

A filtragem de alto nível (HLT - *high-level trigger*) tipicamente utiliza computadores pessoais (PCs), pois dispõe de um maior tempo para produzir a decisão de aceitação ou rejeição e opera com uma menor taxa de eventos (uma vez que uma parcela do ruído de fundo já foi rejeitado pelo primeiro nível. As análises executadas no HLT envolvem operações complexas e podem até requerer a recomposição completa do evento [41]. A Figura ?? apresenta o diagrama de blocos de um sistema de genérico para filtragem *online* em experimentos de física de alta energia

A hierarquia e as características de seleção de cada nível variam de acordo com o experimento de HEP em questão [40]. Em modernos experimentos de física de alta energia os detectores são divididos em sub-sistemas responsáveis pela detecção de classes específicas de assinaturas. Por exemplo os calorímetros podem ser utilizados para a identificação de candidatos a elétrons, fótons e jatos, já os múons necessitam de um detector específico (o sistema de múons). O sistema de filtragem utiliza informações destes sub-detectores para identificar as assinaturas da física de interesse.

Considerando os detectores ATLAS e CMS (os dois detectores de propósito geral do LHC), diferentes soluções foram utilizadas para resolver o problema de filtragem e aquisição de dados. No ATLAS, o nível 1 transmite para o HLT um sub-conjunto da informação total do detector (conhecido como região de interesse - ROI, do inglês *region of interest*) que contém as características necessárias para a identificação da assinatura em questão [42]. O CMS utiliza um sistema de filtragem de primeiro nível que envia toda a informação do evento ao HLT [43].

A utilização das RoI exige inteligência para selecionar adequadamente toda a informação necessária, mas a grande vantagem é que a taxa de transmissão de

dados é reduzida, pois se um evento for rejeitado no HLT não há a necessidade de transmitir toda a informação referente ao mesmo. A solução utilizada no CMS exige maior largura de banda para transmissão de dados, porém não há a necessidade de inteligência para efetuar a seleção da RoI. No CMS o problema da largura de banda foi solucionado a partir da utilização de redes de transmissão de dados operando em paralelo e relativamente independentes.

3.2 O sistema de filtragem do ATLAS

Quando operando em alta luminosidade ($10^{34} \text{cm}^{-2} \text{s}^{-1}$), o LHC deve atingir uma taxa de interações de 1 GHz. Entretanto, a frequência de ocorrência de eventos de interesse para a física pode ser muito pequena. Espera-se que, por exemplo, se o bóson de Higgs existir, conforme previstos no Modelo Padrão, eles ocorram com frequência inferior a 0,001 Hz [44]. As estratégias de aceitação de eventos devem garantir que as informações de interesse não sejam perdidas, reduzindo ao máximo a quantidade de eventos não relevantes gravados em mídia permanente.

Considerando que, a cada evento (colisão) no ATLAS, são gerados aproximadamente 1,5 MByte de informação, e que o LHC produz uma colisão a cada 25ns, ou seja, uma taxa de 40×10^6 eventos por segundo, chega-se então a, aproximadamente, 60 TBytes de informação por segundo. Com a tecnologia disponível atualmente não é viável armazenar essa quantidade de informação. Mesmo que fosse possível acumular as leituras de todos os eventos, o processo de filtragem *offline* sobre toda essa massa de dados seria inviável. Assim, é necessário um sistema eficiente de filtragem *online*.

O sistema de filtragem do ATLAS (usualmente chamado de sistema de *trigger*) acessa informação dos três principais sub-detecores, o detector de trajetórias, os calorímetros e a câmara de múons. O *trigger* online opera em 3 níveis sequenciais de seleção de eventos: o nível 1 (L1), o nível 2 (L2) e o filtro de eventos (EF - *event filter*), sendo que os dois últimos compõem a filtragem de alto nível (HLT - *High Level Trigger*) [2]. Cada nível é responsável pela rejeição de uma parcela das assinaturas não relevantes, refinando a decisão do nível anterior. A Figura 3.1 ilustra as principais características dos três níveis de filtragem de eventos no ATLAS.

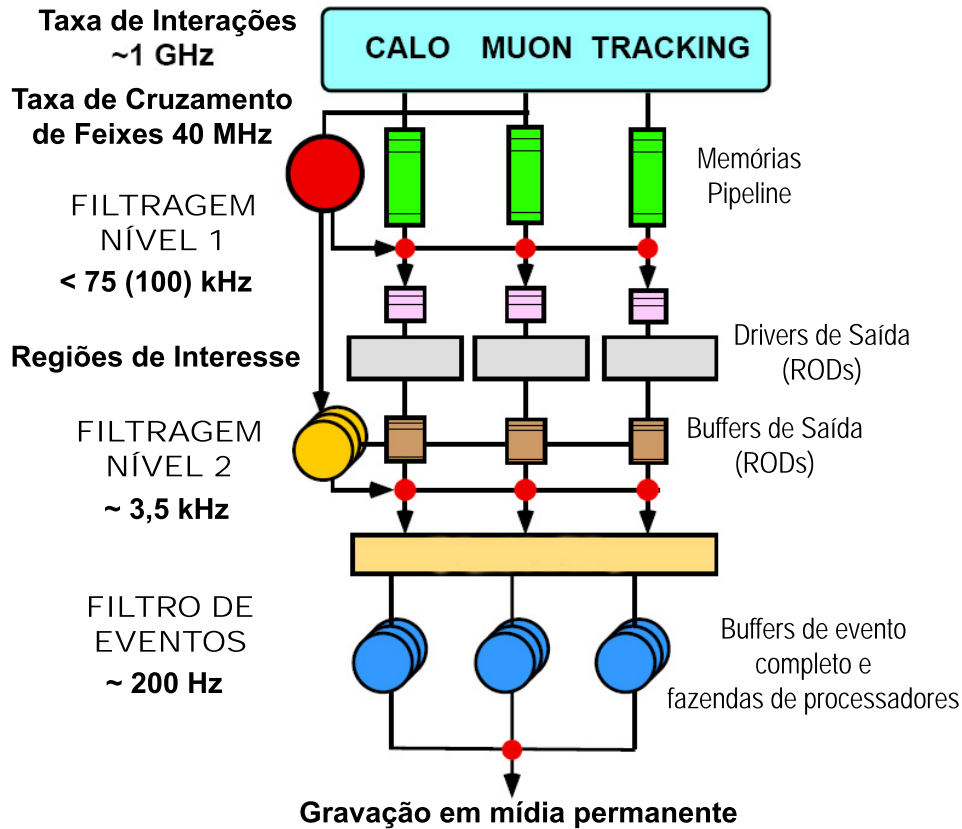


Figura 3.1: Diagrama em blocos do sistema de filtragem e aquisição de dados do ATLAS.

O primeiro nível tem sérias restrições quanto ao tempo de processamento (latência máxima de $2,5\mu s$), recebendo a plena taxa de eventos do LHC como entrada. Esse nível é implementado em *hardware* dedicado, usando apenas parte da resolução disponível ao detector. O L1 entrega ao segundo nível a localização das áreas onde possivelmente aconteceram eventos de interesse, regiões estas conhecidas como RoI (*Regions of Interest*). A seleção de eventos no L2 é feita através de *software* especializado, rodando em um conjunto de 1500 PCs dedicados operando em ambiente de processamento distribuído. Neste nível, o tempo médio para tomada de decisão é 40 ms e informações do detector de trajetórias e das câmaras de múons, assim como a total resolução dos calorímetros, estão disponíveis. O filtro de eventos é o último estágio do sistema de filtragem, recebendo uma taxa de eventos mais baixa, tendo assim latência de alguns segundos para tomada de decisão. A estratégia de processamento sequencial permite que os eventos sejam rejeitados na primeira etapa, minimizando a necessidade de acesso a informações, e facilitando o ajuste e even-

tual modificação das estratégias de extração de características. Na Tabela 3.1 é apresentado um resumo das principais características dos 3 níveis de filtragem do ATLAS.

Nível	Te (Hz)	Ts (Hz)	Cr	Latência (s)	Implementação
L1	40×10^6	$75 \times (100)10^3$	533 (400)	$2,5 \times 10^{-6}$	<i>Hardware</i>
L2	$75(100) \times 10^3$	$3,5 \times 10^3$	21 (29)	40×10^{-3}	<i>Software</i>
EF	$3,5 \times 10^3$	≈ 200	17	≈ 4	<i>Software</i>

Tabela 3.1: Principais características do sistema de *trigger* do ATLAS, onde Te e Ts são, respectivamente, as taxas de eventos na entrada e na saída e $Cr = Te/Ts$ é o coeficiente de redução de eventos.

Um problema que afetará os algoritmos de extração de características é o efeito de empilhamento (do inglês *pile-up*), que ocorre quando há uma sobreposição de eventos em regiões do detector [33], ou seja, um evento que ainda se desenvolve tem seu padrão de deposição de energia distorcido por um novo evento que chega e se sobrepõe, gerando um ruído de fundo que pode atingir grande intensidade.

Para o projeto e teste dos métodos de extração de características, foram usados conhecimentos prévios adquiridos em outras experiências com aceleradores de partículas e eventos simulados através de técnicas de Monte Carlo [45]. As simulações utilizam modelos estocásticos que descrevem as interações, levando em conta as características físicas do acelerador e do detector, assim como os efeitos de cada nível de filtragem. Para o ATLAS, foram utilizados geradores de eventos para colisões próton-próton como HERWIG, ISAJET, GEANT e PYTHIA, descritos em [35] e [46]. Os algoritmos de classificação e extração de características foram projetados para os dados simulados e serão posteriormente adaptados para a realidade de operação quando do início da aquisição de dados.

3.2.1 Primeiro nível de filtragem

Conforme mostrado na Figura 3.1 e na Tabela 3.1, o primeiro nível de filtragem é responsável por reduzir a taxa de eventos de aproximadamente 40 MHz para 75 kHz (a taxa de saída do L1 pode ser aumentada até 100 kHz, a depender das condições de operação do detector). A decisão do primeiro nível deve ser tomada até $2,5\mu s$

após o cruzamento de feixes (colisão) ao qual o evento está associado.

O L1 identifica as assinaturas básicas de interesse e, para tornar mais rápida a tomada de decisão, a granularidade dos subsistemas do detector é menos fina [44]. Considerando o sistema de calorímetros, que possui mais de 100.000 células detectoras, o L1 utiliza apenas 7000 torres de soma analógicas (as torres são obtidas somando-se a energia de células dentro de regiões de $0,1 \times 0,1$ em $\Delta\eta \times \Delta\phi$) [47].

A tomada de decisão quanto à aceitação ou rejeição de eventos no nível 1 é feita pelo processador central de *trigger* (*central trigger processor* - CTP), que combina as informações disponíveis nos calorímetros, para a detecção de partículas eletromagnéticas e hadrônicas, e nos sub-detecores RPC (*Resistive Plate Chamber*) e TGC (*Thin Gap Chambers*) para a detecção de múons, conforme mostrado na Figura 3.2. O filtro dos calorímetros é dividido em três sub-sistemas. O pré-processador digitaliza os sinais medidos e envia as informações para os processadores de regiões (CP - *Cluster Processor*) e de soma de energia / jatos (JEP - *Jet/Energy Sum Processor*). O CP é responsável pela identificação dos candidatos a elétrons, fótons e τ -leptons e o JEP identifica candidatos a jatos e produz a soma global de energia do evento. Considerando o filtro de múons, cada um dos sub-detecores é responsável pela identificação dos candidatos a múons em uma região do detector, o RPC opera no barril e o TGC na tampa. Se a assinatura analisada satisfaz um critério de aceitação de algum dos sub-detecores (calorímetros, RPC ou TGC), então ela é aceita pelo L1 e enviada para uma análise mais criteriosa na filtragem de alto-nível.

Até a tomada de decisão de nível 1, toda a informação do evento é armazenada em memórias tipo *pipeline*. Quando um evento é aceito, as informações referentes a este são descarregadas para uso pelo nível 2 de filtragem. As informações dos eventos rejeitados são descartadas. O L1 também é responsável por fornecer

O primeiro nível fornece informações sobre a posição (no plano η, ϕ) onde os eventos aceitos ocorreram, sinalizando assim as regiões de interesse (RoI) para análise no L2. O nível 1 também fornece outras informações importantes, como o critério utilizado para aceitação do evento e a identificação da colisão (cruzamento de feixe) ao qual o evento está associado. O nível 2 tem acesso, se necessário, a toda a informação do evento com total precisão e granularidade.

Na Tabela 3.2 são mostradas as frequências dos principais canais de filtragem




Figura 3.2: Diagrama em blocos do primeiro nível de filtragem.

esperadas para o L1 quando o LHC estiver operando em alta luminosidade ($L=10^{34}\text{cm}^{-2}\text{s}^{-1}$). Pode-se perceber que a taxa total desta simulação é da ordem de 40 kHz, aproximadamente 2 vezes menor que a frequência de saída esperada para o nível 1 na operação do LHC. Isso se deve às incertezas inerentes aos eventos simulados [44].

3.2.2 Filtragem de alto nível

O sistema de filtragem de nível 2 (L2) e o filtro de eventos (EF) são responsáveis pela filtragem de alto nível (HLT - *high-level trigger*) do ATLAS. O nível 2 deve reduzir a taxa de eventos de 75 kHz (podendo chegar até 100 kHz) para 3,5 kHz, tendo um tempo de latência de aproximadamente 40 ms para tomar a decisão [46]. O EF precisa diminuir a taxa de eventos de 3,5 kHz para 200 Hz. Os eventos que forem aceitos pelos três níveis de filtragem serão armazenados em mídia permanente para futura análise *offline*. O tempo para a tomada de decisão no filtro de eventos é de alguns segundos. O HLT é implementado em *software* e opera em um conjunto de PCs em paralelo. Embora existam algoritmos desenvolvidos pela colaboração do

Canal	Frequência (kHz)
Um múon	4
Par de múons	1
Região eletromagnética	22
Par de regiões eletromagnéticas	5
Um jato	0,2
Três jatos	0,2
Quatro jatos	0,2
Jato e E_T^{miss}	0,5
Tau e E_T^{miss}	1
Múon e região eletromagnética	0,4
Outras condições	5
Total	≈ 40

Tabela 3.2: Frequência esperada para os principais canais de *trigger* no primeiro nível de filtragem do ATLAS ($L=10^{34}\text{cm}^{-2}s^{-1}$).

ATLAS para a filtragem de alto nível (nos diversos canais de interesse), pesquisas continuam sendo conduzidas com o objetivo de propor rotinas de filtragem alternativas que forneçam maior eficiência de discriminação da física de interesse e, ao mesmo tempo, maior rejeição do ruído de fundo.

Considerando os efeitos conjuntos do segundo nível e do filtro de eventos, a filtragem de alto nível deve reduzir em aproximadamente 500 vezes a taxa de eventos. As etapas de processamento do HLT são iniciadas pelo acesso às informações das RoI, fornecidas pelo L1. A extração de características é efetuada em cada sistema do detector, iniciando pela confirmação da RoI no sistema onde esta foi originada (câmara de múons ou calorímetro), seguida pela confirmação em outros sistemas, como a câmara de arrasto [35]. Os principais objetos de *trigger* identificados no HLT são candidatos a múons, elétrons, fótons, taus, jatos, E_T^{miss} e física dos hádrons b. As informações necessárias para a decisão do alto nível dependem do tipo de região de interesse fornecida pelo L1, cada uma tendo suas próprias características de processamento [46]. O desempenho geral é medido a partir da eficiência na discriminação da física de interesse e do ruído de fundo. As principais características

desejadas para os algoritmos de filtragem no L2 são listadas a seguir:

- alta eficiência ($> 95\%$) por RoI selecionada no L1;
- eficiência uniforme em η e eficiência uniforme ou crescente com E_T ;
- redução do ruído de fundo minimizando a taxa de eventos classificados de forma incorreta (falso alarme);
- robustez em relação à luminosidade, ruído de medição, imperfeições de alinhamento e calibração.

Um diagrama de blocos do sistema de filtragem de alto nível é mostrado na Figura 3.3. As informações dos sub-detectors (calorímetros, câmaras de arrasto e de múons) são utilizadas inicialmente pelo nível 1, enquanto isso, são armazenadas em memórias temporárias, para posterior uso pelo nível 2. O acesso aos dados dos sub-detectors pelo *trigger* de alto nível é feito através dos *Read Out Buffers* (ROB). As informações das RoI são armazenadas nos RoIB (*Region of Interest Buffers*). Mais informações sobre os componentes dos sistemas de filtragem podem ser encontradas em [44], [46], [35] e [39].

Conforme mencionado anteriormente, a filtragem de alto nível pode utilizar toda a granularidade e precisão dos subdetectors do ATLAS. Então, percebe-se que, os algoritmos do HLT operam num espaço de decisão multidimensional, com restrições no tempo de processamento e rígidos padrões de eficiência. Deve-se notar também que, as características do sistema de filtragem podem mudar com o melhor conhecimento do detector, após os testes e o início de operação. Percebe-se, então, que o sistema de *trigger* de alto nível demanda esforços no sentido de propor, testar e comparar diferentes estratégias de seleção.

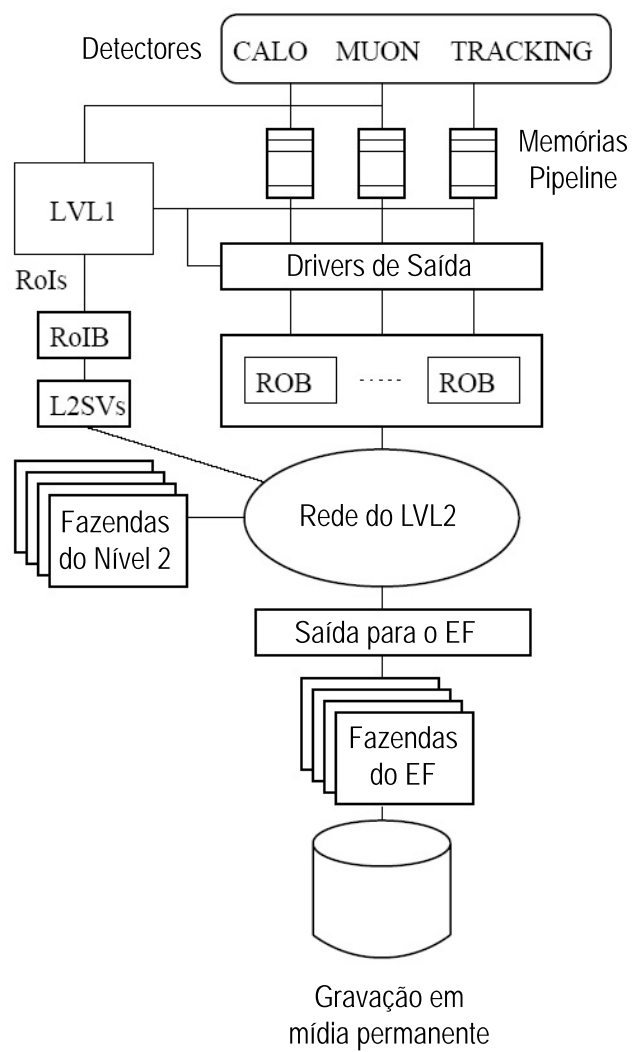


Figura 3.3: Diagrama em blocos do segundo nível de filtragem.

Capítulo 4

Filtragem de Elétrons partir de Informações de Calorimetria

Considerando informações do perfil de deposição de energia medido nos calorímetros, os elétrons podem ser confundidos com jatos hadrônicos. Os algoritmos utilizados tradicionalmente para filtragem de elétrons exploram diferenças espaciais (longitudinais e laterais) entre os chuveiros eletromagnéticos e hadrônicos.

Filtragem de elétrons no L1

A filtragem de elétrons no L1 é baseada em cortes lineares nos parâmetros do perfil de deposição de energia medido nos calorímetros. A definição dos critérios de seleção leva em conta o conhecimento das características típicas do perfil de deposição de energia de objetos eletromagnéticos (elétrons e fótons), que tipicamente apresentam:

- concentração ao redor do ponto de colisão;
- alta concentração de energia na seção eletromagnética;
- baixa concentração de energia na seção hadrônica.

Conforme dito anteriormente, no primeiro nível de filtragem as células dos calorímetros são somadas para formar sinais conhecidos como torres de *trigger* (TT). O tamanho das torres de *trigger* é diferente para as camadas eletromagnéticas e hadrônicas. No calorímetro eletromagnético, cada TT cobre uma área de $0,1 \times 0,1$ no plano $\eta \times \phi$, já no calorímetro hadrônicos cada TT representa uma região de $0,2$




Figura 4.1: Janela deslizante analisada pelo L1 no calorímetro eletromagnético.

$\times 0,2$ no plano $\eta \times \phi$. A partir da análise de uma janela deslizante, cobrindo uma região de 4×4 TT (16 no total), quatro critérios podem ser utilizados pelo L1 para definir um possível candidato a elétron:

1. Haver mais energia na região central de 2×2 TT, do que na periferia;
2. As energias das TTs da região central (de 2×2 TT) são somadas duas a duas e utiliza-se o maior valor encontrado, que deve exceder um patamar de energia eletromagnética;
3. O nível de energia na periferia (fora da região central de 2×2 TT) é calculado para verificar o isolamento em energia do objeto em questão;
4. A energia nas camadas hadrônicas é somada para verificar o vazamento de energia fora do calorímetro eletromagnético (isolamento hadrônico).

Os patamares de seleção do nível 1 podem ser ajustados e os critérios combinados, a depender das características da física de interesse que se deseja estudar num dado momento de operação do detector.

4.1 Filtragem de elétrons no L2 - Algoritmo T2Calo

O **T2Calo** [46] é o algoritmo padrão para extração de características e teste de hipóteses adotado no segundo nível de filtragem do ATLAS. Esse algoritmo utiliza

informações de calorimetria, sendo capaz de separar objetos eletromagnéticos isolados de jatos hadrônicos, utilizando parâmetros que estimam a forma dos chuveiros de deposição de energia [46].

O primeiro passo do T2Calo é refinar a posição da RoI fornecida pelo L1, encontrando a célula de maior energia na segunda camada do calorímetro eletromagnético. Essa posição (η_1, ϕ_1) será posteriormente refinada pelo cálculo da posição da média ponderada da energia em uma janela de 3×7 em (η, ϕ) . Para a seleção dos objetos eletromagnéticos são calculados os parâmetros:

- $R_\eta^{shape} = E_{37}/E_{77}$, onde E_{nm} é a energia depositada numa janela de $n \times m$ em torno de (η_1, ϕ_1) ;
- $R_\eta^{strip} = (E_{1st} - E_{2nd})/(E_{1st} + E_{2nd})$ é obtida em uma janela de $\Delta\eta \times \Delta\phi = 0,125 \times 0,2$, onde E_{1st} e E_{2nd} são o máximo e o segundo maior valor de energia encontrados depois de somar em ϕ para cada posição η ;
- A energia total E depositada no calorímetro eletromagnético é calculada em uma janela de 3×7 células em torno de (η_1, ϕ_1) ;
- A energia que passa para o calorímetro hadrônico E^{had} é calculada em uma janela de $\Delta\eta \times \Delta\phi = 0,2 \times 0,2$ em torno do novo centro da RoI calculado pelo T2Calo.

Considerando que o perfil de deposição de energia dos elétrons é, em geral, mais concentrado ao redor do ponto de máximo e que, também não espera-se deposição de uma quantidade significativa de energia nas camadas hadrônicas por elétrons, percebe-se que, o T2Calo opera através de cortes lineares utilizando informações da física de interesse.

Técnicas de extração de características e classificação que fazem uso do processamento estatístico de sinais e cortes não-lineares no espaço de busca foram propostas como uma alternativa ao T2Calo para a discriminação elétron/jato no L2. Exemplos podem ser encontrados em [48] e [49].

Como resultado destes trabalhos, foi implementado na plataforma de software do ATLAS o discriminador Neural-Ringer [48, 50], que utiliza um classificador neural supervisionado para o canal elétron-jato no L2. Para extração de características, os

sinais dos calorímetros são formatados em anéis concêntricos de deposição de energia (mais detalhes a respeito serão fornecidos no Capítulo 4). Este discriminador apresentou desempenho superior ao T2Calo, com tempo de processamento que, embora seja maior, atende aos requisitos do nível 2.

Num ambiente complexo como o que é gerado a cada colisão do LHC, onde o nível de ruído de fundo é extremamente alto e os eventos de interesse são raros, qualquer melhora na eficiência dos algoritmos de filtragem significa menor quantidade de eventos não relevantes armazenados mídia permanente, facilitando a análise *offline*.

O sucesso obtido com o Neural-Ringer motiva a busca por técnicas de pré-processamento que contribuam para a otimização do custo computacional, ou para o aumento da eficiência de discriminação. Neste contexto, o presente trabalho propõe o uso de técnicas de extração de características como Análise de Componentes Independentes e métodos correlatos para a compactação da informação e extração de características discriminantes. No próximo capítulo, as técnicas de aprendizado estatístico para extração de características e classificação utilizadas neste trabalho serão descritas e comentadas.

4.2 Descrição dos dados utilizados

Nesta seção serão descritas as principais características das bases de dados utilizadas. Os sinais simulados utilizados foram obtidos a partir de simuladores de Monte Carlo para colisões próton-próton [...]. As simulações consideram as características esperadas nas colisões do LHC e as especificações do ATLAS. Assim como na operação real do detector, é possível aplicar diferentes cortes (formas de seleção) de nível 1 nos dados simulados. Os cortes podem mudar de acordo com a "física" que se deseja obter. Os dados simulados são extremamente importantes para o projeto e teste dos discriminadores, uma vez que os simuladores fornecem a identidade (classe) da partícula, permitindo o treinamento supervisionado dos algoritmos de filtragem. Nos dados experimentais essa informação não está disponível. Nesse caso, outras estratégias precisam ser utilizadas para avaliar o desempenho dos algoritmos.

4.2.1 Sinais simulados - Corte E10 *loose*

Neste conjunto de sinais, a seleção de nível 1 realiza apenas um corte linear na energia total do evento, deixando passar somente eventos com energia da ordem de 10 GeV ou maior (os eventos de baixa energia são eliminados). Este corte é mais utilizado para teste do sistema de filtragem no período inicial de operação do detector, pois é pouco provável a identificação de assinaturas relevantes, uma vez que uma grande quantidade de eventos de falso-alarme é aprovada pelo nível 1.

... , gráficos eta, phi e energia

4.2.2 Sinais simulados - Corte E15i

Um corte de nível 1 mais sofisticado foi aplicado para a obtenção desse conjunto de sinais. A energia mínima agora é da ordem de 15 GeV e, adicionalmente, foram efetuados cortes considerando outras características do perfil de deposição de energia. Conforme descrito no Capítulo 2, os elétrons apresentam perfil de energia mais concentrado em torno do ponto de colisão e com pouca ou nenhuma energia medida nas camadas hadrônicas. Considerando essas características, são aplicados:

- corte de vazamento para as camadas hadrônicas - a energia nas camadas hadrônicas é calculada e se ela for maior que um valor limite o evento é rejeitado pelo L1;
- corte de isolamento em energia - efetuado a partir da relação entre a energia no centro ($\sum E_C$) e na periferia ($\sum E_P$) do perfil de deposição de energia da segunda camada eletromagnética, se $\frac{\sum E_P}{\sum E_C}$ for maior que um limiar pré-estabelecido o evento é rejeitado pelo L1.

Este corte de nível 1 se aproxima da característica esperada para a fase operação do detector.

... , gráficos eta, phi e energia

4.2.3 Raios Cósmicos

Os raios cósmicos são (descrever e justificar porque contaminam o detector) , gráficos eta, phi e energia

4.2.4 Sinais Reais de Colisões do LHC

Nestes sinais não existe a caracterização prévia do tipo de partícula (como havia no caso dos sinais simulados). Para a avaliação do desempenho dos discriminadores com estes dados foi utilizada a decisão do sistema *offline* de filtragem. A filtragem *offline* dispõe de um tempo muito maior para a tomada de decisão ... (mais info sobre o offline) ...

(, gráficos eta, phi e energia, qual o corte de nível 1 ??)

4.3 Neural Ringer - Alternativa para Filtragem de Elétrons no L2 do ATLAS

Os sinais do perfil de deposição de energia utilizados para discriminação elétron/jato são medidos nas sete camadas dos calorímetros do ATLAS. Considerando a granularidade de cada camada, uma Região de Interesse (RoI) típica (de tamanho $0,4 \times 0,4$ em $\eta \times \phi$) é descrita por aproximadamente 700 células. Um procedimento foi proposto em [50] para compactar os sinais dos calorímetros mantendo a interpretação física do perfil de deposição de energia. As células sensoras de cada camada são formatadas em anéis concêntricos de deposição de energia.




Figura 4.2: Diagrama do processo de construção dos anéis.

Considerando um conjunto de células de uma RoI em uma certa camada do calorímetro, conforme ilustrado na Figura 4.2, a célula mais energética de cada camada é considerada como o primeiro anel. Em seguida as células ao redor do primeiro anel definem o segundo anel e assim sucessivamente. A energia amostrada pelas células pertencentes a um dado anel são somadas produzindo o sinal de energia

em anéis. É interessante notar que, devido à diferença de granularidade entre as camadas do calorímetro, um número diferente de anéis é gerado para cada camada. A Tabela 4.1 mostra a distribuição dos anéis por camada. A Figura 4.3 mostra os sinais medidos na segunda camada eletromagnética do calorímetro respectivamente para um elétron e um jato.

Tabela 4.1: Número de anéis formados para cada camada do calorímetro do ATLAS.

Camada	PS	E1	E2	E3	H0	H1	H0	Total
Anéis	8	64	8	8	4	4	4	100

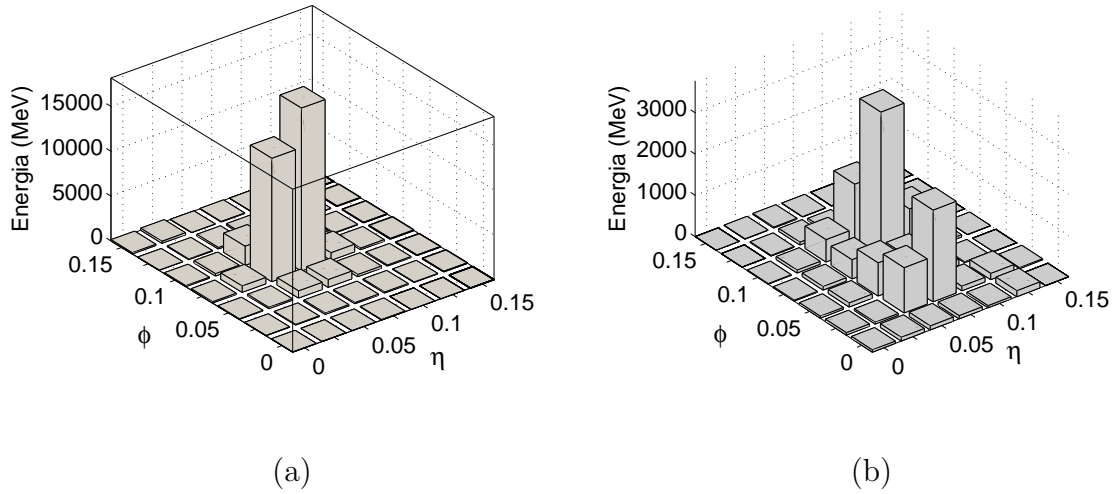




Figura 4.3: Sinais medidos na camada EM2 para (a) elétron e (b) jato.

A Figura 4.4 mostra sinais em anéis respectivamente para um elétron típico, um jato típico e um jato com perfil semelhante ao de elétrons. Percebe-se que o perfil de deposição medido para elétrons apresenta pouco espalhamento (é contido em uma pequena região) e é quase totalmente concentrado nas camadas eletromagnéticas. Os jatos tipicamente apresentam maior energia hadrônica e deposição em uma maior área do calorímetro. Alguns jatos (como o mostrado na Figura 4.4-c) podem apresentar perfil de deposição de energia semelhante ao de elétrons, representando um ruído de fundo de difícil identificação.


Antes da utilização nos sistemas de classificação (teste de hipótese) os sinais em anéis são normalizados dividindo-se a energia de cada anel pela energia total do



(a)



(b)



(c)

Figura 4.4: Sinais em anéis para (a) elétron típico, (b) jato típico e (c) jato com perfil semelhante ao de elétrons.

evento:

$$r_i = \frac{r_i}{\sum_{i=1}^{100} r_i} \quad (4.1)$$

A formatação em anéis produz uma compactação por um fator de 7 vezes (de 700 células para 100 anéis), mantendo a interpretação física do perfil de deposição de energia, tornando o sinal independente do ponto de colisão no detector e reduzindo a influência do ruído de cada célula.

Capítulo 5

Revisão da Literatura

Neste capítulo serão mostrados os fundamentos teóricos de algumas técnicas de aprendizado estatístico utilizadas para extração de características e classificação na filtragem de segundo nível do ATLAS. A partir da estatística de segunda ordem, a análise de componentes principais (PCA - *Principal Component Analysis*) é capaz de realizar uma transformação na qual os componentes na nova base são ortogonais e ordenadas por energia (variância). A análise de componentes independentes (ICA - *Independent Component Analysis*) utiliza estatística de ordem superior para encontrar direções onde os sinais projetados são independentes estatisticamente. A ICA transforma os sinais, sem supervisão externa, tornando sua estrutura essencial mais acessível [5]. Os mapas auto-organizáveis (SOM - *Self-Organizing Map*) também são muito utilizados para extração de características e agrupamento. O SOM é um tipo de rede neural de treinamento não-supervisionado capaz de produzir um espaço de características onde sinais semelhantes são mapeados em regiões adjacentes deste espaço. As redes neurais de treinamento supervisionado são bastante utilizadas para classificação pois sua habilidade de produzir hiperplanos não-lineares de separação em geral produz melhores resultados que os classificadores lineares. Na Seção 5.1 serão mostradas aplicações de técnicas de aprendizado estatístico em Física de Partículas. Na Seção 5.2 e os aspectos teóricos das técnicas utilizadas serão discutidos, e em 3.3 os sistemas de classificação propostos serão descritos.

5.1 Aplicações em Física de Altas Energias e Áreas Correlatas

Nesta Seção serão descritas algumas aplicações de técnicas de aprendizado estatístico em Física de Alta Energia (HEP - *High-Energy Physics*).

5.1.1 Aplicações de classificadores neurais

As redes neurais de treinamento supervisionado vêm sendo utilizadas para classificação de eventos em sistemas de *trigger* de detectores de partículas em física de alta energia desde o início da década de 1990. O primeiro *trigger* baseado em redes neurais foi projetado e testado no FermiLab para a identificação da trajetória de múons [51]. O *trigger* neural não foi implementado no experimento mas operou em paralelo com o algoritmo oficial, obtendo uma resolução 40 vezes melhor.

O primeiro sistema de *trigger* neural operando em um experimento de HEP [52] foi implementado no segundo nível de filtragem do detector H1 (um dos detectores do acelerador HERA, que operou no laboratório DESY na Alemanha) [53]. No H1, o segundo nível de filtragem foi baseado em redes neurais, um classificador neural foi treinado para cada canal de filtragem existente no experimento. As redes neurais foram implementadas em hardware dedicado para minimizar o tempo de resposta [54].

Exemplos mostram também a aplicação de redes neurais para a análise de chuveiros de partículas gerados nos calorímetros. A colaboração do *Crystal Barrel*, detector do experimento LEAR do CERN [55], conseguiu a identificação de fótons e píons [56]. No experimento HEGRA [57] (localizado na ilha La Palma, Espanha), conseguiu-se a separação entre fótons e hádrons com um classificador neural supervisionado. A colaboração do H1 conseguiu discriminar elétrons de píons utilizando os perfis dos calorímetros eletromagnéticos e hadrônicos [52]. Um *trigger* de segundo nível baseado em redes neurais e informação de calorimetria foi proposto para o LHC em [58]. No último trabalho, informações do perfil de deposição de energia nos calorímetros foram utilizados para produzir a identificação de elétrons. Outros exemplos da aplicação de redes neurais para classificação de sinais de calorimetria pode ser encontrados em [54].

Outras aplicações de redes neurais em HEP também são comuns, entre as quais pode-se destacar a identificação do sabor de quarks no experimento LEP do CERN [59], o trigger de neutrinos do experimento CHOOZ [52], a discriminação gamma-hadron a partir de chuveiros de partículas gerados por raios cósmicos [60], a medição da massa de top-quarks no acelerador Tevatron do Fermilab [61], a identificação da massa de eventos de raios cósmicos, no Observatório Pierre Auger [62].

Mesmo com todos os exemplos de aplicações bem sucedidas de redes neurais, o seu uso está longe de ser uma unanimidade entre a comunidade de HEP. Uma característica particular do campo de aplicação é que há uma busca pelo entendimento de novos fenômenos, que são representados (nos dados simulados, que em geral são utilizados no treinamento dos classificadores) por modelos teóricos aproximados, que nem sempre estão corretos. Um experimento pode concluir que um modelo teórico existente está incompleto ou até mesmo errado. O uso de redes neurais é justificado pela facilidade de operação em alta dimensão (inúmeras variáveis são utilizadas no processo de identificação da física de interesse), porém, a dependência dos modelos teóricos é mais difícil de ser verificada ou corrigida nos classificadores não-lineares (em comparação com os cortes lineares mais usualmente utilizados em HEP) [52]. Essa característica particular da HEP talvez tenha produzido uma resistência maior ao uso de redes neurais em comparação a outros campos da ciência. No caso da aplicação no detector H1, toda a colaboração do experimento precisou se convencer que as redes não eram uma caixa preta misteriosa e um esforço conjunto foi feito no sentido de entender como as redes funcionam e como podem ser ajustadas de modo ótimo para cada problema [54]. De um modo geral, o uso de redes neurais está consolidado e bem aceito como ferramenta importante na análise *offline*, porém, no trigger online a situação ainda é ambígua, com grupos a favor e outros contra [52].

5.1.2 Aplicações de técnicas estatísticas de extração de características

Mais recentemente, a partir do final da década de 1990, os métodos de aprendizado estatístico multi-variável como PCA, ICA e SOM vêm sendo aplicados com sucesso em problemas na área de física de alta energia. Nestes algoritmos, o aprendizado é feito de modo não-supervisionado, e as características estimadas não dependem de

conhecimento prévio a respeito dos sinais utilizados.

Um dos primeiros trabalhos neste tópico [63], foi publicado em 1998 e utiliza mapas auto-organizáveis (SOM) para a classificação de eventos de raios gama em astronomia de alta energia. Em [64], mapas SOM foram aplicados para a separação de bósons W do ruído de fundo composto por jatos hadrônicos. No trabalho [65], o ruído de fundo gerado na aceleração do feixe de partículas foi rejeitado a partir de mapas auto-organizáveis modificados. Redes SOM também foram utilizadas com sucesso para análise, classificação e monitoramento de sinais do telescópio OGLE (no Chile) [66] e para a identificação de prováveis assinaturas de bósons de Higgs [67].

A análise de componentes principais (PCA) é uma técnica de descorrelação e compactação bastante utilizada em diversas áreas do conhecimento. Em física de alta energia, PCA foi aplicada para a seleção de variáveis de entrada de um discriminador neural no trabalho [68]. Em [69], são apresentadas diversas aplicações em HEP onde é utilizada a PCA para extração de características e compactação. No trabalho [70], sinais ópticos de nebulosas planetárias são processados por PCA com o objetivo de extrair informações a respeito de suas características morfológicas. Numa outra aplicação em astrofísica, PCA é utilizada, em conjunto com ICA, para a remoção do ruído de fundo e de outras fontes de interferência, permitindo melhor visualização de dados de ventos e tempestades solares [71]. O trabalho [49] utiliza a PCA, de forma segmentada, para compactação de sinais de calorimetria do ATLAS, em seguida classificadores neurais realizam a decisão elétron/jato, conseguindo boa eficiência de classificação.

A análise de componentes independentes (ICA) tem aplicação mais recente em HEP, sendo que um dos primeiros trabalhos foi publicado em 2005 e descreve a eliminação de ruído na análise de sinais do feixe de partículas do experimento BOOSTER do Fermilab [72]. Neste trabalho também é realizada uma comparação com um sistema semelhante baseado em PCA e a ICA apresenta resultados melhores. No trabalho [73], ICA é utilizada para análise de dados multi-variados em experimentos de física atômica e nuclear. A aplicação de ICA proporcionou redução do ruído de fundo, permitindo melhor visualização do sinal de interesse. ICA também foi aplicado com sucesso para separação de sinais em astrofísica de alta energia conforme detalhado a seguir. Em [74], ICA foi aplicada para a separação de imagens

de fontes sobrepostas adquiridas pelo satélite Planck da Agência Espacial Européia; no trabalho [75] utiliza-se a análise de componentes independentes, em substituição aos filtros casados, para a decomposição de sinais astrofísicos simulados compostos pela combinação de moléculas elementares em estado congelado. Ainda na área de astrofísica, nos trabalhos [76, 77] ICA foi aplicado para a caracterização da radiação cósmica de fundo em microondas (CMB - *Cosmic Microwave Background*). A CMB é uma forma de energia eletromagnética que preenche todo o universo e foi inicialmente observada em 1965. A CMB é visualizada apenas por rádio-telescópios.

A partir destes exemplos, percebe-se que, apesar da aplicação mais recente em física de alta energia e áreas correlatas, diversos problemas de extração de características, remoção de ruído, agrupamento não-supervisionado (*clustering*) e visualização vêm sendo resolvidos com a aplicação das técnicas estatísticas de processamento não-supervisionado de sinais.

5.2 Técnicas de Extração de Características Utilizadas neste Trabalho

A seguir serão descritos, de modo resumido, as técnicas de extração de características utilizadas neste trabalho para a maximização da eficiência do canal elétron/jato do segundo nível de filtragem do detector ATLAS. Mais detalhes teóricos a respeito dos métodos podem ser encontrados no Apêndice A.

5.2.1 Mapas auto-organizáveis

O mapa auto-organizável (SOM - *Self Organizing Map*) é uma rede neural com treinamento não-supervisionado, baseado na aprendizagem competitiva, que é capaz de realizar uma organização topológica das entradas. O SOM foi proposto por Teuvo Kohonen em 1982 [78], sendo capaz de realizar um mapeamento não-linear dos sinais de um espaço de entrada contínuo de dimensão k para um espaço de características discreto que, em geral, é bidimensional. Cada neurônio da grade está diretamente conectado a todos os nós de entrada. Na Figura 5.1 pode-se visualizar o diagrama de um mapa auto-organizável bi-dimensional.

O mapa auto-organizável compacta informação e preserva relações topológicas




Figura 5.1: Diagrama de um mapa auto-organizável

ou métricas do conjunto de sinais. Os SOM estão ligadas à ICA por conseguirem extrair informações ocultas dos sinais de forma não supervisionada [79]. Uma aproximação das componentes independentes não-lineares pode ser obtida utilizando mapas auto-organizáveis [5].

Três processos estão envolvidos na formação do mapa auto-organizado: a **competição**, onde para cada vetor de entrada há apenas um neurônio vencedor; a **cooperação**, quando o neurônio vencedor determina uma vizinhança topológica de neurônios excitados; e a **adaptação**, que procede ao ajuste dos pesos sinápticos para reforçar a resposta do neurônio vencedor, e de seus vizinhos, ao padrão de entrada.

A atualização do vetor de pesos w_j do neurônio j é feita através da equação:

$$w_j(n+1) = w_j(n) + \eta(n)h_{ij}(n)(x(n) - w_j(n)), \quad (5.1)$$

sendo $\eta(n)$ a taxa de aprendizagem, a função de vizinhança $h_{ij}(n)$ pode ser definida por:

$$h_{ij}(n) = \exp(-d_{ij}^2/2\sigma^2(n)) \quad (5.2)$$

onde d_{ij} é a distância do neurônio j para o neurônio vencedor i e $\sigma(n)$ é a largura da função vizinhança na n -ésima iteração.

O mapa de características possui algumas propriedades, listadas a seguir [6]:

1. é formado pelo conjunto de vetores de pesos sinápticos w_i no espaço de saída discreto e fornece uma boa aproximação para o espaço de entrada;
2. é ordenado de modo topológico. Padrões de entrada semelhantes são mapeados para regiões adjacentes no mapa de características;

3. regiões do espaço de entrada que possuem alta probabilidade de ocorrência são mapeadas para domínios maiores do espaço de saída;
4. fornece uma aproximação discreta das curvas principais, podendo ser visto como uma generalização não-linear da análise de componentes principais.

No mapa de características o neurônio que apresentar maior saída é considerado o vencedor, ou seja a saída do SOM é do tipo “vencedor leva tudo” (WTA - *winner takes all*). O neurônio ativado é escolhido a partir de sua semelhança com a entrada apresentada. É comum a utilização da distância euclidiana como métrica da proximidade entre dois vetores; nesse caso, o neurônio vencedor é aquele que minimiza $i(\mathbf{x}) = \|\mathbf{x}(n) - \mathbf{w}_j\|$.

Uma outra forma de operar um mapa auto-organizável é utilizar as projeções dos sinais de entrada no mapa de características, ou seja as saídas u_j de cada neurônio j que pode ser calculada por:

$$u_j = \mathbf{x}^T \mathbf{w}_j \quad (5.3)$$

O vetor $\mathbf{u} = [u_1, \dots, u_K]^T$ pode ser considerado como a projeção de \mathbf{x} no mapa de características.

Os mapas auto-organizáveis pertencem à classe de algoritmos de codificação vetorial, sendo capazes de encontrar de forma otimizada um número fixo de vetores ou palavras de código que melhor representem o conjunto de sinais.

5.2.2 Análise de Componentes Principais

A análise de componentes principais (PCA - *Principal Component Analysis*) é uma técnica estatística de processamento de sinais diretamente ligada à transformação de *Karhunen-Loève* [4]. O objetivo da PCA é encontrar uma transformação linear onde os sinais projetados sejam não-correlacionados e grande parcela da energia (variância) esteja concentrada num pequeno número de componentes. Para isso, são exploradas informações da estatística de segunda ordem. A análise de componentes principais é bastante usada para compactação de informação. Para reduzir a dimensão dos dados, seleciona-se apenas os componentes de maior energia, de modo que o sinal recuperado a partir da informação compactada tenha pequeno

erro médio quadrático se comparado ao original. A seguir serão desenvolvidos, de forma resumida, os fundamentos matemáticos da PCA.

Considerando-se um vetor $\mathbf{x} = [x_1, \dots, x_N]^T$ aleatório com N elementos, assume-se que ele tenha média zero:

$$\mathcal{E}\{\mathbf{x}\} = 0 \quad (5.4)$$

onde $\mathcal{E}\{\cdot\}$ é o operador esperança. Se \mathbf{x} tem média não nula faz-se $\mathbf{x} \leftarrow \mathbf{x} - \mathcal{E}\{\mathbf{x}\}$.

A projeção z_i de \mathbf{x} na direção de \mathbf{v}_i pode ser expressa por:

$$z_i = \mathbf{v}_i^T \mathbf{x} = \sum_{k=1}^N v_{ki} x_k \quad (5.5)$$

Na transformação por PCA, as componentes z_i ($i = 1, \dots, N$) devem ser ortogonais e ordenadas (de modo decrescente) pela variância das projeções, sendo, então, z_1 a projeção de máxima variância. Para tornar a variância independente da norma de \mathbf{v}_i , faz-se:

$$\mathbf{v}_i \leftarrow \frac{\mathbf{v}_i}{\|\mathbf{v}_i\|} \quad (5.6)$$

Fazendo-se com que $\|\mathbf{v}_i\| = 1$, torna-se a variância função apenas da direção das projeções. A ortogonalidade garante a não-correlação entre as componentes.

Como $\mathcal{E}\{\mathbf{x}\} = 0$, então $\mathcal{E}\{z_i\} = 0$, logo a variância da projeção z_i é calculada por $\mathcal{E}\{z_i^2\}$. Seguindo a definição da PCA, z_1 tem máxima variância; logo, \mathbf{v}_1 é encontrado pela maximização de [5]:

$$J_1^{PCA}(\mathbf{v}_1) = \mathcal{E}\{z_1^2\} = \mathcal{E}\{(\mathbf{v}_1^T \mathbf{x})^2\} = \mathbf{v}_1^T \mathcal{E}\{\mathbf{x}\mathbf{x}^T\} \mathbf{v}_1 = \mathbf{v}_1^T \mathbf{C}_x \mathbf{v}_1, \quad (5.7)$$

onde \mathbf{C}_x é a matriz de covariância de \mathbf{x} .

A solução para o problema de maximização da equação (5.7) pode ser encontrada na álgebra linear em função dos autovetores $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_N$ da matriz \mathbf{C}_x . A ordem

dos autovetores é tal que os autovalores associados satisfazem $d_1 > d_2 > \dots > d_N$. Desta forma, tem-se:

$$\mathbf{v}_i = \mathbf{e}_i, \quad 1 \leq i \leq N \quad (5.8)$$

Percebe-se que a PCA de \mathbf{x} e a decomposição por autovalores da matriz \mathbf{C}_x (de dimensão $N \times N$) são equivalentes. Limitações computacionais na extração das componentes principais utilizando as equações (5.5) e (5.8) aparecem quando a dimensão N do vetor \mathbf{x} aumenta, pois o processo de obtenção dos autovetores se torna proibitivamente lento. Nesse caso, uma solução é utilizar métodos iterativos de extração das componentes principais através de redes neurais [80].

5.2.3 Análise de Componentes Independentes

Diferente da PCA, que busca as direções ortogonais de máxima variância, a análise de componentes independentes (ICA - *Independent Component Analysis*) é uma transformação onde as componentes na saída são estatisticamente independentes.

- **Independência Estatística:** Considerando duas variáveis aleatórias (VAs) x e y , se elas são independentes, então o conhecimento de uma não traz nenhuma informação a respeito da outra. Um sinal musical e um ruído sonoro originado de uma máquina elétrica são exemplos de variáveis independentes.

Matematicamente, y_1 e y_2 são independentes estatisticamente se e somente se [81]:

$$p_{y_1, y_2}(y_1, y_2) = p_{y_1}(y_1)p_{y_2}(y_2), \quad (5.9)$$

onde $p_{y_1, y_2}(y_1, y_2)$, $p_{y_1}(y_1)$ e $p_{y_2}(y_2)$ são respectivamente as funções de densidade de probabilidade (pdf - *probability density function*) conjunta e marginais de y_1 e y_2 . O conceito de independência envolve o conhecimento de toda a estatística dos dados, sendo assim muito mais abrangente que a não-correlação (utilizada pela PCA), que somente utiliza estatística de segunda ordem (variância).

Pode-se obter uma expressão equivalente à equação (5.9) se, para todas as

funções $g(y_1)$ e $h(y_2)$ absolutamente integráveis em y_1 e y_2 , vale a igualdade:

$$\mathcal{E}\{g(y_1)h(y_2)\} = \mathcal{E}\{g(y_1)\}\mathcal{E}\{h(y_2)\} \quad (5.10)$$

Para evitar a estimação das funções de densidade de probabilidade, pode-se utilizar a equação (5.10). A definição de independência pode ser facilmente estendida para mais de duas variáveis aleatórias. Percebe-se da equação (5.10) que a independência é um princípio mais restritivo que a não-correlação (quando $g(x) = x$ e $h(y) = y$). No Apêndice A serão detalhados os princípios matemáticos mais utilizados para a estimação das componentes independentes.

Na ICA, considera-se que um sinal multi-dimensional $\mathbf{x}(t) = [x_1(t), \dots, x_N(t)]^T$ observado (ou medido) é gerado a partir da combinação linear das fontes independentes $\mathbf{s}(t) = [s_1(t), \dots, s_N(t)]^T$. Na forma matricial e suprimindo-se o índice temporal t , pode-se escrever [82]:

$$\mathbf{x} = \mathbf{A}\mathbf{s}, \quad (5.11)$$

onde \mathbf{A} ($N \times N$) é a matriz de mistura.

O objetivo final da ICA é encontrar uma aproximação \mathbf{y} das fontes independentes ou da transformação linear \mathbf{A} utilizando apenas os sinais observados \mathbf{x} . O vetor \mathbf{y} é definido por:

$$\mathbf{y} = \mathbf{W}\mathbf{x} \quad (5.12)$$

sendo \mathbf{W} a matriz de separação.

Um problema clássico que pode ser solucionado usando-se ICA é conhecido como *cocktail-party problem*, e está formulado de forma simplificada omitindo atrasos temporais e outros fenômenos físicos como a existência de múltiplas reflexões, nas equações (5.13) e (5.14) (ver Figura 5.2). Considerando que numa sala existem duas pessoas falando simultaneamente e dois microfones em diferentes posições, os sinais gravados $x_1(t)$ e $x_2(t)$ são uma soma ponderada das fontes $s_1(t)$ e $s_2(t)$:

$$x_1(t) = a_{11}s_1(t) + a_{12}s_2(t) \quad (5.13)$$

$$x_2(t) = a_{21}s_1(t) + a_{22}s_2(t); \quad (5.14)$$

os coeficientes a_{ij} dependem das distâncias dos microfones às pessoas, e podem ser considerados como os elementos da matriz de mistura \mathbf{A} do modelo da equação 5.11, onde:

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}. \quad (5.15)$$

Se os fatores a_{ij} são conhecidos, o problema é facilmente resolvido a partir de:

$$\mathbf{s} = \mathbf{W}\mathbf{x}, \quad (5.16)$$

onde $\mathbf{W} = \mathbf{A}^{-1}$. Na prática, tanto as fontes s_i como os a_{ij} devem ser obtidos apenas dos sinais misturados x_i .




Figura 5.2: Diagrama do *cocktail party problem*.

Em um exemplo de aplicação de ICA, a Figura 5.3-a mostra as fontes $s_1(t)$ e $s_2(t)$, que foram misturadas linearmente gerando os sinais $x_1(t)$ e $x_2(t)$ da Figura 5.3-b. Após a aplicação de um algoritmo para extração das componentes independentes (FastICA [83]), foram obtidas as curvas da Figura 5.3-c. Percebe-se que os sinais recuperados são cópias dos originais, a menos de fatores multiplicativos. Esta é uma das limitações inerentes do modelo da ICA, não há como garantir o fator de escala (que pode ser positivo ou negativo) ou a ordem de extração das componentes.

As técnicas de ICA foram desenvolvidas inicialmente para solucionar problemas de separação cega de sinais (BSS - *Blind Signal Separation*) semelhantes ao *cocktail-party problem*, porém mais recentemente surgiram outras aplicações interessantes,

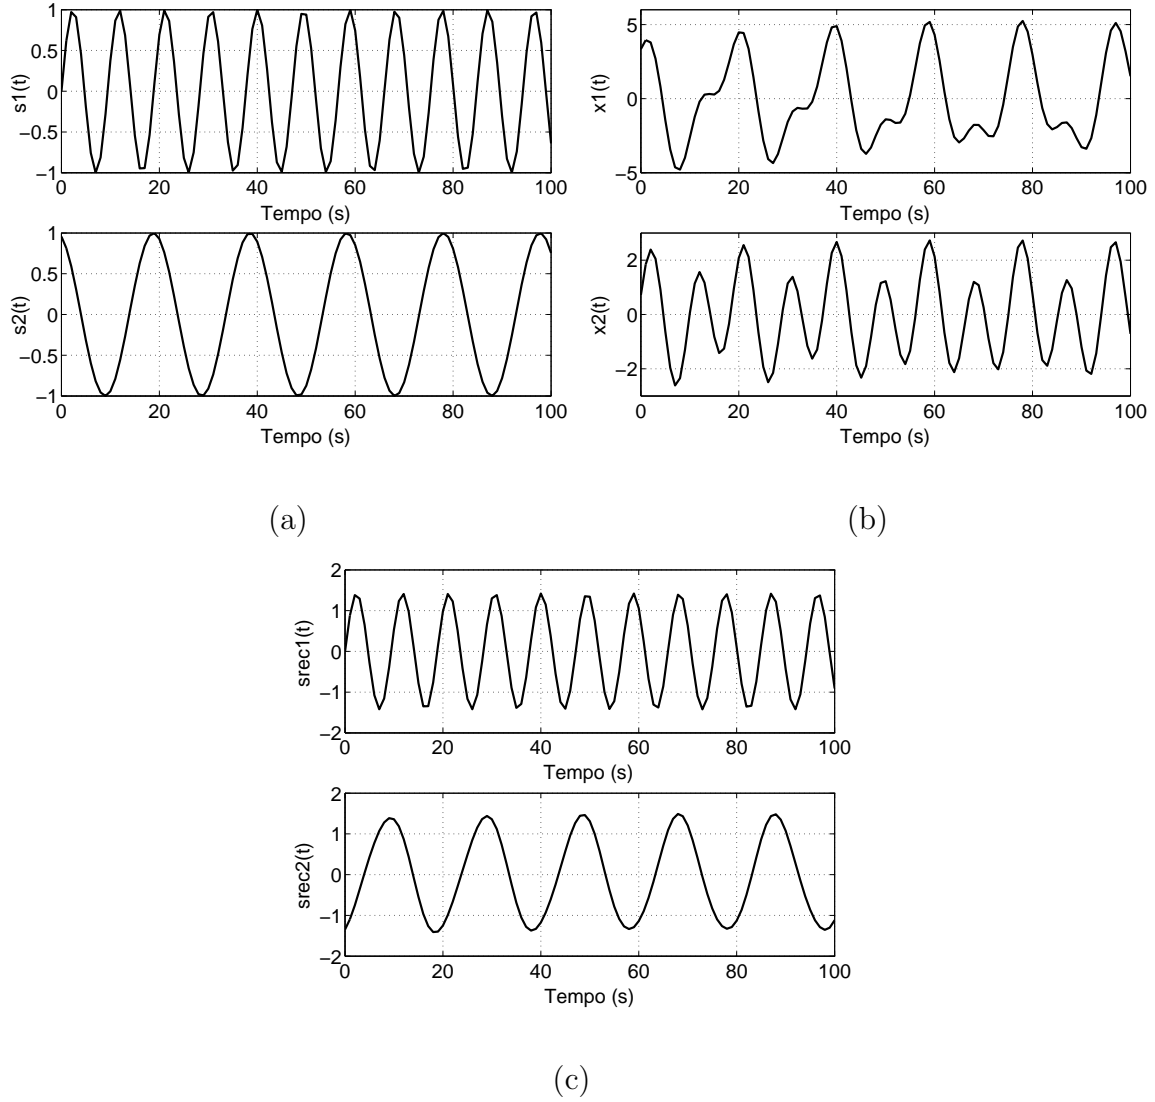


Figura 5.3: Sinais (a) fonte, (b) observados e (c) recuperados através da ICA.

como extração de características, separação de fontes em telecomunicações e redução de ruído em imagens [5, 83]. Atualmente a ICA tem sido aplicada com sucesso tanto para separação de sinais como para extração de características.

5.2.4 ICA não-linear

Em muitos problemas práticos o modelo básico da ICA, onde os sinais observados são considerados combinações lineares e instantâneas das fontes, não representa corretamente o cenário real. Os calorímetros do ATLAS são um exemplo de ambiente onde os sinais podem ser modificados por fenômenos não-lineares (os calorímetros são projetados para serem detectores lineares, porém, por restrições na construção dos

sensores e montagem do detector, é razoável esperar que os sinais, na prática, sejam modificados por fenômenos não-lineares de natureza desconhecida, como por exemplo saturação de sensores, distorções na conversão dos sinais ópticos para elétricos e na propagação dos sinais).

A equação (5.17) apresenta um modelo geral para as misturas não-lineares:

$$\mathbf{x} = \mathbf{F}(\mathbf{s}), \quad (5.17)$$

onde \mathbf{F} é um mapeamento não-linear de $\mathbb{R}^N \rightarrow \mathbb{R}^N$

vetor de m funções de mistura não lineares desconhecidas, \mathbf{x} e \mathbf{s} são respectivamente os sinais observados e as fontes. A ICA não-linear consiste em encontrar o mapeamento $\mathbf{G}: \mathbb{R}^N \rightarrow \mathbb{R}^N$ tal que as componentes de \mathbf{y} sejam estatisticamente independentes:

$$\mathbf{y} = \mathbf{G}(\mathbf{x}). \quad (5.18)$$

Uma característica da NLICA é que o problema apresenta múltiplas soluções [84]. Se \mathbf{y}_1 e \mathbf{y}_2 são variáveis aleatórias independentes, é fácil provar que $f(\mathbf{y}_1)$ e $g(\mathbf{y}_2)$ (onde $f(\cdot)$ e $g(\cdot)$ são funções diferenciáveis) são também independentes []. Fica claro que, sem o uso de alguma restrição, infinitos mapeamentos inversos G satisfazem a condição de independência entre os sinais estimados y_i , $i=1, \dots, N$, em uma dada aplicação. Se o objetivo do problema for realizar a separação cega das fontes (BSS - *Blind Signal Separation*), neste caso, deseja-se que as componentes y_i sejam as fontes independentes que produziram os sinais observados \mathbf{x} , então, informações a respeito do modelo de mistura ou das fontes devem ser conhecidas a priori. A NLICA vêm sendo aplicada com sucesso em problemas como processamento de sinais de fala [85] e remoção de ruído em imagens [86].

Em geral, o número de parâmetros a serem estimados num modelo de ICA não-linear é maior que no caso linear. Os algoritmos de NLICA, se comparados com os de ICA, apresentam maior complexidade computacional e convergência mais lenta. Em problemas de separação cega de fontes o algoritmo a ser utilizado deve ser escolhido utilizando informações a respeito do modelo de mistura. Considerando estas limitações, o uso da NLICA em substituição ao modelo linear somente é justificado se a precisão na estimação das componentes aumenta e a aplicação não apresenta restrição ao aumento do tempo de processamento.

Entre os algoritmos de NLICA propostos na literatura, uma classe de métodos impõe restrições estruturais ao modelo de mistura, neste caso, pode-se garantir que as componentes estimadas são iguais às fontes (a menos por indeterminações de fator multiplicativo e ordem de estimação dos sinais, assim como no modelo linear). Uma solução de implementação mais direta é o uso de mapas auto-organizáveis para estimar o mapeamento não-linear, neste caso não há restrição de modelo. Outro método diretamente relacionado com a NLICA, chamado de ICA Local, propõe uma etapa de agrupamento dos sinais em conjuntos de características semelhantes, que deve ser realizada antes da ICA. O agrupamento produz um mapeamento não-linear dos dados e a ICA (linear) estima as componentes independentes. Mais informações a respeito dos diversos algoritmos e modelos de NLICA serão fornecidas nas próximas seções.

Unicidade da Solução em NLICA

No caso não-linear, a independência estatística não é suficiente para garantir a separação das fontes. Se duas variáveis aleatórias y_1 e y_2 são independentes, então $p_{y_1, y_2}(y_1, y_2) = p_{y_1}(y_1)p_{y_2}(y_2)$, para funções diferenciáveis f e g , pode-se provar que [87]:

$$p_{f(y_1), g(y_2)}(y_1, y_2) = p_{f(y_1)}(y_1)p_{g(y_2)}(y_2), \quad (5.19)$$

e então as variáveis $f(y_1)$ e $g(y_2)$ são também independentes. Esta indeterminação, diferente do fator de escala e da ordem de estimação das componentes (que são inerentes a ICA linear), não são aceitáveis em um problema de separação de fontes.

Estudos teóricos indicaram que a unicidade da solução da NLICA pode ser conseguida se o problema apresentar pelo menos uma das características a seguir [88]:

- O número de componentes é igual a dois. Deste modo os sinais podem ser considerados como uma variável complexa.
- As pdf das componentes independentes são limitadas a valores conhecidos.
- A função de mistura \mathbf{F} preserva o zero ($\mathbf{F}(0) = 0$) e é um mapeamento unívoco que preserva localmente a ortogonalidade das coordenadas.
- O modelo de mistura é conhecido a priori e utilizado como informação para o algoritmo de estimação das componentes independentes.

Misturas Pós Não-Lineares

Um caso especial da ICA não-linear são os métodos de estimação que incluem no algoritmo de estimação das componentes independentes informações a respeito do modelo não-linear que gerou os dados observados. Estas informações se configuram em restrições estruturais ao mapeamento inverso (que é estimado pelo algoritmo). Entre estes modelos, o de misturas **pós não-lineares** (PNL) [87] é um dos mais utilizados na literatura.

No modelo PNL, considera-se que inicialmente ocorre uma combinação linear das fontes (como no modelo básico de ICA), e as funções não-lineares f_i são aplicadas antes da observação dos sinais x_i :

$$x_i = f_i\left(\sum_{j=1}^n a_{ij}s_j\right). \quad (5.20)$$

É importante notar que as não-linearidades são aplicadas individualmente a cada componente da mistura linear (não são permitidas linearidades cruzadas). A Figura 5.4 ilustra o modelo de misturas PNL.




Figura 5.4: Diagrama do modelo de mistura PNL.

A consideração de que as misturas são pós não-lineares permite uma grande simplificação do problema, e as indeterminações existentes se tornam semelhantes às do caso linear. A modelagem através da equação (5.20) satisfaz grande parte dos fenômenos não-lineares, como, por exemplo, a modelagem da distorção de sensores num meio de propagação linear.

Detalhes de alguns algoritmos para estimação das componentes independentes em misturas PNL são fornecidos no Apêndice A.

Outros modelos de misturas com restrições estruturais

Alguns modelos com restrições estruturais diferentes do PNL foram propostos na literatura. No trabalho [89], o modelo de mistura é definido por:

$$\mathbf{x} = \mathbf{A}_2 f(\mathbf{A}_1 \mathbf{s}), \quad (5.21)$$

sendo \mathbf{A}_1 e \mathbf{A}_2 matrizes quadradas e $f = [f_1, f_2, \dots, f_N]^T$ são funções não-lineares aplicados a cada componente (assim como o modelo PNL, este também não permite não-linearidades aplicadas a mais de um componente). O modelo definido na Equação 5.21 e ilustrado também na Figura 5.5 é chamado Pós Não-linear Linear (PNL-L). O bloco linear \mathbf{A}_2 é executado após a aplicação das funções não-lineares, produzindo um modelo mais geral que o PNL. Nos trabalhos [90, 91] são propostos algoritmos baseados em redes neurais para a estimação do modelo PNL-L.




Figura 5.5: Diagrama do modelo PNL-L.

Em [91], um modelo estrutural chamado mono não-linearidade (ver Figura 5.6) foi proposto para o problema da NLICA. Neste modelo os sinais observados são gerados a partir de:

$$\mathbf{x} = f^{-1}(\mathbf{A}f(\mathbf{s})). \quad (5.22)$$

Este modelo é dito mais geral que o PNL pois as funções não-lineares podem ser aplicadas a mais de uma componente (as funções f_i podem ser funções não-lineares de mais de uma variável). Este modelo é chamado de mistura de mono não-linearidade (ver Figura 5.6). A generalidade deste modelo é derivada da teoria da análise funcional (*functional analysis*) [92] e foi mostrado em [91] que esta arquitetura pode representar qualquer mistura com duas camadas de não-linearidades.

Algoritmos sem restrições estruturais

Se nenhuma restrição ao modelo de mistura é imposta não há garantia que os componentes independentes estimados estejam relacionadas com as fontes (ver Seção




Figura 5.6: Diagrama do modelo da Mono não-linearidade.

5.2.4). Então, esta classe de algoritmos de NLICA não é capaz de realizar a separação de fontes, a menos quando as premissas da unicidade das soluções sejam atendidas. Entre os métodos de NLICA sem restrições estruturais, pode-se destacar o uso de mapas auto-organizáveis, que foi um dos primeiros algoritmos utilizados para NLICA [93], e os métodos que utilizam inferência Bayesiana [94].

NLICA a partir de Mapas Auto-Organizáveis:

Uma das primeiras tentativas bem sucedidas de realizar NLICA utilizou mapas auto-organizáveis [93]. Pode-se provar que as coordenadas y_1 e y_2 do neurônio vencedor no mapa (ver Figura 5.7) são independentes e aproximadamente uniformemente distribuídas [93]. Para estimar a NLICA, o SOM é treinado usando como entradas os sinais observados, e as coordenadas do neurônio vencedor correspondem a uma aproximação das componentes independentes.




Figura 5.7: NLICA a partir de SOM.

Entre as desvantagens do método pode-se destacar:

- O mapeamento é discreto (existe um número limitado de neurônios no mapa), então algum tipo de regularização é necessária para produzir componentes

contínuos. Esse problema pode ser minimizado aumentando-se o número de neurônios do mapa.

- Os componentes a serem estimados devem ter pdf sub-gaussiana (quanto mais próxima da distribuição uniforme, melhor).
- O custo computacional aumenta rapidamente com o número de componentes independentes a serem estimados.

Para avaliar o custo computacional, o número de parâmetros N_p do SOM pode ser estimado pela expressão:

$$N_p = N \times (Q_L)^N \quad (5.23)$$

onde N é o número de componentes a serem estimados (que é considerado igual ao número de sinais observados) e Q_L é o número de níveis de quantização desejado.

Com uma formulação alternativa aos SOM, o Mapeamento Topográfico Generativo (GTM - *Generative Topographic Mapping*) foi introduzido em [95], e apresenta princípios estatísticos mais fundamentados que o mapa SOM. O método GTM básico tem poucas vantagens práticas em relação aos Mapas Auto-Organizáveis, pois aqui as componentes independentes também são assumidas como processos uniformemente distribuídos e o espaço de características é formado a partir de uma grade retangular discreta m -dimensional. Porém, devido a sua formulação matemática mais fundamentada, o GTM pode ser facilmente estendido para variáveis não uniformes. O trabalho [96] propõe uma modificação à formulação básica onde são introduzidos coeficientes de ponderação que permitem a estimação de componentes independentes com qualquer tipo de distribuição. Os componentes são modelados como misturas de sinais Gaussianos e os parâmetros são estimados usando o algoritmo *Expectation Maximization* [83]. O treinamento do GMT envolve dois passos, a avaliação da probabilidade *a posteriori* e a adaptação dos parâmetros do modelo.

NLICA a partir de Inferência Bayesiana:

Nos métodos baseados em inferência Bayesiana, considera-se que os sinais observados são gerados a partir de [94]:

$$\mathbf{x} = f(\mathbf{s}) + \mathbf{n} \quad (5.24)$$

onde \mathbf{n} é definido como ruído Gaussiano independente dos componentes a serem estimados.

Os componentes independentes são modelados como misturas de sinais de distribuição Gaussiana. Pode-se provar que [94] dado um número suficiente de Gaussianas, virtualmente qualquer distribuição de probabilidade pode ser modelada com uma certa precisão. Uma variação deste método foi aplicada em [97] para o modelo linear da ICA. Em grande parte dos algoritmos Bayesianos para NLICA, redes neurais tipo MLP de duas camadas são treinadas para aproximar o mapeamento não linear:

$$f(\mathbf{s}) = \mathbf{B}\Phi(\mathbf{A}\mathbf{s} + \mathbf{a}) + \mathbf{b} \quad (5.25)$$

Em um método de estimação Bayesiano, probabilidades *a posteriori* são associadas a cada modelo não-linear que possivelmente teria gerado os dados observados. Verificar uma quantidade tão grande de modelos não é possível na prática, então os métodos Bayesianos para NLICA utilizam uma técnica chamada de “aprendizagem amostral” (EL - *ensemble learning*) [98]. Na EL, somente o conjunto mais provável de modelos é testado utilizando uma aproximação paramétrica que é ajustada à probabilidade *a posteriori* [99].

Métodos Bayesianos de NLICA foram propostos em [100] e [101]. No trabalho [102] foram realizados testes experimentais para comparar o desempenho dos modelos Bayesiano e PNL na estimação dos componentes independentes, as principais conclusões foram:

- os algoritmos PNL apresentam desempenho superior quando as misturas seguem o modelo PNL clássico (não-linearidades inversíveis e mesmo número de componentes independentes e sinais observados);
- o desempenho de ambos os métodos pode ser melhorada a partir da exploração da informação de mais misturas que componentes independentes;
- a principal vantagem do método Bayesiano é que mapeamentos mais genéricos podem ser produzidos (uma vez que não há restrições estruturais). Estes métodos geralmente apresentam maior custo computacional e necessitam de várias inicializações para obter uma solução ótima (podem apresentar problemas com mínimos locais da função custo).

Local ICA

Se o modelo da ICA for utilizado para extração de características (ao invés de separação de fontes), uma melhor descrição dos dados pode ser obtida se forem exploradas características locais. Considerando um conjunto de sinais multi-dimensionais com estatística variável, o modelo da ICA linear pode não ser capaz de revelar a estrutura fundamental dos dados. Neste caso, é mais razoável realizar a extração de características (estimação das componentes independentes) a partir de k subconjuntos dos dados (ver Figura 5.8). Os sinais pertencentes ao k -ésimo subconjunto apresentam características semelhantes. Este procedimento leva ao modelo da ICA local.




Figura 5.8: Diagrama do modelo da ICA local.

Conforme proposto em [103], um conjunto de dados de alta dimensão pode ser separado em sub-conjuntos, através de algum algoritmo de agrupamento como o k -means [104] ou SOM [105], e componentes independentes lineares são então estimadas de cada subconjunto. Determinar o número ideal de agrupamentos em um conjunto de dados não é uma tarefa simples e geralmente requer informação a priori. No trabalho [106] foi proposto um critério para a escolha do número de agrupamentos em um problema “cego” de processamento de sinais.

Na ICA Local, o agrupamento é responsável por uma representação não-linear dos dados, enquanto modelos de ICA linear aplicados a cada sub-conjunto (*cluster*) descrevem as características locais dos dados. A ICA local pode ser considerada como um compromisso entre os modelos linear e não-linear da ICA [84]. O objetivo é obter uma melhor representação dos dados (se comparado com o modelo linear da ICA), evitando os problemas computacionais do modelo não-linear [107]. Em diferentes abordagens, os agrupamentos podem ser montados com superposição,

usando por exemplo fronteiras *fuzzy* [108, 109], ou sem superposição [107, 110].

Nos trabalhos [111, 112] a ICA Local foi aplicada para a estimação da informação mútua. A informação mútua [113] é uma importante ferramenta em diversas aplicações de processamento de sinais, especialmente na seleção de características.

Capítulo 6

Metodologia Proposta

6.1 Sistemas de Classificação Propostos para a Seleção de Elétrons no Segundo-Nível de Filtragem do ATLAS

Os sistemas de filtragem propostos neste trabalho são divididos em duas etapas distintas. Inicialmente os sinais medidos são pré-processados para que suas características discriminantes se tornem mais acessíveis. As características extraídas são utilizadas como entrada para os classificadores propriamente ditos. Nesta Seção serão descritos os sistemas de filtragem utilizados.

Os métodos de extração de características propostos neste trabalho (SOM, PCA, ICA e NLICA) operam sempre sobre os sinais em anéis para a extração de características discriminantes e assim aumentar a eficiência dos classificadores. A estimação das características discriminantes dos anéis pode ser realizada de duas formas distintas conforme descrito a seguir.

Características Globais

Os sinais em anéis produzidos em todas as camadas do calorímetro podem ser justapostos em um único vetor de características (de 100 componentes). Este vetor é então utilizado como entrada para os algoritmos de aprendizado estatístico, este procedimento é ilustrado na Figura 6.1

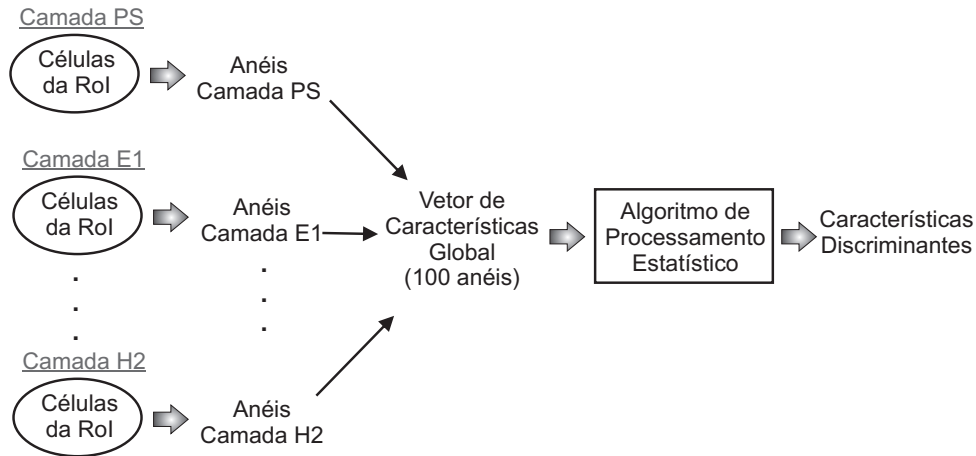


Figura 6.1: Processo de extração de características globais.

Características Segmentadas

Alternativamente, as características discriminantes podem ser estimadas separadamente para os anéis produzidos em cada camada do calorímetro. Este procedimento, em geral, produz resultados de mais fácil interpretação física pois sabe-se que cada camada do calorímetro possui características distintas como o tipo e a granularidade das células detectoras. A Figura 6.2 ilustra este procedimento.

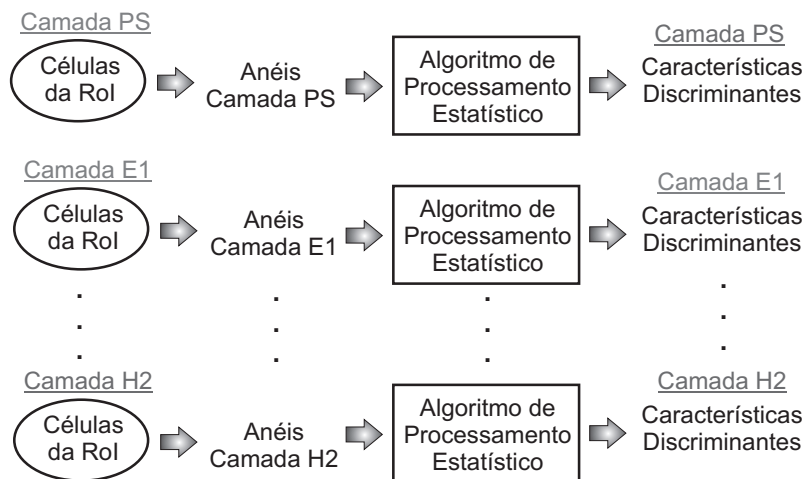


Figura 6.2: Processo de extração de características segmentadas.

6.1.1 Classificadores Neurais Supervisionados

Neste trabalho foram utilizados classificadores neurais tipo perceptrons de múltiplas camadas (MLP). Mais detalhes sobre classificação de sinais e a implementação de

classificadores neurais supervisionados podem ser encontrados no Apêndice B. Os classificadores, assim como os algoritmos de extração de características, podem ser aplicados de modo global e de modo segmentado.

Classificador Global

O classificador global opera sobre um conjunto de características discriminantes globais, produzindo a decisão elétron/jato. A Figura 6.3 ilustra a operação do classificador global.




Figura 6.3: Decisão utilizando classificador global.

Classificadores Segmentados

Considerando o sistema de calorímetros do detector ATLAS, a informação disponível está segmentada em diversas camadas com características físicas e granularidade diferentes. Para melhor explorar as características do detector, está sendo proposto o uso de um conjunto de classificadores neurais, cada um especialista na informação de uma camada do calorímetro (ver Figura 6.4).

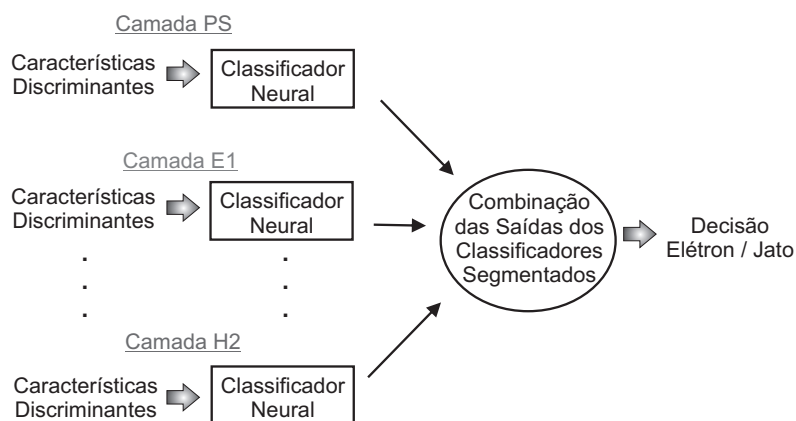


Figura 6.4: Decisão utilizando classificadores segmentados.

Um problema que surge na utilização de múltiplos classificadores segmentados é como combinar suas saídas para produzir da decisão final. Neste contexto, pode-se

utilizar as informações de dois modos, através dos rótulos de classe atribuídos por cada classificador ou utilizando-se a saída contínua (que no caso dos classificadores utilizados varia de -1 a 1).

6.1.2 Combinação de Múltiplos Classificadores

Quando estão disponíveis informações de múltiplos classificadores, surge o problema de como combiná-las de forma ótima. A depender do tipo de saída escolhida para os classificadores, sendo variáveis contínuas (com excursão de -1 a 1) ou variáveis discretas (rótulos de classe), a combinação pode ser realizada através de estratégias distintas [114].

Considerando K classificadores com saídas contínuas u_k , uma forma usualmente utilizada para combinação é a média das saídas:

$$\mu(\mathbf{x}) = \sum_{k=1}^K u_k(\mathbf{x}) \quad (6.1)$$

Considerando que os múltiplos classificadores apresentam eficiência diferente, pode-se dar aos mais eficientes maior poder de decisão com o uso de fatores de ponderação α_k :

$$\mu(\mathbf{x}) = \sum_{k=1}^K \alpha_k u_k(\mathbf{x}) \quad (6.2)$$

Outra forma para a combinação de classificadores de saídas contínuas u_k é o cálculo da média geométrica:

$$\mu(\mathbf{x}) = \sqrt[K]{\prod_{k=1}^K u_k(\mathbf{x})} \quad (6.3)$$

Alternativamente, considerando que a saída dos múltiplos classificadores é o rótulo de classe associado ao vetor de entrada \mathbf{x} , um método muito utilizado para combinação das informações é a votação da maioria [114]. Neste caso, também podem ser utilizados fatores de ponderação, caso as eficiências dos classificadores sejam diferentes. Deste modo, o voto de um classificador mais eficiente tem mais influência na decisão final.

Capítulo 7

Resultados

Os resultados apresentados neste trabalho foram obtidos a partir de dados simulados (utilizando simuladores de Monte Carlo para colisões próton-próton) e dados reais medidos no detector (sinais de raios cósmicos e também dos primeiros ciclos de operação do LHC). Neste capítulo, inicialmente, serão descritas as características das diversas bases de dados utilizadas. A seguir, os resultados obtidos através da aplicação das diversas técnicas de processamento de sinais propostas neste trabalho serão apresentados.

7.1 Resultados - Dados simulados / corte L1 do tipo E10 *loose*

7.2 Resultados - Dados simulados / corte L1 do tipo E15i

7.3 Resultados - Sinais de raios cósmicos

7.4 Resultados - Sinais Reais de Colisões do LHC

Referências Bibliográficas

- [1] ATLAS COLABORATION, “ATLAS Experiment at CERN Large Hadron Collider”, *Journal of Instrumentation*, v. 3, n. S08003, pp. 1–407, 2008.
- [2] HAUSER, R., “The ATLAS High Level Trigger System”. In: *Proceedings of the U.S. Atlas Computing Meeting*, v. 1, pp. 1–5, Upton, EUA, 2003.
- [3] EVANS, L., BRYANT, P., “LHC Machine”, *Journal of Instrumentation*, v. 3, n. S08001, pp. 1–158, 2008.
- [4] JOLLIFFE, I. T., *Principal Component Analysis*. 2nd ed. Springer: New York, US, 2002.
- [5] HYVARINEN, A., KARHUNEN, J., OJA, E., *Independent Component Analysis*. Wiley: New York, US, 2001.
- [6] HAYKIN, S., *Neural Networks and Learning Machines*. 3rd ed. Prentice Hall: New Jersey, US, 2008.
- [7] COMMITTEE ON ELEMENTARY PARTICLE PHYSICS IN THE 21ST CENTURY, N. R. C., *Revealing the Hidden Nature of Space and Time: Charting the Course for Elementary Particle Physics*. National Academic Press: Washington-DC, US, 2006.
- [8] ATLAS-COLLABORATION, *Letter of Intents for a General Purpose pp Experiment at the Large Hadron Collider at CERN*, Tech. rep., CERN, Geneva, Switzerland, October 1992.
- [9] ATLAS-COLLABORATION, “Experiment Overview”, Disponível em :<<http://www.atlas.ch/>>. Acesso em: 20 de março de 2007.

- [10] FERNOW, R. C., *Introduction to Experimental Particle Physics*. Cambridge University Press: Cambridge-UK, 1986.
- [11] MARTIN, B. R., *Nuclear and Particle Physics, An Introduction*. Wiley: West Sussex, UK, 2006.
- [12] CHUNG, K. C., *Introdução à Física Nuclear*. EdUERJ: Rio de Janeiro, 2001.
- [13] VELTMAN, M. J. G., *Facts and Mysteries in Elementary Particle Physics*. World Scientific: New Jersey, US, 2003.
- [14] ELLIS, R. K., STIRLING, W. J., WEBBER, B. R., *QCD and Collider Physics. Cambridge Monographs on Particle Physics, Nuclear Physics and Cosmology*, Cambridge University Press: Cambridge-UK, 2003.
- [15] PRICE, M., “The LHC project”, *Nuclear Instruments and Methods in Physics Research A*, v. 478, pp. 46–61, 2002.
- [16] CERN-COLABORATION, “CERN”, Disponível em :<<http://www.cern.ch/>>. Acesso em: 20 de março de 2007.
- [17] BERTONE, G., HOOPER, D., SILK, J., “Particle dark matter, evidence, candidates and constraints”, *Physics Reports*, v. 405, pp. 279–390, 2005.
- [18] LYKKEN, J. D., “Introduction to Supersymmetry”, Lectures at the Theoretical Advanced Study Institute (TASI 96):Fields, Strings, and Duality, June 1996.
- [19] BIGI, I., SANDA, A., *CP violation*. Cambridge University Press: Cambridge, UK, 1999.
- [20] DESY, “Deutsches Elektronen-SynchrotronDie”, Disponível em :<<http://www.desy.de/>>. Acesso em: 02 de julho de 2009.
- [21] KEK, “KEK High-Energy Accelerator”, Disponível em: <<http://www.kek.jp/>>. Acesso em: 02 de julho de 2009.
- [22] FERMILAB, “Fermi National Accelerator Laboratory”, Disponível em :<<http://www.fnal.gov/>>. Acesso em: 02 de julho de 2009.

- [23] SLAC, “SLAC Laboratory”, Disponível em: <http://www.slac.stanford.edu/>. Acesso em: 02 de julho de 2009.
- [24] BROOKHAVEN, “Brookhaven National Laboratory”, Disponível em: <http://www.bnl.gov/>. Acesso em: 02 de julho de 2009, 2009.
- [25] LHC-COLLABORATION, “Large Hadron Collider”, Disponível em: <http://lhc.web.cern.ch/lhc/>. Acesso em: 28 de março de 2007.
- [26] CMS COLLABORATION, “CMS Experiment at the CERN LHC”, *Journal of Instrumentation*, v. 3, n. S08004, pp. 1–334, 2008.
- [27] LHCb COLLABORATION, “LHCb Detector at the LHC”, *Journal of Instrumentation*, v. 3, n. S08005, pp. 1–205, 2008.
- [28] LHCf COLLABORATION, “LHCf Experiment at the CERN Large Hadron Collider”, *Journal of Instrumentation*, v. 3, n. S08006, pp. 1–36, 2008.
- [29] ALICE COLLABORATION, “ALICE Experiment at the CERN LHC”, *Journal of Instrumentation*, v. 3, n. S08002, pp. 1–245, 2008.
- [30] TOTEM COLLABORATION, “TOTEM Experiment at the CERN Large Hadron Collider”, *Journal of Instrumentation*, v. 3, n. S08007, pp. 1–107, 2008.
- [31] ROSSI, L., “The ATLAS tracking and vertexing detector”, *Nuclear Instruments and Methods in Physics Research Section A*, v. 580, n. 2, 2007.
- [32] PUZO, P., “ATLAS Calorimetry”, *Nuclear Instruments and Methods in Physics Research A*, v. 494, n. 1, pp. 340–345, 2002.
- [33] WIGMANS, R., *Calorimetry: Energy Measurement in Particle Physics*. Clarendon Press: Gloucestershire, UK, 2000.
- [34] PONTECORVO, L., “The ATLAS muon spectrometer”, *The European Physical Journal C - Particles and Fields*, v. 34, n. 1, 2004.
- [35] ATLAS-COLLABORATION, *ATLAS Detector and Physics Performance Technical Design Report, Volume 1*, Tech. rep., CERN, Geneva, Switzerland, May 1999.

- [36] ADRAGNA, ET AL., P., “The ATLAS Hadronic Tile Calorimeter: From Construction Toward Physics”, *IEEE Transactions on Nuclear Science*, v. 53, n. 5, pp. 1275–1281, June 2006.
- [37] DREES, J., “Review of final LEP results or a tribute to LEP”. In: *Proceedings of the International Symposium on Lepton and Photon Interactions at High Energies*, pp. 349–373, Roma, ItÁlia, Julho 2001.
- [38] KANE, G., PIERCE, A., (eds), *Perspectives on LHC Physics*. World Scientific: Singapore, 2008.
- [39] ATLAS-COLLABORATION, *ATLAS Detector and Physics Performance Technical Design Report, Volume 2*, Tech. rep., CERN, Geneva, Switzerland, May 1999.
- [40] WATTS, G., “Review of Triggering”. In: *Proceedings of the IEEE Nuclear Science Symposium and Medical Imaging Conference*, v. 1, pp. 282–287, Portland, EUA, October 2003.
- [41] VOLKER LINDENSTRUTH, I. K., “Overview of trigger systems”, *Nuclear Instruments and Methods in Physics Research A*, v. 535, n. 1, pp. 48–56, 2004.
- [42] RIU, I., ABOLINS, M., ET. AL, P. A., “Integration of the Trigger and Data Acquisition Systems in ATLAS”, *IEEE Transactions on Nuclear Science*, v. 55, n. 1, pp. 106–112, 2008.
- [43] SEEZ, C., “The CMS trigger system”, *The European Physical Journal C - Particles and Fields*, v. 34, n. 1, pp. 151–159, 2004.
- [44] ATLAS-COLLABORATION, *First-Level Trigger Technical Design Report*, Tech. rep., CERN, Geneva, Switzerland, June 1998.
- [45] ROBERT, C., CASELLA, G., *Monte Carlo Statistical Methods*. Springer-Verlag: New York, US, 2004.
- [46] ATLAS-COLLABORATION, *ATLAS High-Level Trigger, Data Acquisition and Controls Technical Design Report*, Tech. rep., CERN, Geneva, Switzerland, May 2003.

- [47] CERQUEIRA, A. S., CALÔBA, L. P., SEIXAS, J. M., “Analog System for Building the First-Level Triggering Signal Provided By the Hadronic Calorimeter of ATLAS Detector”, *Nuclear Instruments and Methods in Physics Research - A*, v. 570, n. 1, pp. 117–125, 2007.
- [48] DOS ANJOS, A., TORRES, R., SEIXAS, J., “Neural triggering system operating on high resolution calorimetry information”, *Nuclear Instruments and Methods in Physics Research A*, v. 559, n. 1, pp. 134–138, 2006.
- [49] LIMA JR., H., SEIXAS, J., “A segmented principal component analysis applied to calorimetry information at ATLAS”, *Nuclear Instruments and Methods in Physics Research A*, v. 559, n. 1, pp. 129–133, April 2006.
- [50] DOS ANJOS, A. R., *Sistema de filtragem online aplicada a um ambiente com alta taxa de eventos*, Ph.D. Thesis, COPPE/UFRJ, Dezembro 2006.
- [51] LINDSEY, C., DENBY, B., HAGGERTY, H., et al., “Real Time Track Finding with a VLSI Neural Network”, *Nuclear Instruments and Methods in Physics Research A*, v. A, n. 317, pp. 346–356, 1992.
- [52] DENBY, B., “Neural Networks in high-energy physics, a ten year perspective”, *Computer Physics Communications*, v. 1, n. 119, pp. 219–231, 1999.
- [53] NGUYET, T. T., “Searches for new physics by the H1 experiment at HERA”, *Acta Physica Polonica B Proceedings Supplement*, v. 1, n. 2, pp. 407–409, 2008.
- [54] KOLANOSKI, H., “Application of artificial neural networks in particle physics”, *Nuclear Instruments and Methods in Physics Research A*, v. 1, n. 367, pp. 14–20, 1995.
- [55] AKER, E., “The Crystal Barrel Spectrometer at LEAR”, *Nuclear Instruments and Methods in Physics Research A*, v. 321, n. 6, pp. 69–108, 1992.
- [56] DEGENER, T., “A Feed Forward Neural Network for Recognition of Fluctuations in Electromagnetic Showers”. In: *Proceedings of the International*

Workshop on Software Engineering, Artificial Intelligence and Expert Systems for High Energy and Nuclear Physics, v. 1, n. 1, pp. 1–11, Oberammergau, Germany, 1993.

- [57] WESTERHOFF, S., MEYER, H., “Neural nets as a tool for separating gamma and hadron induced Air Showers”. In: *Proceedings of the AIHENP*, v. 1, n. 1, pp. 1–8, Pisa, Italy, 1995.
- [58] CALOBA, L., SEIXAS, J., PEREIRA, F., “Neural Discriminating Analysis for a Second-Level Trigger System”. In: *Proceedings of the International Conference on Computing in High Energy Physics (CHEP95)*, Rio de Janeiro, Brazil, September 1995.
- [59] PRORIOL, J., “Selection of variables for neural network analysis. Comparison of several methods with high energy physics analysis”, *Nuclear Instruments and Methods in Research A*, v. 361, n. 3, pp. 581–585, 1995.
- [60] BUSSINO, S., MARI, M., “Gamma-hadron discrimination in extensive air showers using a neural network”, *Astroparticle Physics*, v. 1, n. 15, pp. 65–77, 2005.
- [61] WHITESON, S., WHITESON, D., “Machine learning for event selection in high energy physics”, *Engineering Applications of Artificial Intelligence*, v. 22, n. 8, pp. 1203–1217, 2009.
- [62] RIGGI, S., CARUSO, R., INSOLIA, A., et al., “A neural network approach to event-by-event cosmic ray primary mass identification”, *Proceedings of Science*, v. ACAT07, n. 035, pp. 1–13, 2007.
- [63] LANG, M. J., “Application of Kohonen network classifier in TeV gamma-ray astronomy”, *Journal of Physics G: Nuclear Particle Physics*, v. 1, n. 24, pp. 2279–2287, 1998.
- [64] BECKS, K. H., DRESS, J., FLAGMEYER, U., et al., “Separation of hadronic W-decays from QCD-background with self-organizing maps”, *Nuclear Instruments and Methods in Physics Research A*, v. 426, n. 2, pp. 599–604, 1999.

- [65] LANGE, J. S., “Transputer self-organizing map algorithm for beam background rejection at the BELLE silicaon vertex detector”, *Nuclear Instruments and Methods in Physics Research A*, v. 420, n. 1, pp. 288–309, 1999.
- [66] WYRZYKOWSKI, L., BELOKUROV, V., “Self-organizing maps, an application to the OGLE data and the Gaia Science Alerts”. In: *Proceedings of the International Conference on Classification and discovery in large astronomical surveys, AIP Conference Proceedings*, v. 1083, n. 1, pp. 201–206, Rinberg Castle, Germany, 2008.
- [67] HEIKKINEN, A., “Separation of Higgs boson signal from Drell-Yan background with self-organizing maps”, *Proceedins of Science*, v. ACAT07, n. 065, pp. 1–8, 2007.
- [68] PRORIOL, J., “Selection of variables for neural network analysis. Comparison of several methods with high-energy physics data”, *Nuclear Instruments and Methods in Physics Research A*, v. 361, n. 1, pp. 581–585, 1995.
- [69] WOLTER, M., “Multivariate Analysis Methods in Physics”, *Physics of Particles and Nuclei*, v. 38, n. 2, pp. 255–268, 2007.
- [70] AKRAS, S., BOUMIS, P., “A principal component analysis approach to the morphology of planetary nebulae”, *Astrophysics Journal*, v. 1, n. 1, pp. 1–8, 2007.
- [71] CADAVID, A. C., LAWRENCE, J. K., RUZMAIKIN, A., “Principal Components and Independent Component Analysis of Solar and Space Data”, *Solar Physics Journal*, v. 248, n. 2, pp. 247–261, 2008.
- [72] HUANG, X., LEE, S. Y., PREBYS, E., et al., “Application of independent component analysis to Fermilab BOOSTER”, *Physical Review Special Topics, Accelerators and Beams*, v. 8, n. 6, pp. 1–14, 2005.
- [73] FERNANDEZ, C., NAYERI, S., “Independent Component Analysis Applications in Physics”. In: *Proceedings of the Int. Joint Conference on Neural Networks*, v. 1, n. 1, pp. 2213–2216, Montreal, Canada, 2005.

- [74] COSTAGLIA, M., KURUOGLU, E. E., AHMED, A., “Astrophysical Source Separation using Particle Filters”, *Lecture Notes in Computer Science - Independent Component Analysis and Blind Signal Separation*, v. 3195, pp. 930–937, 2004.
- [75] IGUAL, J., LINHARES, R., SALAZAR, A., “Source Separation of Astrophysical Ice Mixtures”, *Lecture Notes in Computer Science - Independent Component Analysis and Blind Signal Separation*, v. 3889, pp. 368–375, 2006.
- [76] MOUDDEN, Y., ABRIAL, P., MELIN, J. B., et al., “Independent Component Separation from Incomplete Spherical Data using Wavelets. Application to CMB Data Analysis”. In: *Proceedings of the International Conference on Physics in Signal and Image Processing*, v. 1, pp. 1–6, Toulouse, France, 2005.
- [77] VIOO, R., ANDREANI, P., “A Modified ICA Approach for Signal Separation in CMB maps”, *Astronomy and Astrophysics Journal*, v. 802, pp. 1–12, February 2008.
- [78] KOHONEN, T., *Self Organizing Maps*. 3rd ed. Springer: Berlin, Germany, 2001.
- [79] BASE, A. M., GRUBER, P., THEISA, F., et al., “Blind source separation based on self-organizing neural network”, *Engineering Applications of Artificial Intelligence*, v. 19, n. 3, pp. 305–311, 2006.
- [80] OJA, E., “Neural Networks, Principal Components, and Subspaces”, *International Journal of Neural Systems*, v. 1, n. 1, pp. 61–68, 1989.
- [81] PAPOULIS, A., *Probability, Random Variables, and Stochastic Processes*. 3rd ed. McGraw-Hill: New York, US, 1991.
- [82] CICHOCKI, A., AMARI, S., *Adaptive Blind Signal and Image Processing*. John Wiley and Sons: West Sussex, UK, 2002.
- [83] HYVARINEN, A., OJA, E., “Independent Component Analysis: Algorithms and Applications”, *Neural Networks*, v. 13, n. 4-5, pp. 411–430, 2000.

- [84] JUTTEN, C., KARHUNEN, J., “Advances in Nonlinear Blind Source Separation”. In: *Proceedings of the 4th Int. Symp. on Independent Component Analysis and Blind Signal Separation*, v. 1, pp. 245–256, Nara, Japan, 2003.
- [85] ROJAS, F., PUNTONET, C. G., ROJAS, I., “Independent component analysis evolution based method for nonlinear speech processing”, *Artificial Neural Nets Problem Solving Methods, PT II*, v. 2687, pp. 679–686, 2003.
- [86] HARITOPOULOS, M., YIN, H., ALLINSON, N. M., “Image denoising using self-organizing map-based nonlinear independent component analysis”, *Neural Networks*, v. 15, n. 8-9, pp. 1085–1098, 2002.
- [87] TALEB, A., JUTTEN, C., “Source Separation in post-nonlinear mixtures”, *IEEE Transactions on Signal Processing*, v. 47, n. 10, pp. 2807–2820, 1999.
- [88] HYVARINEN, A., PAJUNEN, P., “Nonlinear Independent Component Analysis: Existence and Uniqueness results”, *Neural Networks*, v. 12, n. 3, pp. 429–439, 1999.
- [89] SOLAZZI, M., UNCINI, A., “Spline neural networks for blind separation of post-nonlinear-linear mixtures”, *IEEE Transactions on Circuits and Systems - I: Regular Papers*, v. 51, n. 4, pp. 817–829, 2004.
- [90] WOO, W. L., DLAY, S. S., “Nonlinear blind source separation using a hybrid RBF-FMLP network”, *IEE Proceedings on Vision, Image and Signal Processing*, v. 8, n. 2, pp. 173–183, 2005.
- [91] GAO, P., WOO, W., DLAY, S. S., “Neural network approaches to nonlinear blind source separation”. In: *Proceedings of the Eighth International Symposium on Signal Processing and Its Applications*, v. 1, pp. 78–81, Sydney, Australia, 2005.
- [92] GRIFFEL, D. H., *Applied Functional Analysis*. Dover: West Sussex, UK, 1985.
- [93] PAJUNEN, P., HYVARINEN, A., KARHUNEN, J., “Nonlinear blind source separation by self-organizing maps”. In: *Proceedings of the International*

Conference on Neural Information Processing, v. 1, pp. 1207–1210, Hong Kong, September 1996.

- [94] LAPPALAINEN, H., HONKELA, A., “Advances in Independent Component Analysis”, chap. Bayesian nonlinear independent component analysis by multi-layer perceptrons, pp. 93–121, Springer, 2000.
- [95] BISHOP, C. M., SVENSEN, M., WILLIAMS, C. K. I., “GTM: The generative topographic mapping”, *Neural Computation*, v. 10, pp. 215–234, 1998.
- [96] PAJUNEN, P., KARHUNEN, J., “A maximum likelihood approach to nonlinear blind source separation”. In: *Proceedings of the International Conference on Artificial Neural Networks*, v. 1, pp. 541–546, Lausanne, Switzerland, 1997.
- [97] LAPPALAINEN, H., “Ensemble learning for independent component analysis”. In: *Proceedings of the International Workshop on Independent Component Analysis and Blind Signal Separation*, v. 1, pp. 7–12, Aussois, France, 1999.
- [98] LAPPALAINEN, H., MISKIN, J. W., “Advances in Independent Component Analysis”, chap. Ensemble learning, pp. 75–92, Springer, 2000.
- [99] VALPOLA, H., “Nonlinear independent component analysis using ensemble learning: Theory”. In: *Proceedings of the International Workshop on Independent Component Analysis and Blind Signal Separation*, v. 1, pp. 351–356, Helsinki, Finland, 2000.
- [100] HONKELA, A., “Approximating nonlinear transformations of probability distributions for nonlinear independent component analysis”. In: *Proceedings of the IEEE International Joint Conference on Neural Networks*, v. 3, pp. 2169–2174, Budapest, Hungary, 2004.
- [101] HONKELA, A., VALPOLA, H., ILIN, A., et al., “Blind separation of nonlinear mixtures by variational bayesian learning”, *Digital Signal Processing*, v. 17, n. 5, pp. 914–934, 2007.

- [102] ILIN, A., ACHARD, S., JUTTEN, C., “Bayesian versus constrained structure approaches for source separation in post-nonlinear mixtures”. In: *Proceedings of the IEEE International Joint Conference on Neural Networks*, v. 3, pp. 2181–2186, Budapest, Hungary, July 2004.
- [103] KARHUNEN, J., MALAROIU, S., “Local independent component analysis using clustering”. In: *Proceedings of the International Workshop on Independent Component Analysis and Blind Signal Separation*, v. 1, pp. 1–6, Aussois, France, 1999.
- [104] DUDA, R. O., HART, P. E., STORK, D. G., *Pattern Classification*. 2nd ed. Wiley: New York, US, 2000.
- [105] KOHONEN, T., OJA, E., SIMULA, O., et al., “Engineering Applications of the Self-Organizing Map”, *Proceedings of the IEEE*, v. 84, n. 10, pp. 1358–1384, October 1996.
- [106] SIMAS FILHO, E. F., SEIXAS, J. M., CALOBA, L. P., “Segmented self-organized feature extraction for online filtering in a high event rate detector”. In: *Proceedings of the European Conference on Signal Processing*, v. 1, pp. 1–5, Lausanne, Switzerland, August 2008.
- [107] KARHUNEN, J., MALAROIU, S., ILMONIEMI, M., “Local linear independent component analysis based on clustering”, *International Journal of Neural Systems*, v. 10, pp. 439–451, 2000.
- [108] HONDA, K., ICHIHASHI, H., OHUE, M., et al., “Extraction of local independent components using fuzzy clustering”. In: *Proceedings of 6th International Conference on Neural Networks and Soft Computing*, v. 1, pp. 837–842, Zakopane, Poland, 2000.
- [109] MAENAKA, T., HONDA, K., ICHIHASHI, H., “Local independent component analysis with fuzzy clustering and regression-principal component analysis”. In: *Proceedings of IEEE International Conference on Fuzzy Systems*, v. 1, pp. 857–862, Vancouver, Canada, 2006.

- [110] PALMIERI, F., BUDILLON, A., “Advances in Independent Component Analysis”, chap. Multi-class independent component analysis for rank deficient distributions, pp. 145–160, Springer-Verlag, 2000.
- [111] LAN, T., ERDOGMUS, D., “Local Linear ICA for Mutual Information Estimation in Feature Selection”. In: *Proceedings of the IEEE Workshop on Machine Learning for Signal Processing*, v. 1, n. 1, pp. 3–8, Connecticut, USA, September 2005.
- [112] LAN, T., HUANG, Y., ERDOGMUS, D., “Independent Component Analysis and Blind Signal Separation”, v. 3889, chap. A Comparison of Linear ICA and Local Linear ICA for Mutual Information Based Feature Ranking, pp. 823–830, *Lecture Notes in Computer Science*, Springer, 2006.
- [113] COVER, T. M., THOMAS, J. A., *Elements of Information Theory*. Wiley: New York, US, 1991.
- [114] KUNCHEVA, L., *Combining Pattern Classifiers, Methods and Algorithms*. Wiley: New York, US, 2004.
- [115] GERSHO, A., “On the Structure of Vector Quantizers”, *IEEE Transactions on Information Theory*, v. 28, n. 2, pp. 157–166, March 1982.
- [116] GRAY, R. M., “Vector Quantization”, *IEEE ASSP Magazine*, v. Part 1, pp. 4–29, April 1984.
- [117] KOHONEN, T., “Improved versions of learning vector quantization”. In: *Proceedings of the International Joint Conference on Neural Networks*, v. 1, pp. 545–550, San Diego, US, 1990.
- [118] BARAS, J. S., DEY, S., “Combined Compression and Classification with Learning Vector Quantization”, *IEEE Transactions on Information Theory*, v. 45, n. 6, pp. 1911–1920, 1999.
- [119] FREEMAN, J. A., SKAPURA, D. M., *Neural Networks Algorithms, Applications, and Programming Techniques*. Addison Wesley, 1991.

- [120] PEEBLES JR., P. Z., *Probability, Random Variables and Random Signal Principles*. Mc Graw Hill: New York, US, 2001.
- [121] SPIEGEL, M. R., SCHILLER, J. J., SRINIVASAN, R. A., *Probability and Statistics*. 2nd ed. McGraw-Hill: New York, US, 2000.
- [122] SHANNON, C. E., “A Mathematical Theory of Communication”, *The Bell System Technical Journal*, v. 27, n. 6, pp. 379–423, July 1948.
- [123] HYVARINEN, A., “New approximations of diferencial entropy for independent component analysis and projection pursuit”, *Advances in Neural Information Signal Processing*, v. 10, pp. 273–279, 1998.
- [124] CICHOCKI, A., UNBEHAUEN, R., “Robust Neural Networks with On-Line Learning for Blind Identification and Blind Separation of Sources”, *IEEE Transactions on Circuits and Systems-I: Fundamental Theory and Applications*, v. 43, n. 11, November 1996.
- [125] CARDOSO, J.-F., SOULOUMIAC, A., “Blind Beamforming for Non-gaussian Signals”, *IEE Proceedings-F*, v. 140, n. 6, pp. 362–370, November 1993.
- [126] HYVARINEN, A., “Fast and Robust Fixed-Point Algorithms for Independent Component Analysis”, *IEEE Transactions on Neural Networks*, v. 10, n. 3, pp. 626–634, 1999.
- [127] LUENBERGER, D. G., *Linear and Nonlinear Programming*. Addison-Wesley: Boston, US, 1984.
- [128] MICHAL, A. D., *Matrix and Tensor Calculus*. 1st ed. Dover: West Sussex, UK, 2008.
- [129] CARDOSO, J. F., “Source separation using higher order moments”. In: *Proceedings of the IEEE Int. Conf. on Acoustics, Speech and Signal Processing*, v. 4, pp. 2109–2112, Glasgow, UK, 1989.
- [130] AKUZAWA, T., MURATA, N., “Multiplicative Nonholonomic Newton-like Algorithm”, *Chaos, Solitons and Fractals*, v. 12, n. 4, pp. 785–793, 2001.

- [131] AKUZAWA, T., “Extended Quasi-Newton Method for the ICA”. In: *Proceedings of the Int. Workshop Independent Component Anal. Blind Signal Separation*, pp. 521–525, Helsinki, Finland, 2000.
- [132] CUENCA, W. M., LEVY, A. F., SEIXAS, J. M., et al., “Análise de Componentes Independentes para Extração Cega de Ruídos Gaussianos dos Sinais de Descargas Parciais em Equipamentos de Alta Tensão”. In: *Anais do Congresso Brasileiro de Redes Neurais*, v. 1, pp. 133–138, São Paulo, 2003.
- [133] CICHOCKI, A., DOUGLAS, S., AMARI, S., “Robust techniques for independent component analysis with noisy data”, *Neurocomputing*, v. 22, n. 1-3, pp. 113–129, 1998.
- [134] HYVARINEN, A., “Independent Component Analysis in the Presence of Gaussian Noise by Maximizing Joint Likelihood”, *Neurocomputing*, v. 22, n. 1-3, pp. 49–67, 1998.
- [135] HYVARINEN, A., “Sparse Code Shrinkage: Denoising of Nongaussian Data by Maximum Likelihood Estimation”, *Neural Computation*, v. 11, n. 7, pp. 1739–1768, 1999.
- [136] PARASCHIV-IONESCU, A., JUTTEN, C., AMINIAN, K., et al., “Source separation in strong noisy mixtures a study of wavelet de-noising pre-processing”. In: *IEEE International Conference on Acoustics, Speech, and Signal Processing*, v. 2, pp. 1681–1684, Orlando, US, 2002.
- [137] TAN, Y., WANG, J., “Nonlinear Blind Source Separation using Higher Order Statistics and a Genetic Algorithm”, *IEEE Transactions on Evolutionary Computation*, v. 5, n. 6, pp. 600–612, 2001.
- [138] KAI, S., QI, W., MINGLI, D., “Approach to nonlinear blind source separation based on niche genetic algorithm”. In: *Proceedings of the Sixth International Conference on Intelligent Systems Design and Applications*, v. 1, pp. 441–445, Jinan, China, 2006.

- [139] GOLDBERG, D. E., *Genetic Algorithms in Search, Optimization and Machine Learning*. Addison-Wesley: Boston, US, 1989.
- [140] TAN, Y., WANG, J., “Nonlinear blind separation using an RBF network model”. In: *Proceedings of the IEEE International Symposium on Circuits and Systems*, v. 3, pp. 634–637, Geneva, Switzerland, 2000.
- [141] TREES, H. L. V., *Detection, Estimation, and Modulation Theory, Part I*. Wiley: New York, US, 2001.
- [142] SHANMUGAN, K. S., BREIPOHL, A. M., *Random Signals, Detection, Estimation and Data Analysis*. Wiley: New York, US, 1988.
- [143] FISHER, R. A., “The Use of Multiple Measurements in Taxonomic Problems”, *Annals of Eugenics*, v. 7, pp. 179–188, 1936.
- [144] SIMAS FILHO, E. F., ALMEIDA, L. A. L., LIMA, A. C. C., “Vibration Monitoring of On-Load Tap Changers Using a Genetic Algorithm”. In: *Proceedings of the IEEE Instrumentation and Measurement Technology Conference*, v. 3, pp. 2288–2293, Ottawa, Canada, 2005.
- [145] SIMAS FILHO, E. F., ALMEIDA, L. A. L., “Filtragem inversa de medições de histerese térmica utilizando Redes Neurais”. In: *Anais do XVI Congresso Brasileiro de Automática*, v. 1, pp. 1–6, Salvador, Brasil, Outubro 2006.
- [146] ZOPPOLI, R., PARISINI, T., SANGUINETI, M., “Neural Aproximators for Function Optimization”, *Proceedings of the 35th conference on decision and control*, v. 3, pp. 3290–3293, 1996.
- [147] ICHIKAWA, Y., SAWA, T., “Neural Networks Application for Direct Feedback Controllers”, *IEEE Transactions on Neural Networks*, v. 3, n. 2, pp. 224–231, 1992.
- [148] WASSERMAN, P., *Neural Computing, Theory and Practice*. Van Nostrand Reinhold: New York, US, 1989.

Apêndice A

Aspectos Teóricos das Técnicas de Extração de Características

Neste apêndice serão fornecidos os detalhes da teoria envolvida nos diversos métodos de extração de características utilizados neste trabalho.

A.1 Mapas auto-organizáveis

A.1.1 Quantização vetorial por aprendizado

A quantização vetorial (VQ - *Vector Quantization*) é uma técnica de codificação onde um espaço de entrada é mapeado em um grupo finito de vetores representativos (*codebook*) [115]. A codificação é definida como um particionamento do espaço de entrada em um número finito de regiões. O quantizador realiza um mapeamento do espaço \mathbb{R}^k , em um subconjunto finito Y de \mathbb{R}^k :

$$Q : \mathbb{R}^k \rightarrow \mathbf{Y} \quad (\text{A.1})$$

sendo $\mathbf{Y} = \{y_1, y_2, \dots, y_k\}$ o livro de código (*codebook*). Para cada palavra de código y_i existe uma partição R_i do espaço de entrada que satisfaz:

$$R_i = Q^{-1}(\mathbf{y}_i) = \{\mathbf{x} \in \mathbb{R}^k : Q(\mathbf{x}) = \mathbf{y}_i\} \quad (\text{A.2})$$

$$\bigcup_{i=1}^N R_i = \mathbb{R}^k, \quad R_i \cap R_j = \emptyset, \quad i \neq j \quad (\text{A.3})$$

Quando um quantizador vetorial possui mínima distorção é denominado **quantizador de Voronoi**. Neste caso, diz-se que o espaço de entrada está particionado de acordo com a regra do vizinho mais próximo, e as partições criadas são chamadas de células de Voronoi [116]. Usando-se a distância euclidiana como parâmetro de distorção, o quantizador Q^* é dito ótimo se, para qualquer outro quantizador Q , com o mesmo número de pontos, a condição abaixo é satisfeita:

$$E||\mathbf{x} - Q^*(\mathbf{x})||^2 \leq E||\mathbf{x} - Q(\mathbf{x})||^2 \quad (\text{A.4})$$

As palavras de código ou os vetores de Voronoi podem ser calculados de modo aproximado pelo algoritmo SOM. O *codebook* é formado a partir dos pesos sinápticos dos neurônios do mapa. As células de Voronoi são compostas pelos pontos do espaço de entrada que estão mais próximos do vetor de código correspondente.

Em um problema de classificação, pode-se empregar a quantização vetorial por aprendizado (*Learning Vector Quantization*) [117], que utiliza informações sobre as classes para mover ligeiramente os vetores de Voronoi, visando a uma melhora no desempenho de decisão do classificador.

Na sua forma básica, o algoritmo LVQ escolhe aleatoriamente um vetor de entrada \mathbf{x} ; quando seu rótulo de classe $\mathcal{C}_{\mathbf{x}_i}$ e o de um vetor de Voronoi \mathbf{w}_c concordam, então, \mathbf{w}_c é movido na direção de \mathbf{x} :

$$\mathcal{C}_{\mathbf{w}_c} = \mathcal{C}_{\mathbf{x}_i} \rightarrow \mathbf{w}_c(n+1) = \mathbf{w}_c(n) + \alpha[\mathbf{x} - \mathbf{w}_c(n)] \quad (\text{A.5})$$

onde α é a taxa de aprendizagem ($0 < \alpha < 1$). Em caso contrário, \mathbf{w} é afastado de \mathbf{x} :

$$\mathcal{C}_{\mathbf{w}_c} \neq \mathcal{C}_{\mathbf{x}_i} \rightarrow \mathbf{w}_c(n+1) = \mathbf{w}_c(n) - \alpha[\mathbf{x} - \mathbf{w}_c(n)] \quad (\text{A.6})$$

Conforme proposto em [117], podem ser implementadas algumas modificações na forma básica do algoritmo de LVQ, visando a melhorar o desempenho do método.

Chega-se, então, aos algoritmos LVQ-2 e LVQ-2.1, que ajustam dois vetores de código simultaneamente.

Alguns exemplos da aplicação da quantização vetorial por aprendizado para compressão de sinais e classificação podem ser encontrados em [117] e [118].

A.1.2 Classificação a partir do mapa de características

Considerando um problema de classificação, o mapeamento auto-organizável consegue transformar o conjunto de sinais, revelando características ocultas. A nova organização do conjunto de entrada pode ser utilizada para guiar o processo de discriminação. Em [119] é proposta uma estratégia de classificação a partir do mapa de características onde uma rede neural MLP é conectada às saídas do SOM (ver Figura A.1). A MLP é treinada com supervisão usando informações a respeito das classes de sinais.




Figura A.1: Diagrama da classificação a partir do mapa de características

A.2 Análise de Componentes Principais

A.2.1 Redução de dimensão

A principal aplicação da PCA é a compactação da informação. A redução de dimensão é obtida utilizando-se para a reconstrução do sinal original \mathbf{x} um número K de componentes principais sendo $K < N$. Na Figura A.2 é ilustrado o processo de redução de dimensão utilizando análise de componentes principais. Em geral, o número de componentes é escolhido visando a preservar uma parcela V_e da energia total, de modo que $\hat{\mathbf{x}} \approx \mathbf{x}$. A variância explicada V_e de um conjunto de componentes




Figura A.2: Compressão e recuperação do sinal \mathbf{x} utilizando a transformação por PCA.

pode ser calculada usando-se:

$$V_e(K) = \frac{\sum_{i=1}^K d_i}{\sum_{i=1}^N d_i}, \quad (\text{A.7})$$

sendo d_i o autovalor da matriz \mathbf{C}_x de covariância do processo correspondente à componente i .

A transformação por PCA é ótima no sentido de representação do sinal nas primeiras componentes, mas não há garantia de que a compactação facilite o processo de classificação. Quando as direções de maior variância coincidem com as de melhor discriminação das classes, então a PCA é também útil para o reconhecimento de padrões, em caso contrário, a redução de dimensão pode dificultar a separação. Entretanto, em problemas de classificação onde a dimensão da entrada é excessivamente grande o pré-processamento por PCA reduz o custo computacional e conseqüentemente o tempo de processamento.

A.3 Análise de Componentes Independentes

A.3.1 Princípios de estimação das componentes independentes

No modelo básico da ICA (ver equação (5.11)) assume-se que a matriz \mathbf{A} é quadrada e não são considerados os atrasos temporais nem a existência de ruído aditivo. O princípio básico para a extração das componentes independentes é obtido do teorema

do limite central. Como a soma de duas variáveis aleatórias independentes é sempre mais próxima de uma distribuição normal do que as variáveis originais, os sinais misturados x_i , que são gerados a partir do somatório ponderado das fontes s_i , têm distribuições de probabilidade mais semelhantes à Gaussiana quando comparadas aos sinais originais. As fontes podem ser obtidas então pela maximização da não-Gaussianidade.

Maximização da não-Gaussianidade

A **curtose** é o cumulante de quarta ordem, e para uma variável y de média zero e variância unitária é definida por [120]:

$$kurt(y) = \mathcal{E}\{y^4\} - 3(\mathcal{E}\{y^2\})^2. \quad (\text{A.8})$$

Variando no intervalo $[-2, \infty)$, a curtose é igual a zero para uma variável Gaussiana, os valores negativos indicam sub-Gaussianidade e os positivos super-Gaussianidade.

A curtose é um parâmetro estatístico facilmente calculado a partir das realizações da variável aleatória, porém seu valor pode ser bastante influenciado por um pequeno conjunto de pontos na cauda da distribuição [121], sendo, nesse caso, pouco robusta para a estimativa da não-Gaussianidade. Conhecidos como intrusos (ou *outliers*) esses pontos podem realmente pertencer à variável aleatória, ou ter sido artificialmente introduzidos por algum fenômeno desconhecido, como erro de medida ou de digitação.

Uma estimação alternativa da não-Gaussianidade pode ser obtida a partir da **negentropia**, que é calculada por [113]:

$$J(y) = H(y_{gauss}) - H(y), \quad (\text{A.9})$$

onde $H(\cdot)$ é a entropia, e y_{gauss} é uma variável aleatória Gaussiana com a mesma média e variância de y . A entropia é um dos conceitos básicos da teoria da informação e pode ser interpretada como o grau de informação contido em uma variável. Para uma variável aleatória discreta a entropia é definida como [122]:

$$H(Y) = - \sum_i P(Y = a_i) \log P(Y = a_i), \quad (\text{A.10})$$

onde os a_i são os possíveis valores da variável Y , e $P(Y = a_i)$ é a probabilidade de Y ser igual a a_i .

Um resultado importante obtido a partir da teoria da informação é que uma variável Gaussiana tem a máxima entropia entre todas as variáveis de mesma variância. Considerando a equação (A.9), a negentropia é sempre não negativa e zero quando a variável é Gaussiana, servindo como uma medição da não-Gaussianidade. O grande problema no cálculo de $J(\cdot)$ é a necessidade de se estimar as probabilidades da equação (A.10). Para evitar esse cálculo, utilizam-se aproximações da negentropia. Conforme descrito em [5], existem duas aproximações mais utilizadas para a negentropia, uma faz uso de cumulantes de ordem superior:

$$J(Y) \approx \frac{1}{12}E\{Y^3\}^2 + \frac{1}{48}kurt(Y)^2, \quad (\text{A.11})$$

e outra utiliza funções não-polinomiais [123]:

$$J(Y) \approx [k_1(E\{G_1(Y)\})^2 + k_2(E\{G_2(Y)\} - E\{G_2(\nu)\})^2], \quad (\text{A.12})$$

onde ν é uma variável aleatória Gaussiana de média zero e variância unitária. As funções não-lineares recomendadas em [123] são $G_1(y) = y \exp(-y^2/2)$ e $G_2(y) = |y|$ ou $G_2(y) = \exp(-y^2/2)$.

O uso de cumulantes traz de volta o problema da pouca robustez a *outliers*. É mostrado em [123] que o uso das funções não-polinomiais leva ao método da máxima entropia [5].

Minimização da informação mútua

Um outro método de estimação de ICA, também derivado da teoria da informação, é obtido pela minimização da informação mútua. A informação mútua $I(\cdot)$ entre m variáveis aleatórias escalares y_i é definida como [83]:

$$I(y_1, y_2, \dots, y_m) = \sum_{i=1}^m H(y_i) - H(\mathbf{y}) \quad (\text{A.13})$$

A entropia $H(y_i)$ pode ser interpretada como o comprimento de código (ou a quantidade de informação) necessário para representar a variável y_i . Conforme a equação (A.13), a informação mútua é a diferença entre o somatório das entropias

de cada uma das m variáveis y_i e a entropia do vetor aleatório $\mathbf{y} = [y_1, y_2, \dots, y_m]$. Pode-se provar que a codificação mais eficiente é obtida quando se utiliza o conjunto de variáveis \mathbf{y} . Utilizar as variáveis isoladamente sempre gera um maior código, menos quando as y_i são independentes, pois desta forma uma variável não carrega informação sobre as demais, sendo a informação mútua igual a zero. Desta forma, $I(y_1, y_2, \dots, y_m)$ pode ser utilizada como uma medida da dependência entre as variáveis. A matriz \mathbf{W} de transformação inversa da ICA, conforme equação 5.16, pode ser estimada através da minimização da informação mútua dos sinais s_i recuperados.

ICA através da decorrelação não linear

A igualdade da equação:

$$\mathcal{E}\{g(x)h(y)\} = \mathcal{E}\{g(x)\}\mathcal{E}\{h(y)\} \quad (\text{A.14})$$

repetida aqui para comodidade do leitor, garante que as variáveis x e y são independentes quando todas funções $g(\cdot)$ e $h(\cdot)$, integráveis em x e y são decorrelacionadas. Portanto, a extração das ICs pode ser obtida testando-se a correlação entre todas as funções não-lineares $g(\cdot)$ e $h(\cdot)$.

Existem alguns algoritmos propostos na literatura para o problema da decorrelação não-linear, como o *Hérault-Jutten* [5] e o *Chichocki-Unbehauen* [124], mas como não é possível testar a decorrelação entre todas as funções não-lineares, escolhem-se $f(\cdot)$ e $g(\cdot)$ visando-se a obter boas aproximações das componentes independentes. O algoritmo *Hérault-Jutten*, por exemplo, aconselha o uso de $f(y) = y^3$ e $g(y) = \arctg(y)$, já o *Chichocki-Unbehauen* sugere uma função polinomial e a tangente hiperbólica.

A PCA não-linear (NLPCA - *Non-linear Principal Component Analysis*) pode ser vista como uma extensão não linear da PCA, e é capaz de encontrar projeções decorrelacionadas não-linearmente. Enquanto o objetivo da PCA é minimizar o erro médio quadrático de reconstrução do sinal projetando as componentes numa base ortonormal, a NLPCA pode ser definida de modo simples através da função-

objetivo a ser minimizada:

$$J(\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n) = \mathcal{E}\left\{\left\|\mathbf{x} - \sum_{i=1}^n g_i(\mathbf{w}_i^T \mathbf{x}) \mathbf{w}_i\right\|^2\right\}, \quad (\text{A.15})$$

onde $g_1(\cdot), g_2(\cdot), \dots, g_n(\cdot)$ é um conjunto de funções escalares e não-lineares, e os vetores \mathbf{w}_i formam a base do sub-espço onde serão projetadas as entradas \mathbf{x} . Quando o mínimo de $J(\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n)$ for encontrado, o produto $\mathbf{w}_i^T \mathbf{x}$ dará as componentes principais não-lineares. Se $g_i(y) = y$ para todo i , então equação (A.15) se reduz à função objetivo da PCA. Quando os sinais satisfazem ao modelo da ICA, mostrado na equação (5.11), a NLPCA obtém uma aproximação das componentes independentes.

A.3.2 Pré-processamento dos sinais para ICA

Em geral, os algoritmos de extração das componentes independentes têm seu trabalho simplificado quando os sinais são centralizados, ou seja, têm sua média removida fazendo-se:

$$\mathbf{x} \leftarrow \mathbf{x} - \mathcal{E}\{\mathbf{x}\} \quad (\text{A.16})$$

Outra transformação importante é o branqueamento. Um vetor $\mathbf{z} = (z_1, z_2, \dots, z_n)^T$ é dito branco quando os elementos z_i são descorrelacionados e têm variância unitária. O branqueamento pode ser realizado por uma transformação linear:

$$\mathbf{z} = \mathbf{V}\mathbf{x} \quad (\text{A.17})$$

O branqueamento, que é apenas a descorrelação seguida de uma normalização, pode ser realizado por uma transformação através de PCA. Com as variáveis branqueadas a extração da ICA é facilitada, pois os sinais já estão descorrelacionados.

Em problemas com vetores de entrada de alta dimensão, é importante a compactação da informação através de PCA ou Análise de Relevância para facilitar o processo de extração das componentes independentes.

A.3.3 Principais algoritmos para ICA

Diversos algoritmos vêm sendo propostos para a extração das componentes independentes. Essas rotinas diferem basicamente no princípio teórico no qual fundamentam

a obtenção das componentes independentes (não-Gaussianidade, informação mútua, decorrelação não-linear, etc) e na forma fazem a otimização da função objetivo escolhida. Os principais parâmetros para avaliação de desempenho são o tempo de processamento (complexidade computacional) e a precisão na extração das componentes.

Um estudo comparativo entre diversos métodos de estimação das componentes independentes foi realizado em [5]. O algoritmo **FastICA**, descrito com detalhes em [5] e [83], é o que apresenta menor custo computacional. Algoritmos que realizam decorrelação não linear e NLPCA têm desempenho semelhante ao FastICA em termos da precisão na obtenção da matriz \mathbf{W} , porém exigem maior esforço de computação. O algoritmo **JADE** (*Joint Approximate Diagonalization of Eigenmatrices*) proposto em [125] também é muito utilizado em ICA, mostrando bons resultados.

Algoritmo FastICA

Considerando as aproximações da negentropia mostradas nas Equações (A.11) e (A.12), e o fato de que a minimização da negentropia leva à independência estatística, no trabalho [126] foram propostos algoritmos de ponto fixo para ICA (chamados FastICA), que utilizam iterações semelhantes às de Newton [127]. Entre as vantagens deste algoritmo pode-se citar simplicidade computacional, baixa utilização de memória e boas características de convergência [83].

A partir de algumas manipulações da equação (A.12), o algoritmo FastICA para estimação de uma componente independente é formulado a seguir para sinais pré-branqueados:

1. Escolha um vetor de pesos inicial \mathbf{w} de modo aleatório;
2. Faça $\mathbf{w}^+ = E\{\mathbf{x}g(\mathbf{w}^T\mathbf{x})\} - E\{g'(\mathbf{w}^T\mathbf{x})\}\mathbf{w}$;
3. $\mathbf{w} = \mathbf{w}^+ / \|\mathbf{w}^+\|$;
4. Se o algoritmo não tiver convergido voltar para o passo 2.

Os autores sugerem o uso de uma das funções $g(\cdot)$ a seguir:

$$g_1(x) = \text{tgh}(a_1 x), \quad (\text{A.18})$$

$$g_2(x) = x \exp(-a_2 x^2/2), \quad (\text{A.19})$$

$$g_3(x) = x^3, \quad (\text{A.20})$$

onde $1 \leq a_1 \leq 2$ e $a_2 \approx 1$. A escolha da função não-linear pode ser guiada pelas características a seguir [126]: a função $g_1(\cdot)$ é indicada quando não há informação a respeito da estatística das componentes independentes, pois o algoritmo apresenta resultados satisfatórios para qualquer tipo de distribuição; o uso de $g_2(\cdot)$ é indicado quando as componentes independentes são super-Gaussianas e o $g_3(\cdot)$ deve ser utilizada para estimar componentes sub-Gaussianas.

Para estimar mais de uma componente independente pode-se utilizar métodos de ortogonalização deflacionária como o de Gram-Schmidt [5].

Algoritmo JADE

No algoritmo JADE (*Joint Approximate Diagonalization of Eigenmatrices*), as informações estatísticas de segunda e quarta ordem são utilizadas a partir de uma abordagem tensorial. Tensores [128] são generalizações de alta-dimensão das matrizes. O tensor cumulante de quarta ordem \mathbf{T}_4 é uma “matriz” de quatro dimensões onde cada elemento é definido por $q_{ijkl} = \text{cum}(x_i, x_j, x_k, x_l)$, os índices i, j, k e l variam de 1 até N (onde N é o número de sinais) e $\text{cum}(x_i, x_j, x_k, x_l)$ é o cumulante de quarta ordem:

$$\begin{aligned} \text{cum}(x_i, x_j, x_k, x_l) = & E\{x_i, x_j, x_k, x_l\} - E\{x_i, x_j\}E\{x_k, x_l\} \\ & - E\{x_i, x_k\}E\{x_j, x_l\} - E\{x_k, x_j\}E\{x_i, x_l\} \end{aligned} \quad (\text{A.21})$$

Sabe-se que a diagonalização da matriz de correlação (\mathbf{C}_y) produz a decorrelação entre os componentes de \mathbf{y} [5]. Para sinais independentes, apenas quando $i=k=j=l$ os cumulantes de quarta-ordem são diferentes de zero. Considerando isso, os métodos Tensoriais de ICA propõe a diagonalização de \mathbf{T}_4 para alcançar a independência estatística [125].

Embora teoricamente simples, a utilização de métodos tensoriais de ICA exigem uma grande quantidade de recursos computacionais para a decomposição em auto-valores de matrizes de quarta-ordem. O algoritmo JADE propõe um método

aproximado para a diagonalização de \mathbf{T}_4 , se tornando mais leve computacionalmente.

Considerando que os dados satisfazem o modelo da ICA para dados pré-branqueados, pode-se escrever:

$$\mathbf{z} = \mathbf{V}\mathbf{A}\mathbf{s} = \mathbf{W}^T\mathbf{s} \quad (\text{A.22})$$

onde $\mathbf{x} = \mathbf{A}\mathbf{s}$ são os sinais observados, \mathbf{V} é a matriz de branqueamento e $\mathbf{W}^T = \mathbf{V}\mathbf{A}$ é a matriz de misturas branqueada. Neste caso, pode-se provar (ver [5] que o tensor cumulante de \mathbf{z} tem uma estrutura especial e suas auto-matrizes são descritas por:

$$\mathbf{M} = \mathbf{w}_m\mathbf{w}_m^T \quad (\text{A.23})$$

onde $m=1,\dots,N$ e w_n são as colunas da matriz \mathbf{W}^T

O algoritmo JADE utiliza a transformação linear F_{ij} da matriz \mathbf{M} definida por:

$$F_{i,j}(\mathbf{M}) = \sum m_{kl}\text{cum}(x_i, x_j, x_k, x_l) \quad (\text{A.24})$$

onde m_{kl} é um elemento da matriz \mathbf{M} .

A decomposição em autovalores é vista como um processo de diagonalização, então busca-se a matriz \mathbf{W} que diagonaliza $F(\mathbf{M})$ para qualquer \mathbf{M} (ou seja, $\mathbf{Q} = \mathbf{W}F(\mathbf{M}_i)\mathbf{W}^T$ é uma matriz diagonal).

A função custo do método JADE busca a diagonalização de \mathbf{Q} pela maximização da soma dos elementos de sua diagonal. As matrizes \mathbf{M}_i utilizadas são as automatrizes do tensor cumulante dos dados, pois assim tem-se um conjunto de N matrizes que contém toda a informação relevante a respeito dos cumulantes.

Os métodos tensoriais [129, 125] foram, provavelmente, a primeira classe de algoritmos capazes de executar a ICA de modo realmente eficiente [5]. Atualmente, estes métodos são mais utilizados para sinais de baixa dimensão, pois o custo computacional aumenta rapidamente com o número de componentes a serem estimados.

Algoritmo Multiplicativo com Iteração de Newton

Um algoritmo multiplicativo para ICA foi proposto por Akuzawa e Murata em [130]. Usando a curtose como função para avaliar a independência, esse algoritmo utiliza estratégia de otimização de segunda ordem, através do método de Newton [127], para estimar as componentes independentes.

O algoritmo proposto por Akuzawa não requer pré-branqueamento, operando diretamente sobre os dados medidos. Resultados experimentais obtidos em [131, 132] indicam que o algoritmo de Akuzawa apresenta melhor desempenho que FastICA e JADE quando os sinais estão contaminados por ruído Gaussiano.

Considerando a transformação linear $\mathbf{Y} = \mathbf{CX}$, o objetivo do algoritmo de Akuzawa é encontrar a matriz \mathbf{C} que maximiza a independência entre as componentes de \mathbf{y} . Os passos a seguir são executados durante as iterações:

1. Escolher C_0 (a matriz de separação inicial) e a matriz Δ_0 ($N \times N$);
2. Calcular a iteração $C_t = \exp(\Delta_t - 1)C_{t-1}$;
3. Avalie a função custo em C_t usando uma expansão de segunda ordem em torno de C_{t-1} ;
4. Δ_t é escolhido como o ponto de sela da função custo;
5. Retorne para o passo 2 até convergir.

Mais detalhes a respeito da execução do passo 4 podem ser encontradas em [130]. Modificações no método de Akuzawa foram propostos em [131] com o objetivo de reduzir o custo computacional pela substituição das iterações de Newton pelo método quasi-Newton [127].

Comparado com FastICA e JADE, o algoritmo multiplicativo de Akuzawa é mais lento (mesmo em sua versão modificada que utiliza o método de otimização quasi-Newton), suas vantagens aparecem quando o nível de ruído aumenta, neste caso o método de Akuzawa apresenta melhores resultados.

A.3.4 Extensões ao modelo básico de ICA

A análise de componentes independentes em sua formulação básica mostrada nas equações (5.11) e (5.16) é empregada com sucesso em uma grande variedade de aplicações. O modelo básico de ICA não considera que os sinais podem estar contaminados por ruído aditivo, ou que o sinal misturado seja gerado de forma não-linear. No ambiente do calorímetro do ATLAS, o ruído estará presente nas células absorvedoras de energia, e por características de construção do sistema, transformações não-lineares dos sinais poderão estar presentes.

ICA para sinais ruidosos

Sabe-se que os sinais reais no ambiente do calorímetro do ATLAS estarão contaminados por ruído. A formulação básica da ICA, mostrada na equação (5.11), não considera a presença de ruído. Um modelo mais realista permite a obtenção do modelo da ICA para sinais ruidosos (*Noisy ICA*) [5]:

$$\mathbf{x} = \mathbf{A}\mathbf{s} + \mathbf{n}, \quad (\text{A.25})$$

onde $\mathbf{n} = (n_1, n_2, \dots)$ é o vetor de ruído. Em geral, considera-se que o ruído é gaussiano e independente das componentes independentes. Assume-se também que a matriz de covariância do ruído $\Sigma = \sigma^2 I$ é conhecida.

A equação (A.25) pode ser associada a ruído de sensores, uma vez que o ruído n_i é adicionado separadamente a cada fonte x_i . O ruído de fonte, que é adicionado às componentes independentes s_i é representado pela equação a seguir:

$$\mathbf{x} = \mathbf{A}(\mathbf{s} + \mathbf{n}) \quad (\text{A.26})$$

Um caso especial que pode simplificar bastante o problema de estimação das componentes independentes em ambiente ruidoso acontece quando existem poucas fontes de ruído. Se o número total de componentes de ruído é menor que o de componentes independentes, o modelo básico da ICA pode ser adaptado. Define-se o vetor $\tilde{\mathbf{s}} = (s_1, \dots, s_k, n_1, \dots, n_l)^T$, onde s_i ($i = 1, \dots, k$) são as componentes independentes e n_j ($j = 1, \dots, l$) são as fontes de ruído. Assumindo-se que o número de misturas é $k + l$, então o modelo básico da ICA pode ser aplicado a $x = A\tilde{s}$ e usando-se um algoritmo deflacionário consegue-se estimar as k componentes menos gaussianas, que são as próprias ICs.

Na maioria das vezes, deseja-se considerar que o ruído foi adicionado a cada uma das misturas; assim, $k + l$ é maior que o número de misturas, e o modelo básico da ICA não pode ser aplicado ao vetor $\tilde{\mathbf{s}}$.

O processo de estimação das componentes independentes já é bastante difícil na formulação básica, e quando o ruído é considerado o cenário piora consideravelmente. Nos modelos das equações (A.25) e (A.26) pode-se verificar que as ICs não são obtidas apenas com a inversão da matriz de mistura \mathbf{W} :

$$\mathbf{W}\mathbf{x} = \mathbf{s} + \mathbf{W}\mathbf{n} \quad (\text{A.27})$$

A solução do problema da equação (A.27) envolve duas etapas: o uso de métodos de otimização numérica para obter uma aproximação do ruído e, a partir de então, a estimação das componentes independentes. Em uma abordagem mais simples e que parece ser a mais promissora para o *noisy ICA*, são utilizadas técnicas de remoção de tendência para reduzir os efeitos do ruído, adaptando-se os métodos básicos de ICA para o caso ruidoso [133].

O algoritmo FastICA pode ser adaptado para sinais contaminados por ruído usando medidas não tendenciosas da Gaussianidade [134]:

$$\mathbf{w}^* = E\{\tilde{\mathbf{x}}g(\mathbf{w}^T)\tilde{\mathbf{x}}\} - (I + \tilde{\Sigma})\mathbf{w}E\{g'(\mathbf{w}^T\tilde{\mathbf{x}})\}, \quad (\text{A.28})$$

sendo que a norma do novo valor \mathbf{w}^* é tornada unitária após cada iteração, e $\tilde{\Sigma}$ é dado por:

$$\tilde{\Sigma} = E\{\tilde{\mathbf{n}}\tilde{\mathbf{n}}^T\} = (\mathbf{C} - \Sigma)^{-1/2}\Sigma(\mathbf{C} - \Sigma)^{-1/2} \quad (\text{A.29})$$

onde $\mathbf{C} = E\{\mathbf{x}\mathbf{x}^T\}$ é a matriz de covariância dos sinais ruidosos observados. A função $g(\cdot)$ pode ser escolhida entre as abaixo:

Outras técnicas como o “encolhimento de código esparsa” (*Sparse Code Shrinkage*) [135] também são utilizadas para a extração das componentes independentes para sinais ruidosos. Em casos onde o nível de ruído é muito alto, pode-se tentar o uso de técnicas de processamento de sinais como *wavelets* ou filtragem adaptativa [136].

A.4 ICA não-linear

Conforme mostrado no Capítulo ??, o modelo da ICA não-linear (NLICA) apresenta uma formulação mais geral que o linear. A seguir será mostrado o desenvolvimento teórico de um algoritmo para a estimação das componentes independentes no modelo pós não-linear.

A.4.1 Algoritmo Taleb-Jutten para o modelo PNL

Um dos primeiros algoritmos para o modelo pós não-linear da ICA foi proposto por Taleb e Jutten no trabalho [87]. Este algoritmo é robusto a variações na distribuição de probabilidade das fontes, pois executa estimação iterativa da estatística das componentes independentes estimadas através do cálculo da função escore:

$$\psi = p'_{Y_i}(u)/p_{Y_i}(u), \quad (\text{A.30})$$

conforme Figura A.3.

Cada função não-linear g_k ($k=1,\dots,N$) é modelado por redes MLP com um neurônio linear na saída:

$$g_k(u) = \sum_{h=1}^{N_H} \xi^h \sigma(\omega^h u - \eta^h), \quad (\text{A.31})$$

onde N_H é o número de neurônios ocultos. A divergência de Kullback-Lieber é utilizada para encontrar as regras de aprendizado para a estimação das funções não-lineares [87].

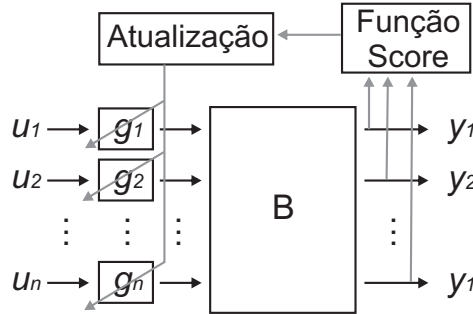


Figura A.3: Diagrama do algoritmo de Taleb-Jutten para o modelo PNL.

Como existem vários parâmetros a serem ajustados no modelo inverso proposto e a otimização envolve funções não-lineares, o algoritmo pode apresentar problemas de convergência para mínimos locais [84]. Diferentes procedimentos foram propostos na literatura para melhorar a eficiência de estimação em modelos PNL. Em [137, 138] um algoritmo genético [139] foi utilizado para executar uma busca global, evitando o problema dos mínimos locais. O problema com esta abordagem é o aumento do custo computacional.

Redes neurais com arquiteturas alternativas também foram aplicadas com sucesso na separação de misturas PNL. Por exemplo, em [140] funções de base

radial (RBF - *Radial Basis Function*). Em um outro trabalho [89], a separação foi realizada por redes neurais com funções de ativação do tipo *spline*.

Apêndice B

Conceitos fundamentais em classificação de sinais

A seguir serão mostrados os fundamentos teóricos de algumas técnicas de classificação de padrões, iniciando-se com uma visão geral do problema de decisão binária. Serão apresentadas técnicas lineares como Filtros Casados e Análise de Discriminantes, e não-lineares, como Redes Neurais.

B.1 Teste de Hipóteses

Considerando-se inicialmente a discriminação entre duas hipóteses H_1 e H_0 , o problema de classificação pode ser resumido pelo esquema da Figura B.1. A fonte gera as saídas, que após passarem por um meio probabilístico, precisam ser detectadas a partir das observações do processo. As regras de decisão, que formam o sistema classificador, são projetadas para maximizar a probabilidade de detecção correta.

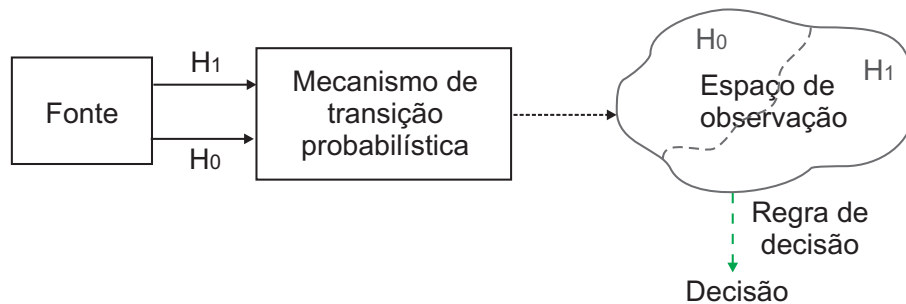


Figura B.1: Esquemático do problema de classificação binário.

No caso da decisão binária, cada vez que uma observação é efetuada 4 situações podem ocorrer:

- decidir pela hipótese H_1 , sendo H_0 verdadeira;
- decidir pela hipótese H_0 , sendo H_1 verdadeira;
- decidir pela hipótese H_1 , sendo H_1 verdadeira;
- decidir pela hipótese H_0 , sendo H_0 verdadeira.

As duas primeiras são erros de decisão e as duas últimas classificações corretas. Cada uma das hipóteses é associada a uma saída da fonte, que é mapeada em uma região do espaço de observação. Considerando um espaço de observação de dimensão N finita, um ponto neste espaço pode ser representado por um vetor:

$$\mathbf{r} = [r_1, r_2, \dots, r_N]. \quad (\text{B.1})$$

O mecanismo de transição probabilística gera pontos de acordo com as densidades de probabilidade condicionais $P_{\mathbf{r}/H_0}(\mathbf{R}/H_0)$ e $P_{\mathbf{r}/H_1}(\mathbf{R}/H_1)$. Quando essas probabilidades são conhecidas ou podem ser estimadas de alguma forma, o projeto do sistema classificador pode ser simplificado. Os critérios de *Bayes* e *Neyman-Pearson* são procedimentos clássicos utilizados para a escolha da regra de decisão.

B.2 Critério de Bayes

O critério de *Bayes* necessita do conhecimento das probabilidades a priori P_1 e P_0 de a fonte produzir H_1 ou H_0 , das probabilidades condicionais $P_{\mathbf{r}/H_0}(\mathbf{R}/H_0)$ e $P_{\mathbf{r}/H_1}(\mathbf{R}/H_1)$ e dos custos C_{ij} associados à escolha da hipótese i sendo j a verdadeira. O risco é, então, definido como [141]:

$$\begin{aligned} \mathfrak{R} = & C_{00}P_0 \int_{Z_0} P_{\mathbf{r}/H_0}(\mathbf{R}/H_0)d\mathbf{R} \\ & + C_{10}P_0 \int_{Z_1} P_{\mathbf{r}/H_0}(\mathbf{R}/H_0)d\mathbf{R} \\ & + C_{11}P_1 \int_{Z_1} P_{\mathbf{r}/H_1}(\mathbf{R}/H_1)d\mathbf{R} \\ & + C_{01}P_1 \int_{Z_0} P_{\mathbf{r}/H_1}(\mathbf{R}/H_1)d\mathbf{R} \end{aligned}, \quad (\text{B.2})$$

onde os elementos do espaço de observação que pertencem às partições Z_0 e Z_1 são associados, respectivamente, a H_0 e H_1 . As variáveis C_{ij} representam o custo da

escolha da hipótese i quando a hipótese verdadeira é a j . Em geral assume-se que o custo de uma decisão errada (C_{ij} sendo $i \neq j$) é maior do que o de um acerto (C_{ij} sendo $i = j$).

Minimizando o risco \mathfrak{R} da equação (B.2) chega-se a [141]:

$$\frac{P_{\mathbf{r}/H_1}(\mathbf{R}/H_1)}{P_{\mathbf{r}/H_0}(\mathbf{R}/H_0)} \underset{H_0}{\overset{H_1}{\geq}} \frac{P_0(C_{10} - C_{00})}{P_1(C_{01} - C_{11})}, \quad (\text{B.3})$$

a expressão à esquerda é chamada razão de semelhança ($\Lambda(\mathbf{R})$) e a fração à direita é o valor limiar (patamar) do teste (κ). Com isso, a equação (B.3) se reduz a:

$$\Lambda(\mathbf{R}) \underset{H_0}{\overset{H_1}{\geq}} \kappa; \quad (\text{B.4})$$

então, se a razão de semelhança é maior que o patamar, decide-se por H_1 , caso contrário, escolhe-se H_0 .

Quando os custos não são conhecidos, pode-se adotar o critério *minimax*, que minimiza o risco máximo; após algumas considerações chega-se a:

$$\begin{aligned} C_{00} &= C_{11} = 0 \\ C_{01}P_M &= C_{10}P_F \end{aligned}, \quad (\text{B.5})$$

onde $P_F = \int_{Z_1} P_{\mathbf{r}/H_0}(\mathbf{R}/H_0)d\mathbf{R}$ é a probabilidade de falso-alarme (terminologia usada em sistemas de radar, indicando que decidiu-se pela presença do alvo H_1 estando o mesmo ausente) e $P_M = \int_{Z_0} P_{\mathbf{r}/H_1}(\mathbf{R}/H_1)d\mathbf{R}$ é a probabilidade de perda do alvo.

O teste de *Neyman-Pearson* [142] é utilizado quando não se tem informações sobre os custos ou as probabilidades a priori. Escolhe-se um valor limite para a probabilidade de falso-alarme e procura-se minimizar a probabilidade de perda do alvo para o valor escolhido. Como o critério utiliza P_F e P_M é preciso conhecer as probabilidades condicionais $P_{\mathbf{r}/H_0}(\mathbf{R}/H_0)$ e $P_{\mathbf{r}/H_1}(\mathbf{R}/H_1)$.

B.3 Filtros Casados

Quando o processo de detecção é realizado em ambiente ruidoso o desempenho dos classificadores decai bastante. Os filtros casados são utilizados em processos de

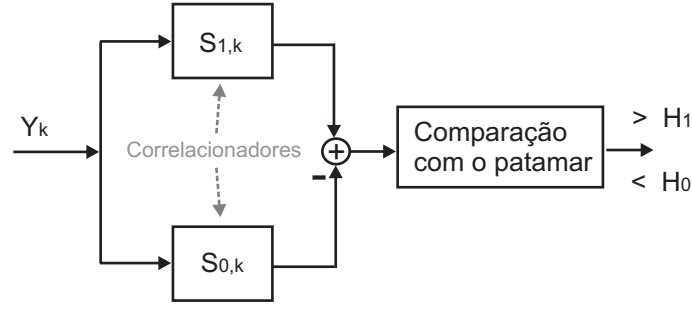


Figura B.2: Diagrama em blocos de um filtro casado.

detecção onde as formas de onda dos sinais corrompidos por ruído são conhecidas. Os filtros casados maximizam a razão sinal-ruído em ambiente de ruído branco. Um processo estocástico é dito branco quando sua densidade espectral de potência $S(\omega)$ é constante em todas as frequências [120]:

$$S(\omega) = N_0/2 \quad (\text{B.6})$$

A autocorrelação do processo branco, calculada a partir da transformada de Fourier inversa de $S(\omega)$ é $R_{xx} = N_0/2\delta(t)$, ou seja, o ruído branco tem correlação nula com qualquer cópia deslocada dele mesmo.

No caso de sinais digitais, conforme mostrado na Figura B.2, o filtro casado é implementado através do cálculo da correlação do sinal recebido $y[k]$ com as formas de ondas esperadas $s_1[k]$ e $s_0[k]$. As saídas dos correlacionadores são subtraídas e comparadas com um patamar de decisão; se o valor for maior que o patamar decide-se por H_1 , caso contrário por H_0 .

Se o ruído de fundo não for branco, o desempenho dos filtros cai bastante. Esse problema é minimizado se o ruído é conhecido. Pode-se, então, projetar um filtro branqueador. A desvantagem do branqueador é que ele atua também sobre o sinal, alterando suas características estatísticas.

Embora muito utilizadas, por sua formulação matemática relativamente simples e bom desempenho em diversas aplicações, as técnicas mostradas até aqui apresentam as desvantagens de necessitarem conhecimento prévio a respeito das distribuições de probabilidade, custos ou forma de onda dos sinais de entrada. Em muitos casos práticos essas informações não estão disponíveis, sendo necessária a utilização de outros métodos de classificação. Além disso, o desempenho dessas técnicas piora

bastante em ambiente de ruído colorido e também quando as classes estão muito sobrepostas.

B.4 Discriminante linear de Fisher

A análise de discriminantes busca a direção \mathbf{w} onde as projeções \mathbf{y} dos sinais de entrada \mathbf{x} sejam maximamente separáveis. A análise por discriminante de Fisher (FDA - *Fisher Discriminant Analysis*) busca a direção ótima de discriminação utilizando 2 parâmetros: a distância inter-classes, e a distância intra-classes [143].

Numa formulação matricial o objetivo é encontrar a direção \mathbf{w}_0 que maximiza a expressão:

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}} \quad (\text{B.7})$$

onde \mathbf{m}_i é a média da classe i , $\mathbf{S}_B = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T$ é a matriz de separação inter-classes e $\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2$ é a matriz de separação intra-classes, sendo:

$$\mathbf{S}_i = \sum_{\mathbf{x} \in \mathcal{D}_i} (\mathbf{x} - \mathbf{m}_i)(\mathbf{x} - \mathbf{m}_i)^T \quad (\text{B.8})$$

Pode-se provar que a direção ótima que maximiza (B.7) é dada por [104]:

$$\mathbf{w} = \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) \quad (\text{B.9})$$

O discriminante de Fisher é capaz de encontrar a transformação linear ótima dos sinais de entrada de modo que os sinais projetados $\mathbf{y} = \mathbf{w}^T \mathbf{x}$ tenham máxima separação. Pode-se realizar a análise por discriminante de Fisher de modo analítico usando-se as equações (B.7), (B.8) e (B.9), ou de modo iterativo a partir de uma rede neural de uma camada.

B.5 Classificadores Neurais

As redes neurais artificiais (RNA) [6] são modelos matemáticos que emulam algumas características do cérebro humano, sendo capazes de adquirir conhecimento (aprender) e generalizar (responder corretamente a estímulos novos). Devido ao poder computacional, obtido de sua estrutura paralelamente distribuída, e às habilidades

de aprender e generalizar, as RNAs vêm sendo utilizadas em diversas aplicações como reconhecimento de padrões e classificação [144], processamento de sinais [145], aproximação de funções [146], controle e identificação de sistemas [147]. A seguir serão descritos os fundamentos matemáticos das redes neurais e sua aplicação como classificadores. Maior ênfase será dada às redes alimentadas adiante (*feedforward neural networks*) com treinamento supervisionado. Os livros [6] e [148] fornecem textos mais abrangentes sobre assunto.

Uma diferença fundamental entre os classificadores neurais e os métodos clássicos como os filtros casados é que nestes últimos é necessário formular um modelo matemático a partir dos sinais. Na abordagem neural, o classificador trabalha diretamente no conjunto de dados, ficando o modelo matemático implícito nos valores dos pesos sinápticos obtidos após o treinamento. Os classificadores neurais têm obtido resultados bastante animadores em problemas para os quais métodos clássicos não apresentam bom desempenho.




Figura B.3: Exemplo de uma rede neural utilizada para separação dos sinais de entrada em 3 classes.

Para o projeto do classificador neural dividem-se os pares entrada saída disponíveis nos conjuntos de treino, teste e validação. A divisão é importante para garantir que a rede treinada consiga generalizar bem o conhecimento adquirido. Ape-

nas o conjunto de treino é considerado para o ajuste dos pesos sinápticos. O conjunto de validação é utilizado na parada do treinamento em caso de sobre-aprendizado. O sobre-aprendizado acontece quando a rede se ajusta demais ao conjunto de treino, perdendo capacidade de generalização. O resultado esperado do classificador é avaliado através do conjunto de teste, que não foi usado no ajuste dos pesos nem na parada do algoritmo.

Para decisão entre duas classes, pode-se usar na camada de saída um neurônio tipo tangente hiperbólica, associando-se $y = +1$ para uma classe e $y = -1$ para a outra. Para decisão entre N classes ($N \geq 3$), pode-se fazer com que a camada de saída tenha N neurônios. Associa-se um neurônio para cada classe. Quando a classe k estiver presente, a saída desejada no neurônio k associado deve ser $+1$ e nos demais -1 . Na fase de operação decide-se pela classe do neurônio com a maior saída. A rede da Figura B.3 é um exemplo de arquitetura que pode ser usada para a separação entre três classes a partir de um espaço de entrada de dimensão m .

Considerando uma rede de duas camadas (ver Figura B.3), a camada oculta é responsável por um mapeamento não-linear das entradas. Este mapeamento busca a máxima separação das classes diferentes, facilitando o processo de classificação realizado pela camada de saída.